




PARTE I

INTRODUÇÃO

Raciocínio Incerto

Introdução

- Uma das tarefas mais difíceis para um computador é simular a forma de raciocínio do ser humano.
- Quando o conhecimento sobre um problema é parcial ou impreciso, apenas se podem obter soluções aproximadas: **soluções com incerteza**
- Há várias formas de lidar com a incerteza na área da **Inteligência Artificial**

Raciocínio Incerto

Introdução

- Lidar com a incerteza:

“a incerteza surge devido a alguma deficiência de informação. A informação pode estar incompleta, ser vaga, imprecisa ou contraditória.”

Klir and Floger (1998) “Fuzzy sets, Uncertainty and Information”, Prentice Hall.

Raciocínio Incerto

Introdução

- Para lidar com a incerteza:
 - Teoria das Probabilidades (Bayes): *degree of belief*
 - Lógica Difusa: *degree of truth*
- Probabilidade: fornece uma forma de resumir a incerteza proveniente da falta de informação

Raciocínio Incerto

exemplos

- 80% dos pacientes já tratados, que têm dores de dentes, têm cáries.
- 5% da população que já teve tuberculose, tem pneumonia
- Eu tenho 80% de probabilidade de fazer um bom trabalho de CR
- A probabilidade do trabalho de CR ser bom é de 70%
- A probabilidade de ter 20 no trabalho de CR é 50%


Raciocínio Probabilístico

- Vantagens
 - Permite resolver problemas onde o raciocínio lógico ou raciocínio baseado em casos não conseguem ter sucesso
 - Torna a forma de resolver problemas mais abrangente e flexível
- Dificuldades
 - Obtenção dos dados que permitam ter probabilidades credíveis e fiáveis

Raciocínio Probabilístico

- A teoria das probabilidades oferece uma forma **quantitativa** de lidar com a incerteza da informação:
 - Possui uma semântica clara
 - Probabilidades podem ser obtidas a partir dos dados
 - Permite incorporar novas evidências de forma direta

Fumar	p
T	0.6
F	0.4



Poluição	p
T	0.3
F	0.7

Raciocínio Probabilístico

- Objetivos: ser capaz de dar respostas a duas situações
 - Como lidar com incerteza usando probabilidades?
 - Como representar a base de conhecimento de um sistema inteligente que usa raciocínio probabilístico?

PARTE II

TEORIA DAS PROBABILIDADES - REVISÃO

Teoria das probabilidades (revisão)

- Uma experiência aleatória **E** é uma experiência em que o resultado não pode ser previsto, mesmo que seja repetido várias vezes nas mesmas condições
 - Experiências
 - E1: Moeda ao ar
 - E2: Atirar o dado de jogo
 - E3: Retirar uma bola de uma caixa contendo bolas numeradas de 1 a 100
 - Variáveis aleatórias
 - E1: “face da moeda para cima”
 - E2: “face do dado para cima”
 - E3: “número da bola extraída”
 - Espaço da amostra: conjunto de valores que as variáveis podem ter
 - E1: {cara, coroa}
 - E2: {1, 2, 3, 4, 5, 6}
 - E3: {1, 2, ..., 100}

Teoria das probabilidades (revisão)

- Eventos

- Um **evento** é um subconjunto do espaço da amostra
 - E1: “Atirar a moeda três vezes e ver quantas vezes sai a cara e quantas vezes sai a coroa”
 - Evento: “aparecer duas caras (k) e uma coroa (c) em qualquer ordem”
 - Subconjunto: $\{(kkc), (kck), (ckk)\}$
 - E2: “Jogar um dado e observar o número na face para cima”
 - Evento: “número na face para cima é par”
 - Subconjunto: $\{2, 4, 6\}$
 - E3: “retirar uma bola e observar o seu número”
 - Evento: “bola extraída tem o número superior a 80”
 - Subconjunto: $\{81, 82, 83, \dots 99, 100\}$

Teoria das probabilidades (revisão)

- Variável aleatória
 - Assume valores no espaço da amostra e para a qual está determinada a probabilidade de ocorrência de cada um dos elementos do espaço da amostra
 - Se o espaço da amostra é contínuo: é necessário conhecer a função de distribuição de probabilidade
 - Se o espaço da amostra é discreto: é necessário conhecer a função massa de probabilidade

Teoria das probabilidades (revisão)

- Probabilidade
 - Para cada evento é atribuído um número real no intervalo $[0, 1]$ que indica qual a probabilidade desse evento ocorrer
 - Se o espaço da amostra consistir em N elementos com igual probabilidade e o evento A corresponder a um de subconjunto r elementos de N , então a probabilidade do evento A ocorrer é:

$$P(A) = r/N$$

Teoria das probabilidades (revisão)

- Probabilidade - exemplo

Uma caixa contém 10 bolas numeradas de 0 a 9. Numa experiência, retira-se uma bola e aponta-se o seu número. Qual a probabilidade dos seguintes eventos?

- A = “número da bola extraída é o 5”
- B = “número da bola extraída é ímpar”
- C = “número da bola extraída é múltiplo de 3”

➤ Espaço da amostra: $S = \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}$

➤ Eventos

$$A = \{5\}$$

$$B = \{1, 3, 5, 7, 9\}$$

$$C = \{3, 6, 9\}$$

Teoria das probabilidades (revisão)

- Probabilidade simples

$$P(A) = r/N$$

- $P(A) = P(5) = 1/10$

- $P(B) = P(1) + P(3) + P(5) + P(7) + P(9)$
 $= 1/10 + 1/10 + 1/10 + 1/10 + 1/10 = 5/10$

- $P(C) = P(3) + P(6) + P(9) = 1/10 + 1/10 + 1/10 = 3/10$

Teoria das probabilidades (revisão)

- **Probabilidade conjunta:** probabilidade de dois ou mais eventos ocorrerem simultaneamente

$$P(A, B, \dots, N) = P(A) * P(B) * \dots * P(N)$$

- Exemplo com dois eventos independentes:

Lançar uma moeda duas vezes

A = obter cara (k) na primeira jogada

B = obter cara (k) novamente na segunda jogada

$$P(A, B) = P(A) * P(B) = \frac{1}{2} * \frac{1}{2} = \frac{1}{4}$$

Teoria das probabilidades (revisão)

- Probabilidade conjunta :

- $P(A, B, \dots, N) = P(A) * P(B) * \dots * P(N)$

só é válida se os eventos forem independentes!!

- Dois eventos são independentes se a ocorrência de um não altera a probabilidade de ocorrência do outro.
 - Caso contrário são chamados eventos não independentes, ou dependentes.

Teoria das probabilidades (revisão)

- **Probabilidade condicional:**
 - Permite calcular a probabilidade de um evento **A** ocorrer, sabendo que outro evento **B** ocorreu:
 - Exemplos:
 - Qual a probabilidade de um doente ter cáries sabendo que está com dores de dentes?
 - Qual a probabilidade de chover sabendo que o céu está muito nublado?
 - Qual a probabilidade de ter 20 valores no exame, sabendo que estudei uma hora?

Teoria das probabilidades (revisão)

- Probabilidade condicional: $P(A \mid B) = P(A, B) / P(B)$
 - Experiência: jogar um dado uma vez
 - Eventos:
 - A = Número da face para cima é 6
 - B = Número da face para cima é maior ou igual do que 4
 - Qual a probabilidade de ocorrer o evento **A** sabendo que o evento **B** ocorreu?

$$\begin{aligned} P(A \mid B) &= P(A, B) / P(B) \\ &= P(A) * P(B) / P(B) \\ &= (1/6 * 1) / 1/2 = 1/3 \end{aligned}$$

Teoria das probabilidades (revisão)

- Probabilidade condicional: $P(A \mid B) = P(A, B) / P(B)$

	Não Fuma	Fuma	Total
Não tem doença respiratória	40	10	50
Tem doença respiratória	7	3	10
Total	47	13	60

- Sabendo que uma pessoa fuma, qual a probabilidade de ter DR?

$$P(\text{DR} \mid F) = P(\text{DR}, F) / P(F) = 3/60 / 13/60 = 0.23$$

Teoria das probabilidades (revisão)

- **Marginalização: obter probabilidades de variáveis a partir de outras**

$P(\text{Chover} \mid \text{Vento})$

Chover	Vento = F	Vento = V	SOMA
Falso	0.64	0.16	0.8
Verdadeiro	0.1	0.1	0.2

Qual a probabilidade: $P(\text{Chover})$?



Chover = F	Chover = V
0.8	0.2

Teoria das probabilidades (revisão)

Marginalização

$$P(A|B,C,D)$$

B	C	D	A = True	A = False
True	True	True	0.0036	0.0054
True	True	False	0.0098	0.0252
True	False	True	0.0024	0.0486
True	False	False	0.0042	0.1008
False	True	True	0.0256	0.0864
False	True	False	0.0432	0.1728
False	False	True	0.0064	0.2016
False	False	False	0.0048	0.25.92



Qual a probabilidade: $P(A|C)$?

C	A = True	A = False
True	0.0822	0.2898
False	0.0178	0.6102

Teoria das probabilidades (revisão)

- Lei da probabilidade total:
 - Se um evento **A** ocorre em **n** condições diferentes, todas mutuamente exclusivas, então a probabilidade do evento **A** ocorrer é a soma das probabilidades dele ocorrer nas **n** condições diferentes

$$P(A) = \sum_n P(A|B_n) * P(B_n)$$



$$P(A) = P(A|b_1)*P(b_1) + P(A|b_2)*P(b_2) + ... + P(A|b_n)*P(b_n)$$

Teoria das probabilidades (revisão)

- **Lei da probabilidade total** – exemplo, controle de qualidade

“Uma empresa multinacional tem 3 fábricas que produzem o mesmo tipo de produto. A fábrica 1 é responsável por 30% da produção, a fábrica 2 por 45% e o restante é produzido pela fábrica 3.

Cada uma das fábricas possui uma percentagem de produtos defeituosos que não cumprem os requisitos exigidos. Respetivamente 1%, 2% e 1.5% dos produtos são defeituosos nas três fabricas.

No centro de distribuição é feito o controle de qualidade da produção combinada das 3 fábricas.”

Teoria das probabilidades (revisão)

- **Lei da probabilidade total** – exemplo, controle de qualidade

“Qual a probabilidade de encontrar um produto defeituoso durante a inspeção de qualidade?”

$A = \{\text{Produto defeituoso}\}$ $F_i = \{\text{Produto da Fábrica } i\}$

$P(F_1) = 0.30$, $P(F_2) = 0.45$, $P(F_3) = 0.25$

$P(A|F_1) = 0.01$, $P(A|F_2) = 0.02$, $P(A|F_3) = 0.015$

Pela lei da probabilidade total:

$$\begin{aligned} P(A) &= P(A|F_1) * P(F_1) + P(A|F_2) * P(F_2) + P(A|F_3) * P(F_3) \\ &= 0.01 * 0.3 + 0.02 * 0.45 + 0.015 * 0.25 = 0.1575 \end{aligned}$$

Teorema de Bayes

Thomas Bayes (1702 - 1761)

- Formulou um teorema capaz de lidar com incertezas e atualizar a crença num determinado evento à medida que novas informações vão sendo conhecidas
- O teorema de Bayes é a base de todos os sistemas inteligentes modernos que utilizam raciocínio probabilístico



Teorema de Bayes

- Os estudos conduzidos por Bayes pretendiam encontrar uma forma de determinar a probabilidade de um evento futuro com base no número de vezes que ocorreu no passado!!
- Todo o seu estudo foi apenas experimental.
- Os estudos de Bayes não foram reconhecidos na época. O seu teorema só foi reconhecido após a sua morte.
- Laplace (1812) usou e desenvolveu o teorema de Bayes. A sua publicação deu o reconhecimento a um teorema que revolucionou a teoria das probabilidades.

Teorema de Bayes

- Na teoria da probabilidade, um valor é calculado com valores conhecidos à priori.
- O Teorema de Bayes veio provar que a probabilidade de uma **hipótese** pode ser calculada com base em **evidências** que sejam conhecidas à posteriori.

Teorema de Bayes

- Resumindo:
 - O teorema de Bayes permite **atualizar probabilidades** quando observamos nova evidência.
 - Começamos com uma crença inicial (priori).
Observamos novos dados (posteriori).
Atualizamos essa crença.
- É a base da inferência em **redes Bayesianas**.

Teorema de Bayes: Aplicações

- **Diagnóstico Médico:** Na medicina, o Teorema de Bayes é frequentemente utilizado para avaliar a probabilidade de um paciente ter uma determinada doença, baseando-se nos resultados de seus exames.
- **Sistemas de Recomendação:** Plataformas como Netflix e Spotify utilizam algoritmos baseados no Teorema de Bayes para recomendar filmes, séries e músicas baseadas nas preferências anteriores dos utilizadores.
- **Filtro de Spam em E-mails:** O filtro de spam de muitos serviços de e-mail usa o Teorema de Bayes para determinar a probabilidade de uma mensagem ser spam.
- **Previsão do Tempo:** Meteorologistas aplicam o Teorema de Bayes para atualizar as previsões do tempo à medida que novos dados são conhecidos.
- **Tomada de Decisões no desporto:** No basebol, por exemplo, técnicos e jogadores usam estatísticas baseadas no Teorema de Bayes para tomar decisões durante o jogo.

Teorema de Bayes

- Equação do Teorema de Bayes

$$P(A | B) = \frac{P(B | A) P(A)}{P(B)}$$

$P(A)$ → probabilidade a priori (antes da evidência)

$P(B | A)$ → verosimilhança (**qual a probabilidade de B sabendo que A é verdade**)

$P(B)$ → probabilidade total da evidência B

$$P(B) = \sum_i P(B|A_i) * P(A_i) \quad \text{Lei da probabilidade total – slide 24}$$

$P(A | B)$ → probabilidade de A a posteriori, conhecida a evidência B

Teorema de Bayes: exemplo 1

Diagnóstico Médico

- 1% da população tem uma doença
 - $P(D) = 0.01$
- O teste dá positivo em 95% dos doentes
 - $P(+|D) = 0.95$
- O teste dá falso positivo em 5% dos saudáveis
 - $P(+|\neg D) = 0.05$
- Pergunta:

Se o teste deu positivo, qual a probabilidade real de a pessoa estar doente?

Teorema de Bayes: exemplo 1

$$P(A | B) = \frac{P(B | A) P(A)}{P(B)}$$

- $P(D | +) = [P(+|D) * P(D)] / P(+)$

- Calcular $P(+)$

$$\begin{aligned} P(+|D)*P(D) + P(+|\neg D)*P(\neg D) \\ = 0.95 \times 0.01 + 0.05 \times 0.99 \\ = 0.0095 + 0.0495 = 0.059 \end{aligned}$$

$$\begin{aligned} P(+|D) &= 0.95 \\ P(D) &= 0.01 \\ P(+|\neg D) &= 0.05 \end{aligned}$$

Usando Bayes:

- $P(D|+) = (0.95*0.01) / 0.059 = 0.161$

Teorema de Bayes: exemplo 2

Intrusão num Servidor

- 2% das ligações são ataques reais
- O sistema IDS deteta corretamente 90% dos ataques
- O IDS gera falso alerta em 8% das ligações normais

Pergunta:

- Se o IDS gera um alerta, qual a probabilidade de ser mesmo um ataque?

Teorema de Bayes: exemplo 2

$$P(A | B) = \frac{P(B | A) P(A)}{P(B)}$$

- $P(A | \text{Alerta}) = [P(\text{Alerta} | A) * P(A)] / P(\text{Alerta})$

- Calcular $P(\text{Alerta})$

$$\begin{aligned} &P(\text{Alerta} | A) * P(A) + P(\text{Alerta} | \neg A) * P(\neg A) \\ &= 0.90 \times 0.02 + 0.08 \times 0.98 \\ &= 0.018 + 0.0784 = 0.0964 \end{aligned}$$

$$\begin{aligned} P(A) &= 0.02 \\ P(\text{Alerta} | A) &= 0.90 \\ P(\text{Alerta} | \neg A) &= 0.08 \end{aligned}$$

Usando Bayes:

- $P(A | \text{Alerta}) = (0.90 * 0.02) / 0.0964 = 0.187$

Teorema de Bayes: exemplo 3

- Um médico sabe que a meningite causa dores no pescoço em 50% dos casos que analisou. Ele sabe que a probabilidade conhecida de um paciente ter meningite (M) é $1/50000$ e que a probabilidade conhecida de um paciente ter dores de pescoço (S) é $1/20$
 - $P(S|M) = 1/2$
 - $P(M) = 1/50000$
 - $P(S) = 1/20$
- Teorema de Bayes: Um paciente chega ao consultório com dores no pescoço (evidência). Qual a probabilidade dele ter meningite, i.e, $P(M|S)$?

$$P(M|S) = [P(S|M)*P(M)] / P(S) = 1/2 * 1/50000 / 1/20 = 0.0002$$

Teorema de Bayes: exemplo 4

- Se durante a inspeção foi encontrado um produto defeituoso (evidência A), qual é a probabilidade desse produto ser da Fábrica 2 (hipótese)?
 - Já tínhamos calculado anteriormente a probabilidade de um produto ser defeituoso na inspeção de qualidade $P(A) = 0.1575$ (ver slide 26)
- E tínhamos a informação:
 $A = \{\text{Produto defeituoso}\}$ $F_i = \{\text{Produto da Fábrica } i\}$

 $P(F_1) = 0.30$, $P(F_2) = 0.45$, $P(F_3) = 0.25$
 $P(A|F_1) = 0.01$, $P(A|F_2) = 0.02$, $P(A|F_3) = 0.015$
- Pelo teorema de Bayes, a probabilidade de encontrar um produto defeituoso oriundo da Fábrica 2 é:

$$P(F_2|A) = P(A|F_2) * P(F_2) / P(A) = 0.02 * 0.45 / 0.1575 = 0.5714$$

PARTE III

REDES BAYESIANAS

Redes Bayesianas


- Usar o teorema de Bayes em sistemas inteligentes?
 - Como representar o conhecimento?
 - Como fazer inferências (raciocínio)?
- REDES BAYESIANAS - *Judea Pearl (1985)*

Redes Bayesianas

- Representação gráfica para raciocínio e representação de conhecimento que lida com incerteza
- Representam de forma compacta a distribuição de probabilidades conjuntas do universo do problema
- Consiste num grafo acíclico direcionado:
 - Vértices: variáveis aleatórias
 - Arestas: relações de causa-efeito entre as variáveis

Redes Bayesianas


- Nós da rede: variáveis, eventos que se pretendem modelar
- Arcos: ligam variáveis e indicam a presença de uma dependência condicional entre elas
- Cada nó possui uma tabela de probabilidades indicativas da ocorrência de cada estado desse evento, incluindo as probabilidades condicionais.



Redes Bayesianas

Modelo


- Sejam 3 variáveis aleatórias A, B e C
 - Se A for independente de B, e A e B influenciarem C, a rede correspondente terá o seguinte aspecto:



- A e B são **pais** de C
- C é **filho** de A e B


Na rede seguinte:

- D é um **antepassado** de B
- B é um **descendente** de D



Redes Bayesianas

- Para cada nó são assinaladas as seguintes tabelas de probabilidade:
 - Se um nó não tem pais, a tabela é do tipo $P(X)$
 - Se um nó tem apenas 1 pai, a tabela é do tipo $P(X|Y)$
 - Se um nó tem vários pais, a tabela é do tipo $P(X|Y_1, Y_2 \dots Y_n)$
- Nesta rede:
 - Cada nó X_i terá apenas uma tabela de probabilidade condicionada do tipo $P(X_i|Y)$, dado que cada atributo depende apenas de Y



Redes Bayesianas


- Desenhar uma Rede Bayesiana envolve 2 fases:
 - Desenhar a rede
 - Estimar as probabilidades condicionais envolvidas (através de históricos ou opinião de peritos)
- Para desenhar a rede:
 - Um nó para cada variável do problema
 - Captar as relações de causa-efeito entre as variáveis e traçar as setas das causas para os efeitos

Redes Bayesianas

- **Variáveis:** fumar, poluição, cancro do pulmão
- **Relações:** Fumar pode causar cancro, poluição pode causar cancro
- **Probabilidades:** obtidas por estudos, dados estatísticos, demográficos, ...

P(Fumar)

Fumar	p
S	0.4
N	0.6



P(Poluição)

Poluição	p
S	0.3
N	0.7

P(Cancro | Fumar, Poluição)

Fumar	Poluição	Tem cancro
S	S	0.7
S	N	0.4
N	S	0.05
N	N	0.01

Redes Bayesianas


Aplicações

- Diagnóstico
 - Medicina, falhas
- Inferência (previsão)
 - Economia, bolsa, meteorologia
- Classificação
 - Reconhecimento de padrões, fala, caracteres
- Data mining
 - Bioinformática

Redes Bayesianas

- Cálculos com redes Bayesianas

- **Probabilidade conjunta**: Probabilidade conjunta de qualquer acontecimento
- **Inferência Causal**: da causa para os efeitos, por exemplo: qual a probabilidade de uma pessoa ter cancro, sabendo que ela fuma?
- **Inferência de Diagnóstico**: dos efeitos para para as causas, por exemplo: sabendo que uma pessoa tem cancro, qual a probabilidade dessa pessoa fumar?



Redes Bayesianas – fórmulas

Cálculo de probabilidades conjuntas: $P(x_1, x_2, x_3, \dots, x_n) = \prod_{i=1}^n P(x_i | Parents(x_i))$

Cálculo de inferências causais (*evidências nas causas x_i*)

Usar a lei da probabilidade total

$$P(X) = \sum P(X | P(Parents\ x_i)) * P(Parents\ x_i)$$

Havendo alguma evidência nos *Parents*, $P(x_i)=1$;

Desconhecendo evidências somar todas probabilidades das várias possibilidades

Calculo de inferência de diagnóstico (*evidência nos efeitos x*):

Usar teorema de Bayes: $P(A|B) = P(B|A) * P(A) / P(B)$

$$P(C|x) = \frac{P(x|C)*P(C)}{P(x)} = \frac{P \sum [P(x|P(c_i))*P(c_i)]}{P(x)}$$

Numerador: Caso haja vários *parents* de uma determinada variável, somar todas as probabilidades

Denominador: usar a lei da probabilidade total com todas as possibilidades.

Redes Bayesianas

$$P(A | B) = \frac{P(B | A) P(A)}{P(B)}$$

• Cálculos com redes Bayesianas – exemplo 1a

- Ataque gera Alerta
- Alerta gera Pico de Tráfego
- $P(\text{Ataque}) = 0.02$ - Probabilidades conjuntas de ocorrer um ataque e não haver alerta?

$$P(\text{Ataque}, \neg \text{Alerta}) = P(\text{Ataque}) * P(\neg \text{Alerta} | \text{Ataque})$$

$$= 0.02 * 0.1 = 0.002$$

- Inferência Causal: Sabendo que ocorreu ataque, qual a probabilidade de não ter sido dado o alerta?

$$P(\neg \text{Alerta} | \text{Ataque}) = 0.1$$

- Inferência Diagnóstico: Sabendo que ocorreu Alerta, qual a probabilidade de ter ocorrido um ataque?


$$P(\text{Ataque} | \text{Alerta}) = P(\text{Alerta} | \text{Ataque}) * P(\text{Ataque}) / P(\text{Alerta})$$

$$= (0.9 * 0.02) / P(\text{Alerta})$$

$$= 0.018 / 0.0964 = 0.187$$

$$P(\text{Alerta}) = P(\text{Alerta} | \text{Ataque}) * P(\text{Ataque}) + P(\text{Alerta} | \neg \text{Ataque}) * P(\neg \text{Ataque})$$


$$P(\neg \text{Ataque}) = 0.9 * 0.02 + 0.08 * 0.98 = 0.018 + 0.0784 = 0.0964$$



Redes Bayesianas

- Cálculos com redes Bayesianas – exemplo 1a

- Um **Alerta** pode ser causado por um **Ataque** ou por um **Pico** legítimo de tráfego.
- $P(\text{Ataque}) = 0.02$ // $P(\text{Pico}) = 0.05$



Redes Bayesianas

- Probabilidades conjuntas de ocorrer um ataque e um Pico de tráfego e não haver alerta?

$$\begin{aligned} P(\text{Ataque}, \text{Pico}, \neg \text{Alerta}) &= P(\text{Ataque}) * P(\text{Pico}) * P(\neg \text{Alerta} \mid \text{Ataque}, \text{Pico}) \\ &= 0.02 * 0.05 * 0.01 = 0.00001 \end{aligned}$$

- Inferência Causal: Sabendo que ocorreu ataque (**evidência, Prob = 1**), qual a probabilidade de não ter sido dado o alerta? (nada sabemos sobre Pico de Tráfego)

$$\begin{aligned} P(\neg \text{Alerta} \mid \text{Ataque}) &= P(\neg \text{Alerta} \mid \text{Ataque}, \text{Pico}) * P(\text{Ataque}) * P(\text{Pico}) + \\ &= P(\neg \text{Alerta} \mid \text{Ataque}, \neg \text{Pico}) * P(\text{Ataque}) * P(\neg \text{Pico}) \\ &= 0.01 * 1 * 0.05 + 0.10 * 1 * 0.95 = 0,0005 + 0.095 = 0.095 \end{aligned}$$

Redes Bayesianas

$$P(A | B) = \frac{P(B | A) P(A)}{P(B)}$$

- Inferência Diagnóstico: Sabendo que ocorreu Alerta, qual a probabilidade de ter ocorrido um ataque?


$$\begin{aligned} P(\text{Ataque} | \text{Alerta}) &= P(\text{Alerta} | \text{Ataque}) / P(\text{Alerta}) \\ &= 0.018 / 0.0694 = 0.26 \end{aligned}$$

$$\begin{aligned} P(\text{Alerta} | \text{Ataque}) &= P(\text{Alerta} | \text{Ataque}, \text{Pico}) * P(\text{Alerta}) * P(\text{Pico}) + \\ &\quad P(\text{Alerta} | \text{Ataque}, \neg \text{Pico}) * P(\text{Ataque}) * P(\neg \text{Pico}) \\ &= 0.99 * 0.02 * 0.05 + 0.90 * 0.02 * 0.95 = 0.018 \end{aligned}$$

$$\begin{aligned} P(\text{Alerta}) &= P(\text{Alerta} | \text{Ataque}, \text{Pico}) * P(\text{Ataque}) * P(\text{Pico}) + \\ &\quad + P(\text{Alerta} | \text{Ataque}, \neg \text{Pico}) * P(\text{Ataque}) * P(\neg \text{Pico}) + \\ &\quad + P(\text{Alerta} | \neg \text{Ataque}, \text{Pico}) * P(\neg \text{Ataque}) * P(\text{Pico}) + \\ &\quad + P(\text{Alerta} | \neg \text{Ataque}, \neg \text{Pico}) * P(\neg \text{Ataque}) * P(\neg \text{Pico}) = \\ &= 0.99 * 0.02 * 0.05 + 0.90 * 0.02 * 0.95 + 0.85 * 0.98 * 0.05 + 0.01 * 0.98 * 0.95 = \\ &= 0.00099 + 0.0171 + 0.042 + 0.0093 = 0.0694 \end{aligned}$$

Redes Bayesianas

- Cálculos com redes Bayesianas



Redes Bayesianas

- Cálculo de probabilidades conjuntas:

- Qual a probabilidade de uma pessoa não fumar, e ter cancro e bronquite?

$$\begin{aligned} P(\neg\text{Fumar}, \text{Cancro}, \text{Bronquite}) &= P(\neg\text{Fumar}) * P(\text{Cancro} | \neg\text{Fumar}) * P(\text{Bronquite} | \neg\text{Fumar}) \\ &= 0.6 * 0.1 * 0.3 = 0.018 \end{aligned}$$

- Qual a probabilidade de uma pessoa fumar, e ter cancro e não ter bronquite?

$$\begin{aligned} P(\text{Fumar}, \text{Cancro}, \neg\text{Bronquite}) &= P(\text{Fumar}) * P(\text{Cancro} | \text{Fumar}) * P(\neg\text{Bronquite} | \text{Fumar}) \\ &= 0.4 * 0.7 * 0.2 = 0.056 \end{aligned}$$

- Qual a probabilidade de uma pessoa fumar, e ter cancro e ter bronquite?

$$\begin{aligned} P(\text{Fumar}, \text{Cancro}, \text{Bronquite}) &= P(\text{Fumar}) * P(\text{Cancro} | \text{Fumar}) * P(\text{Bronquite} | \text{Fumar}) \\ &= 0.4 * 0.7 * 0.8 = 0.224 \end{aligned}$$

Redes Bayesianas

- Cálculo de inferência causal

Qual a probabilidade de uma pessoa ter cancro, sabendo que ela fuma?

>> Resposta direta na rede bayesiana: **$P(\text{Cancro} | \text{Fumar}) = 0.7$**

Qual a probabilidade de uma pessoa ter bronquite, sabendo que ela não fuma?

>> Resposta direta na rede bayesiana: **$P(\text{Bronquite} | \neg \text{Fumar}) = 0.3$**

Qual a probabilidade de uma pessoa ter não ter bronquite, sabendo que ela fuma?

>> Resposta direta na rede bayesiana: **$P(\neg \text{Bronquite} | \text{Fumar}) = 0.2$**

Redes Bayesianas

$$P(A | B) = \frac{P(B | A) P(A)}{P(B)}$$

- Cálculo de inferência de diagnóstico
 - Sabendo que uma pessoa tem cancro, qual a probabilidade dessa pessoa fumar?

$$P(\text{Fumar} | \text{Cancro}) = \frac{P(\text{Cancro} | \text{Fumar}) * P(\text{Fumar})}{P(\text{Cancro})}$$

1º) Usando as probabilidades das tabelas

$$P(\text{Cancro} | \text{Fumar}) * P(\text{Fumar}) = 0.7 * 0.4 = 0.28$$


2º) Usando a lei da probabilidade total e probabilidades das tabelas

$$\begin{aligned} P(\text{Cancro}) &= P(\text{Cancro} | \text{Fumar}) * P(\text{Fumar}) + P(\text{Cancro} | \neg \text{Fumar}) * P(\neg \text{Fumar}) \\ &= (0.7 * 0.4) + (0.1 * 0.6) = 0.34 \end{aligned}$$

$$\text{Logo, } P(\text{Fumar} | \text{Cancro}) = 0.28 / 0.34 = 0.82$$

Redes Bayesianas

- Como obter dados probabilísticos para as tabelas da rede Bayesiana?
 - São fornecidos
 - São calculados a partir de estudos/históricos
- **Exemplo 1:** Diagnóstico de Falha num Servidor
 - Variáveis binárias:
 - Sobrecarga (S)
 - Falha de Hardware (H)
 - Erro de Sistema (E)
 - Servidor em Baixo (B)




Redes Bayesianas

- Como obter dados probabilísticos para as tabelas da rede Bayesiana

Exemplo 1: Diagnóstico de Falha num Servidor (1000 ocorrências)

S	H	E	B	Frequência
0	0	0	0	540
0	0	1	1	60
1	0	1	1	120
1	0	0	0	80
0	1	0	1	70
1	1	1	1	90
0	1	1	1	20
1	1	0	1	20



Regra Geral

Para qualquer nó X:

$$P(X \mid Pais(X)) = \frac{\hat{\text{frequência conjunta}}}{\hat{\text{frequência da configuração dos pais}}}$$

Ou seja:


Divide-se sempre pelo total das ocorrências dos pais

Redes Bayesianas

- Como obter dados probabilísticos para as tabelas da rede Bayesiana

Exemplo 1: Diagnóstico de Falha num Servidor (1000 ocorrências)

S	H	E	B	Frequência
0	0	0	0	540
0	0	1	1	60
1	0	1	1	120
1	0	0	0	80
0	1	0	1	70
1	1	1	1	90
0	1	1	1	20
1	1	0	1	20



Nós sem pais

$$P(S) = (120 + 80 + 90 + 20) / 1000 = 0.31$$

$$P(\neg S) = 0.69$$

$$P(H) = (70 + 90 + 20 + 20) / 1000 = 0.20$$


$$P(\neg H) = 0.80$$

Redes Bayesianas

- Como obter dados probabilísticos para as tabelas da rede Bayesiana

Exemplo 1: Diagnóstico de Falha num Servidor (1000 ocorrências)

S	H	E	B	Frequência
0	0	0	0	540
0	0	1	1	60
1	0	1	1	120
1	0	0	0	80
0	1	0	1	70
1	1	1	1	90
0	1	1	1	20
1	1	0	1	20



$$P(X | Pais(X)) = \frac{\text{frequência conjunta}}{\text{frequência da configuração dos pais}}$$

Nós com pais

$P(E|S)$

Para S=1 -> Total de S=1 = 120 + 80 + 90 + 20 = 310

Casos com E=1 e S=1: 120 + 90 = 210

Casos com E=0 e S=1: 80 + 20 = 100

$$P(E = 1 | S = 1) = 210/310 = 0.677$$


$$P(E = 0 | S = 1) = 100/310 = 0.323$$

Redes Bayesianas

- Como obter dados probabilísticos para as tabelas da rede Bayesiana

Exemplo 1: Diagnóstico de Falha num Servidor (1000 ocorrências)

S	H	E	B	Frequência
0	0	0	0	540
0	0	1	1	60
1	0	1	1	120
1	0	0	0	80
0	1	0	1	70
1	1	1	1	90
0	1	1	1	20
1	1	0	1	20



$$P(X | Pais(X)) = \frac{\hat{\text{frequência conjunta}}}{\hat{\text{frequência da configuração dos pais}}}$$

Nós com pais

$P(E|S)$

Para S=0 -> Total S=0 = 690

Casos E=1 e S=0: 60 + 20 = 80

Casos E=0 e S=0: 540 + 70 = 610

$$P(E = 1 | S = 0) = 80/690 = 0.116$$


$$P(E = 0 | S = 0) = 610/690 = 0.884$$

Redes Bayesianas

- Como obter dados probabilísticos para as tabelas da rede Bayesiana

Exemplo 1: Diagnóstico de Falha num Servidor (1000 ocorrências)

S	H	E	B	Frequência
0	0	0	0	540
0	0	1	1	60
1	0	1	1	120
1	0	0	0	80
0	1	0	1	70
1	1	1	1	90
0	1	1	1	20
1	1	0	1	20



Nós com pais

$P(B|E, H)$ -> 4 combinações de pais

Caso 1 - Para $E = 0, H = 0$ -> Total = 540 + 80 = 620

Casos $B=1$ e $E = 0, H = 0$: 0

Casos $B=0$ e $E = 0, H = 0$: 540 + 80 = 620

$$P(B = 1 | E = 0, H = 0) = 0$$

$$P(B = 0 | E = 0, H = 0) = 1$$


$$P(X | Pais(X)) = \frac{\hat{\text{frequência conjunta}}}{\hat{\text{frequência da configuração dos pais}}}$$

Redes Bayesianas

- Como obter dados probabilísticos para as tabelas da rede Bayesiana

Exemplo 1: Diagnóstico de Falha num Servidor (1000 ocorrências)

S	H	E	B	Frequência
0	0	0	0	540
0	0	1	1	60
1	0	1	1	120
1	0	0	0	80
0	1	0	1	70
1	1	1	1	90
0	1	1	1	20
1	1	0	1	20



Caso 2 - Para $E = 1, H = 0$ -> Total = 60 + 120 = 180

$$P(B = 1 \mid E = 1, H = 0) = 1$$

$$P(B = 0 \mid E = 1, H = 0) = 0$$

Caso 3 - Para $E = 0, H = 1$ -> Total = 70 + 20 = 90

$$P(B = 1 \mid E = 0, H = 1) = 1$$

$$P(B = 0 \mid E = 0, H = 1) = 0$$


Caso 4 - Para $E = 1, H = 1$ -> Total = 90 + 20 = 110

$$P(B = 1 \mid E = 1, H = 1) = 1$$

$$P(B = 0 \mid E = 1, H = 1) = 0$$

Redes Bayesianas

Exercício 1



Redes Bayesianas

Exercício 1

a) Cálculo de probabilidade conjunta:

Qual a probabilidade de ter um cão, ter um gato, ser feliz e não estar em forma?

$$\begin{aligned} P(\text{TerCão}, \text{TerGato}, \text{SerFeliz}, \neg \text{EmForma}) &= \\ &= P(\text{TerCão}) * P(\text{TerGato}) * P(\text{SerFeliz} | \text{TerCão}, \text{TerGato}) * P(\neg \text{EmForma} | \text{TerCão}) \\ &= 0.60 * 0.70 * 0.99 * 0.20 \\ &= 0.08316 \end{aligned}$$

Redes Bayesianas

Exercício 1

b) Cálculo de inferência causal:

A Joana tem um cão, qual a probabilidade de estar em forma?

Resposta direta da tabela = 0.8

A Joana tem um cão, qual a probabilidade de estar feliz?

Na inferência causal as evidências têm probabilidade 1

A evidência conhecida é **TerCão (100%)**, mas nada se sabe sobre a variável **TerGato** que também influencia **SerFeliz**, Logo, devem considerar-se as duas situações **TerGato** e **¬TerGato**:

$$\begin{aligned} P(\text{SerFeliz} | \text{TerCão}) &= P(\text{SerFeliz} | \text{TerCão}, \text{TerGato}) * P(\text{TerCão}) * P(\text{TerGato}) \\ &\quad + P(\text{SerFeliz} | \text{TerCão}, \neg \text{TerGato}) * P(\text{TerCão}) * P(\neg \text{TerGato}) \\ &= 0.99 * 1.0 * 0.70 + 0.80 * 1.0 * 0.30 = \\ &= 0.933 \end{aligned}$$

Redes Bayesianas

Exercício 1

$$\text{TEOREMA DE BAYES}$$
$$P(A|B) = P(B|A) * P(A) / P(B)$$

c) Cálculo de inferência de diagnóstico:

Sabendo que a Joana está feliz, qual a probabilidade de ter um cão?

$$P(\text{TerCão} | \text{SerFeliz}) = P(\text{SerFeliz} | \text{TerCao}) * P(\text{TerCao}) / P(\text{SerFeliz})$$

1º) Calcular $P(\text{SerFeliz} | \text{TerCao}) * P(\text{TerCao})$

SerFeliz é uma evidência que depende de **TerCão** (hipótese) e **TerGato**.

Nada se sabe sobre a variável **TerGato**.

Logo, devem considerar-se as duas situações **TerGato** e **¬TerGato**

$$\begin{aligned} & P(\text{SerFeliz} | \text{TerCao}, \text{TerGato}) * P(\text{TerCao}) * P(\text{TerGato}) + \\ & + P(\text{SerFeliz} | \text{TerCao}, \neg \text{TerGato}) * P(\text{TerCao}) * P(\neg \text{TerGato}) = \\ & = (0.99 * 0.60 * 0.70) + (0.80 * 0.60 * 0.30) = \\ & = 0.4158 + 0.144 = 0.5598 \end{aligned}$$

Redes Bayesianas

Exercício 1

c) Cálculo de inferência de diagnóstico (continuação):

Sabendo que a Joana está feliz, qual a probabilidade de ter um cão?

$$P(\text{TerCão} | \text{SerFeliz}) = P(\text{SerFeliz} | \text{TerCão}) * P(\text{TerCão}) / P(\text{SerFeliz})$$


2º) Calcular $P(\text{SerFeliz})$

$$\begin{aligned} P(\text{SerFeliz}) &= P(\text{SerFeliz} | \text{TerCão}, \text{TerGato},) * P(\text{TerCão}) * P(\text{TerGato}) + \\ &+ P(\text{SerFeliz} | \text{TerCão}, \neg \text{TerGato},) * P(\text{TerCão}) * P(\neg \text{TerGato}) + \\ &+ P(\text{SerFeliz} | \neg \text{TerCão}, \text{TerGato},) * P(\neg \text{TerCão}) * P(\text{TerGato}) + \\ &+ P(\text{SerFeliz} | \neg \text{TerCão}, \neg \text{TerGato},) * P(\neg \text{TerCão}) * P(\neg \text{TerGato}) = \\ &= (0.99 * 0.60 * 0.70) + (0.80 * 0.60 * 0.30) + \\ &+ (0.70 * 0.40 * 0.70) + (0.10 * 0.40 * 0.30) = \\ &= 0.4158 + 0.144 + 0.196 + 0.012 = 0.7678 \end{aligned}$$

$$\begin{aligned} \text{LOGO: } P(\text{TerCão} | \text{SerFeliz}) &= P(\text{SerFeliz} | \text{TerCão}) * P(\text{TerCão}) / P(\text{SerFeliz}) \\ &= \mathbf{0.5598 / 0.7678 = 0.729} \end{aligned}$$

Redes Bayesianas

Exercício 2



Redes Bayesianas

Exercício 2

a) Cálculo de probabilidade conjunta:

Qual a probabilidade de não ocorrer assalto, nem terremoto, o alarme ligar e o João e a Maria ligarem?

$$\begin{aligned} P(\neg \text{Assalto}, \neg \text{Terramoto}, \text{Alarme}, \text{JoãoLiga}, \text{MariaLiga}) &= \\ &= P(\neg \text{Assalto}) * P(\neg \text{Terramoto}) * P(\text{Alarme} | \neg \text{Assalto}, \neg \text{Terramoto}) * P(\text{JoãoLiga} | \text{Alarme}) * P(\text{MariaLiga} | \text{Alarme}) \\ &= 0.999 * 0.998 * 0.001 * 0.9 * 0.7 \\ &= 0.000628 \end{aligned}$$

Redes Bayesianas

Exercício 2

b) Cálculo de inferência causal:

Qual a probabilidade de o alarme tocar, sabendo que não ocorreu assalto, nem terremoto?

>> $P(\text{Alarme} \mid \neg \text{Assalto}, \neg \text{Terramoto}) = 0.001$

Qual a probabilidade de o alarme tocar, sabendo que ocorreu assalto e terremoto?

>> $P(\text{Alarme} \mid \text{Assalto}, \text{Terramoto}) = 0.95$

Qual a probabilidade da Maria Ligar sabendo que o alarme não tocou?

>> $P(\text{MariaLiga} \mid \neg \text{Alarme}) = 0.01$

Redes Bayesianas

Exercício 2

c) Cálculo de inferência de diagnóstico (1):

O Alarme ligou. Qual a probabilidade de ter ocorrido assalto?

$$P(\text{Assalto} | \text{Alarme}) = P(\text{Alarme} | \text{Assalto}) * P(\text{Assalto}) / P(\text{Alarme})$$

1º) Calcular numerador

$$\begin{aligned} &= P(\text{Alarme} | \text{Assalto}, \text{Terramoto}) * P(\text{Assalto}) * P(\text{Terramoto}) + \\ &+ P(\text{Alarme} | \text{Assalto}, \neg \text{Terramoto}) * P(\text{Assalto}) * P(\neg \text{Terramoto}) = \\ &= (0.95 * 0.001 * 0.002) + (0.94 * 0.001 * 0.998) = 0.0094 \end{aligned}$$

$$\begin{aligned} \text{2º) Calcular denominador} &= P(\text{Alarme} | \text{Assalto}, \text{Terramoto}) * P(\text{Assalto}) * P(\text{Terramoto}) + \\ &+ P(\text{Alarme} | \text{Assalto}, \neg \text{Terramoto}) * P(\text{Assalto}) * P(\neg \text{Terramoto}) + \\ &+ P(\text{Alarme} | \neg \text{Assalto}, \text{Terramoto}) * P(\neg \text{Assalto}) * P(\text{Terramoto}) + \\ &+ P(\text{Alarme} | \neg \text{Assalto}, \neg \text{Terramoto}) * P(\neg \text{Assalto}) * P(\neg \text{Terramoto}) = \end{aligned}$$

$$\begin{aligned} &= (0.95 * 0.001 * 0.002) + (0.94 * 0.001 * 0.998) + (0.29 * 0.999 * 0.002) + (0.001 * 0.999 * 0.998) = \\ &= 0.00252 \end{aligned}$$

$$\text{Logo, } P(\text{Assalto}, \text{Alarme}) / P(\text{Alarme}) = 0.374$$

Redes Bayesianas

Exercício 2

d) Cálculo de inferência de diagnóstico (2):

O João ligou. Qual a probabilidade de ter ocorrido assalto?

$$P(\text{Alarme} | \text{Assalto}) * P(\text{Assalto}) / P(\text{Alarme})$$

$$P(\text{Assalto} | \text{JoãoLiga}) = P(\text{JoãoLiga} | \text{Assalto}) * P(\text{Assalto}) / P(\text{JoãoLiga})$$

1º) Calcular Numerador

$$\begin{aligned} & P(\text{JoãoLiga} | \text{Alarme}) * P(\text{Alarme} | \text{Assalto}, \text{Terramoto}) * P(\text{Assalto}) * P(\text{Terramoto}) + \\ & + P(\text{JoãoLiga} | \text{Alarme}) * P(\text{Alarme} | \text{Assalto}, \neg \text{Terramoto}) * P(\text{Assalto}) * P(\neg \text{Terramoto}) + \\ & + P(\text{JoãoLiga} | \neg \text{Alarme}) * P(\neg \text{Alarme} | \text{Assalto}, \text{Terramoto}) * P(\text{Assalto}) * P(\text{Terramoto}) + \\ & + P(\text{JoãoLiga} | \neg \text{Alarme}) * P(\neg \text{Alarme} | \text{Assalto}, \neg \text{Terramoto}) * P(\text{Assalto}) * P(\neg \text{Terramoto}) = \\ & = (0.9 * 0.95 * 0.001 * 0.002) + \\ & + (0.9 * 0.94 * 0.001 * 0.998) + \\ & + (0.005 * 0.005 * 0.001 * 0.002) + \\ & + (0.05 * 0.06 * 0.001 * 0.998) = 0.00084902 \end{aligned}$$

Redes Bayesianas

Exercício 2

d) Cálculo de inferência de diagnóstico (continuação)

2º) Calcular $P(\text{JoãoLiga}) =$

$$\begin{aligned} &= P(\text{JoãoLiga} | \text{Alarme}) * P(\text{Alarme} | \text{Assalto, Terramoto}) * P(\text{Assalto}) * P(\text{Terramoto}) + \\ &+ P(\text{JoãoLiga} | \neg \text{Alarme}) * P(\neg \text{Alarme} | \text{Assalto, Terramoto}) * P(\text{Assalto}) * P(\text{Terramoto}) + \\ &+ P(\text{JoãoLiga} | \text{Alarme}) * P(\text{Alarme} | \text{Assalto, } \neg \text{Terramoto}) * P(\text{Assalto}) * P(\neg \text{Terramoto}) + \\ &+ P(\text{JoãoLiga} | \neg \text{Alarme}) * P(\neg \text{Alarme} | \text{Assalto, } \neg \text{Terramoto}) * P(\text{Assalto}) * P(\neg \text{Terramoto}) + \\ &+ P(\text{JoãoLiga} | \text{Alarme}) * P(\text{Alarme} | \neg \text{Assalto, Terramoto}) * P(\neg \text{Assalto}) * P(\text{Terramoto}) + \\ &+ P(\text{JoãoLiga} | \neg \text{Alarme}) * P(\neg \text{Alarme} | \neg \text{Assalto, Terramoto}) * P(\neg \text{Assalto}) * P(\text{Terramoto}) + \\ &+ P(\text{JoãoLiga} | \text{Alarme}) * P(\text{Alarme} | \neg \text{Assalto, } \neg \text{Terramoto}) * P(\neg \text{Assalto}) * P(\neg \text{Terramoto}) + \\ &+ P(\text{JoãoLiga} | \neg \text{Alarme}) * P(\neg \text{Alarme} | \neg \text{Assalto, } \neg \text{Terramoto}) * P(\neg \text{Assalto}) * P(\neg \text{Terramoto}) = \\ &= (0.9 * 0.95 * 0.001 * 0.002) + (0.05 * 0.05 * 0.001 * 0.002) + (0.9 * 0.94 * 0.001 * 0.998) + \\ &+ (0.05 * 0.06 * 0.001 * 0.998) + (0.9 * 0.29 * 0.999 * 0.002) + (0.05 * 0.71 * 0.999 * 0.002) + \\ &+ (0.9 * 0.001 * 0.999 * 0.998) + (0.05 * 0.999 * 0.999 * 0.998) = 0.0521 \end{aligned}$$

Redes Bayesianas

Exercício 2


d) Cálculo de inferência de diagnóstico (conclusão)

O João ligou. Qual a probabilidade de ter ocorrido assalto?

$$\begin{aligned} P(\text{Assalto} | \text{JoãoLiga}) &= 0.00084902 / 0.0521 \\ &= 0.01628373 \end{aligned}$$

Redes Bayesianas

Exercício 3



Redes Bayesianas

Exercício 3

a) Cálculo de probabilidade conjunta:

Qual a probabilidade de estar nublado, não chover, não haver rega automática e a relva estar molhada?

$$\begin{aligned} P(\text{Nublado}, \neg\text{Chuva}, \neg\text{RegaAut}, \text{RelvaMolhada}) &= \\ &= P(\text{Nublado}) * P(\neg\text{Chuva} | \text{Nublado}) * P(\neg\text{RegaAut} | \text{Nublado}) * P(\text{RelvaMolhada} | \neg\text{Chuva}, \neg\text{RegaAut}) \\ &= 0.5 * 0.2 * 0.9 * 0 \\ &= 0.0 \end{aligned}$$

Redes Bayesianas

Exercício 3

b) Cálculo de inferência causal:

- Qual a probabilidade de não chover, sabendo que está nublado?
>> $P(\text{Chuva} | \text{Nublado}) = 0.8$
- Qual a probabilidade da relva esta molhada sabendo que choveu e a rega automática ligou.
>> $P(\text{RelvaMolhada} | \text{Chuva}, \text{RegaAut}) = 0.99$
- Qual a probabilidade da rega automática não ligar se estiver nublado?
>> $P(\neg \text{RegaAut} | \text{Nublado}) = 0.90$

Redes Bayesianas

Exercício 3

c) Cálculo de Inferência de diagnóstico:

Sabendo que a relva está molhada, qual a probabilidade de ter chovido?

$$P(\text{Chuva} | \text{RelvaMolhada}) = P(\text{RelvaMolhada} | \text{Chuva}) * P(\text{Chuva}) / P(\text{RelvaMolhada})$$

1º) Calcular $P(\text{RelvaMolhada} | \text{Chuva}) * P(\text{Chuva})$

2º) Calcular $P(\text{RelvaMolhada})$

Redes Bayesianas

Exercício 3

c) Cálculo de Inferência de diagnóstico:

$$\begin{aligned} 1^{\circ}) &= P(\text{RelvaMolhada} \mid \text{Chuva}) * P(\text{Chuva}) \\ &= P(\text{RelvaMolhada} \mid \text{RegaAut}, \text{Chuva}) * P(C \mid N) * P(RA \mid N) * P(N) + \\ &\quad + P(\text{RelvaMolhada} \mid \text{RegaAut}, \text{Chuva}) * P(C \mid \neg N) * P(RA \mid \neg N) * P(\neg N) + \\ &\quad + P(\text{RelvaMolhada} \mid \neg \text{RegaAut}, \text{Chuva}) * P(C \mid N) * P(\neg RA \mid N) * P(N) + \\ &\quad + P(\text{RelvaMolhada} \mid \neg \text{RegaAut}, \text{Chuva}) * P(C \mid \neg N) * P(\neg RA \mid \neg N) * P(\neg N) \\ \\ &= (0.99 * 0.8 * 0.1 * 0.5) + (0.99 * 0.2 * 0.5 * 0.5) + (0.9 * 0.8 * 0.9 * 0.5) + (0.9 * 0.2 * 0.5 * 0.5) = \\ &= 0.0396 + 0.0495 + 0.324 + 0.045 = 0.4581 \end{aligned}$$

Redes Bayesianas

Exercício 3

c) Cálculo de Inferência de diagnóstico:

2º) Calcular $P(\text{RelvaMolhada})$

$$\begin{aligned} P(\text{RelvaMolhada}) = & P(\text{RelvaMolhada} | \text{RegaAut}, \text{Chuva}) * P(\text{RA} | \text{N}) * P(\text{C} | \text{N}) * P(\text{N}) + \\ & + P(\text{RelvaMolhada} | \text{RegaAut}, \text{Chuva}) * P(\text{RA} | \neg \text{N}) * P(\text{C} | \neg \text{N}) * P(\neg \text{N}) + \\ & + P(\text{RelvaMolhada} | \text{RegaAut}, \neg \text{Chuva}) * P(\text{RA} | \text{N}) * P(\neg \text{C} | \text{N}) * P(\text{N}) + \\ & + P(\text{RelvaMolhada} | \neg \text{RegaAut}, \text{Chuva}) * P(\neg \text{RA} | \text{N}) * P(\text{C} | \text{N}) * P(\text{N}) + \\ & + P(\text{RelvaMolhada} | \neg \text{RegaAut}, \neg \text{Chuva}) * P(\neg \text{RA} | \text{N}) * P(\neg \text{C} | \text{N}) * P(\text{N}) + \\ & + P(\text{RelvaMolhada} | \text{RegaAut}, \neg \text{Chuva}) * P(\text{RA} | \neg \text{N}) * P(\neg \text{C} | \neg \text{N}) * P(\neg \text{N}) + \\ & + P(\text{RelvaMolhada} | \neg \text{RegaAut}, \text{Chuva}) * P(\neg \text{RA} | \neg \text{N}) * P(\text{C} | \neg \text{N}) * P(\neg \text{N}) + \\ & + P(\text{RelvaMolhada} | \neg \text{RegaAut}, \neg \text{Chuva}) * P(\neg \text{RA} | \neg \text{N}) * P(\neg \text{C} | \neg \text{N}) * P(\neg \text{N}) = \end{aligned}$$

$$\begin{aligned} = & (0.99 * 0.1 * 0.8 * 0.5) + (0.99 * 0.5 * 0.2 * 0.5) + (0.90 * 0.1 * 0.2 * 0.5) + (0.9 * 0.9 * 0.8 * 0.5) + \\ & + (0) + (0.9 * 0.5 * 0.8 * 0.5) + (0.9 * 0.5 * 0.2 * 0.5) + (0) = \\ = & 0.0396 + 0.0495 + 0.009 + 0.324 + 0 + 0.18 + 0.045 + 0 \\ = & 0.6471 \end{aligned}$$

Redes Bayesianas

Exercício 3

c) Cálculo de Inferência de diagnóstico (conclusão)

Sabendo que a relva está molhada, qual a probabilidade de ter chovido?

$$P(\text{Chuva} | \text{RelvaMolhada}) = 0.4581 / 0.6471 = 0.7079$$

Resposta: Há uma de 70,79% de probabilidade de ter chovido

Redes Bayesianas

Exercício 4


Desenhe a rede bayesiana para a seguinte situação (sem probabilidades)

As pessoas que têm gatos podem apresentar arranhadelas e ter rinite. A rinite pode também ser causada por outras alergias diferentes do gato. Quem tem rinite espirra com muita frequência, assim como quem está constipado.

Redes Bayesianas


Exercício 4

Solução



Redes Bayesianas

Exercício 5



Redes Bayesianas

Exercício 5

Analise a Rede Bayesiana do slide anterior e calcule:

(valores a obter estão a vermelho)


- a) A de probabilidade conjunta de ter rendimento alto, débito baixo, obter crédito e não ter stress. (0.095)
- b) A Joana tem rendimento e débito altos, qual a probabilidade de obter crédito? (0.80)
- c) A Joana tem rendimento alto. Qual a probabilidade de obter crédito? (0.857)
- d) A Joana tem stress. Qual a probabilidade de ter débito alto? (0.913)

Redes Bayesianas - Exercício 6

Problema de Arranque de Automóvel

Variáveis:

- Bateria Fraca (BF)
- Combustível Baixo (CB)
- Motor Não Arranca (M)
- Luzes Fracas (L)
- Indicador de Combustível (I)



Dado o histórico abaixo, calcule as probabilidades para inserir nos nós da rede Bayesiana


BF	CB	M	L	I	Freq
0	0	0	0	0	400
1	0	1	1	0	120
0	1	1	0	1	150
1	1	1	1	1	130
1	0	0	1	0	40
0	1	0	0	1	60
0	0	1	0	0	50
1	1	0	1	1	50

Redes Bayesianas - Exercício 7

Atrasos em Transportes

Variáveis:

- **Clima (C)** $\in \{\text{Bom, Chuva, Tempestade}\}$
- **Trânsito (T)** $\in \{\text{Baixo, Médio, Alto}\}$
- **Acidente (A)** $\in \{\text{Sim, Não}\}$
- **Atraso (D)** $\in \{\text{Sem, Pequeno, Grande}\}$



Dado o histórico abaixo, calcule as probabilidades para inserir nos nós da rede Bayesiana

C	T	A	D	Freq
Bom	Baixo	Não	Sem	180
Bom	Médio	Não	Pequeno	120
Bom	Alto	Sim	Grande	50
Chuva	Médio	Não	Pequeno	130
Chuva	Alto	Sim	Grande	140
Chuva	Alto	Não	Pequeno	60
Tempestade	Alto	Sim	Grande	160
Tempestade	Médio	Sim	Grande	80
Tempestade	Baixo	Não	Pequeno	80