


CONHECIMENTO E RACIOCÍNIO

06 – Análise e tratamento de dados Datasets



Inteligência Artificial e aprendizagem




O objetivo dos algoritmos de machine learning:

- aprender com os **dados conhecidos**, para resolver novos problemas

Aprendizagem de máquina (*Machine Learning*)


- Tipos de Aprendizagem
 - Supervisionada: sistemas de regressão, redes neurais
 - Não supervisionada: segmentação, agrupamento (clustering)
 - Por reforço: robótica, jogos




Aprendizagem de máquina

Aprendizagem supervisionada

CLASSIFICAÇÃO




REGRESSÃO




Aprendizagem de máquina

Aprendizagem supervisionada


Metodologia



Tratamento dos dados




Tratamento dos dados



Tratamento dos dados

(feature engineering)

- A importância dos dados



What data scientists spend the most time doing

- Building training sets: 3%
- Cleaning and organizing data: 60%
- Collecting data sets; 19%
- Mining data for patterns: 9%
- Refining algorithms: 4%
- Other: 5%

Tratamento dos dados

(*feature engineering*)

- Os algoritmos de *machine learning* precisam de dados numéricos, e alguns requisitos que precisam de ser validados no dataset

- Como transformar **dados não tratados** em **atributos** (*features*) que possam ser usados em algoritmos de ML?

IMAGENS TEXTO GRÁFICOS ...

DADOS EM TABELAS

NÚMEROS

Tratamento dos dados

(feature engineering)

- Podemos definir preparação de dados/feature engineering como a transformação de dados não tratados num formato que seja mais adequado para para os algoritmos de ML
- Porquê?
 - Algoritmos de ML geralmente exigem que os dados sejam **números**
 - Alguns algoritmos de ML impõem requisitos aos dados
 - **Ruído** estatístico e **erros** nos dados podem precisar ser corrigidos
 - **Relacionamentos não lineares** complexos podem ser extraídos dos dados
 - ...

Tratamento dos dados

Dataset

- O que é um dataset?
 - Consiste numa tabela
 - Colunas são os atributos (features) de um determinado problema
 - Em problemas de classificação: Há uma coluna referente ao **target**
 - As linhas são os exemplos disponíveis para treinar e validar o modelo de machine learning

Iris **classification** problem



	feature				target
	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	species
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa

Id

Example



Tratamento dos dados

Features

- O que é um atributo (*feature*) ?
 - Qualquer **valor** que possa ser calculado a partir de dados brutos com o objetivo de modelar o **problema** para um algoritmo de ML

Iris **classification** problem



feature

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	species
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa

Id

Example



Tratamento dos dados

Features

- O que são bons atributos?
 - **Informativos**: descrevam algo que faça sentido para o ser humano
 - **Disponíveis**: estarem presentes em vários exemplos diferentes
 - **Discriminantes**: permitam distinguir as várias classes
 - **Independentes**
 - **Simples**



Iris Versicolor



COMPRIMENTO DA PÉTALA

TAMANHO DO FOCINHO

Tratamento dos dados

Tarefas

- **Análise Exploratória dos Dados (AED)**
- **Limpeza**
- **Transformação**
- **Seleção**
- **Redução**

Tratamento dos dados

Tarefas

Análise Exploratória dos Dados

Tratamento dos dados

Análise exploratória dos dados

- **Análise dos Atributos**
 - Valores em falta
 - Tipos de dados (numéricos, categóricos)
 - Redundância
 - Atributos não discriminantes
 - Outliers
 - Escalas diferentes
 - Análise estatística
- **Análise do Target**
 - Quantas Classes?
 - Classes balanceadas?

Tratamento dos dados

Análise exploratória dos dados: Visualização dos dados

- A análise prévia e a visualização dos dados de um *dataset* pode dar informação para tomar decisões relativamente às tarefas anteriores
- Para cada atributo, fazer uma análise estatística:
 - Média, moda, mediana, desvio padrão.
- Usar gráficos que permitam visualizar os dados
 - Correlação, outliers, balanceamento, ...

Tratamento dos dados

Análise exploratória dos dados: Visualização dos dados


- **Gráficos de dispersão:** bons para analisar correlação entre dados (regressão linear), ver *outliers*



Tratamento dos dados

Análise exploratória dos dados: Visualização dos dados

X	Y
120	25
130	30
110	22
145	46
150	52
165	64
173	69
169	70
170	66
172	72
165	69
180	74




Média	154,08	54,92
Moda	165,00	69,00
Mediana	165,00	65,00
Desv. Pad	23,06	19,48
Máximo	180,00	74,00
Mínimo	110,00	22,00

Tratamento dos dados

Análise exploratória dos dados: Visualização dos dados

X	Y
120	30
130	70
110	22
145	46
150	52
165	64
173	69
169	70
170	66
172	90
165	69
180	74




Média	154,08	60,17
Moda	165,00	70,00
Mediana	165,00	67,50
Desv. Pad	23,06	19,34
Máximo	180,00	90,00
Mínimo	110,00	22,00

Tratamento dos dados

Análise exploratória dos dados: Visualização dos dados


- **Histogramas:** bons para analisar o balanceamento de classes, divisão dos atributos em gamas diferentes de valores.



Tratamento dos dados

Análise exploratória dos dados: Visualização dos dados

- **Visualização do dataset: relação entre peso e altura (valores normalizados)**




Gén	Altura	Peso
M	0,58	0,49
M	0,43	0,53
M	1,00	1,00
M	0,73	0,88
M	0,38	0,39
M	1,00	0,98
F	0,00	0,00
F	0,25	0,29
M	0,43	0,39
M	0,33	0,61

Tratamento dos dados


Análise exploratória dos dados: Visualização dos dados

Gén	Altura	Peso
0	1,76	70
0	1,7	72
0	1,93	96
0	1,82	90
0	1,68	65
0	1.93	95
1	1,53	45
1	1,63	60
0	1,7	65
0	1,66	76


Atributo Género



Histograma da altura



Histograma do peso



Tratamento dos dados

Tarefas

Limpeza


Tratamento dos dados

Tarefas: *LIMPEZA*

Titanic dataset

Predict survival

Classificação



PROBLEMAS

DADOS

- Inconsistentes
- Irrelevantes
- Redundantes
- Não discriminantes
- Duplicados
- Com valores em falta

Target			Error			Redundant			Missing					
pclass	survived		name	sex	age	sibsp	parch	ticket	fare	cabin	embarked	boat	body	home.dest
0	1	1	Allen, Miss. Elisabeth Walton	female	29.0000	0	0	24160	211.3375	B5	S	2	NaN	St Louis, MO
1	1	1	Allison, Master. Hudson Trevor	male	0.9167	1	2	113781	151.5500	C22	S	11	NaN	Montreal, PQ / Chesterville, ON
2	1	0	Allison, Miss. Helen Loraine	female	2.0000	1	2	113781	151.5500	C22	S	NaN	NaN	Montreal, PQ / Chesterville, ON
3	1	0	Allison, Mr. Hudson Joshua Creighton	male	30.0000	1	2	113781	151.5500	C22	S	NaN	135.0	Montreal, PQ / Chesterville, ON
4	1	0	Allison, Mrs. Hudson J C (Bessie Waldo Daniels)	female	25.0000	1	2	113781	151.5500	C22	S	NaN	NaN	Montreal, PQ / Chesterville, ON

Inconsistent

Irrelevant

Non discriminant

Duplication

Tratamento dos dados

Tarefas: *LIMPEZA*

Valores em falta (NaN)

student_id	age	gender	hours_study_per_week	previous_grade	passed_exam
101	20	M	5	12.5	yes
102	21	F	8	15.0	yes
103	NaN	F	7	14.0	yes
104	22	Male	6	NaN	no
105	120	F	2	10.0	no
106	21	M	40	13.5	yes
107	20	Female	5	12.0	yes
108	NaN	F	7	14.5	yes
108	20	Female	5	14.5	yes
110	19	M	6	11.0	no

Atributos não discriminantes

Escalas diferentes


Formatos mistos:

Linhas duplicadas

id	height	signup_date	hours_studied	final_exam_score	passed_exam
1	175	10-01-2024	5	12	yes
2	1.68	10/02/24	7	15	yes
3	182	5 Mar 2024	6	14	yes
4	1.75	12/jun/24	8	16	yes
5	169	12/05/24	4	10	no
6	182	05/03/24	6	14	yes

Tratamento dos dados

LIMPEZA



Tratamento dos dados

LIMPEZA

Tarefas básicas

- **Exemplos redundantes:**

- Linhas com dados duplicados

ELIMINAR!!!

- **Atributos redundantes:**


- Colunas com poucos valores (baixa variância)
- Colunas com valores únicos
- Colunas que possam ser obtidas de outras: Data de nascimento >> Idade

Tratamento dos dados

LIMPEZA

Outliers

- São valores extremos que não se enquadram na maioria dos valores
 - Um verdadeiro outlier
 - Erros no registo dos dados
 - Corrupção nos dados
- Porque são um problema:
 - Afetam a média, desvio padrão
 - Afetam o desempenho de alguns algoritmos de ML (ex: regressão linear)



Tratamento dos dados

LIMPEZA

Outliers – soluções possíveis

- **Remover**
 - Usar o método do desvio padrão
 - Usar o método da Amplitude interquartil (*Interquartile range – IQR*)
- **É Ruído ou Erro? Então, alterar o valor**
 - **Atribuir um valor mais ajustado aos dados:** ordene os valores, divida em intervalos com o mesmo número de valores, substitua esses valores pela média

Tratamento dos dados

LIMPEZA

Valores em falta

- **Porque surgem?**
 - Informação considerada pouco importante (ex: email)
 - Informação desconhecida na altura da recolha dos dados (ex: tipo de sangue)
 - Informação não obrigatória (ex: telefone)
 - Informação inexistente (nº de gravidezes num homem)
 - Distração ou falhas na recolha dos dados

Tratamento dos dados

LIMPEZA

Valores em falta

- **Soluções**

- Eliminar as linhas onde existam valores em falta
- Preencher com um valor aleatório
- Preencher usando dados estatísticos (média, moda, mediana)
- Preencher usando modelos de previsão ou aproximação (CBR, regressão, redes neuronais, ...)

Tratamento dos dados

LIMPEZA

Estratégias para lidar com valores em falta:

- Por exemplo, atribuir os valores dos exemplo mais próximo (CBR)
 - Qual a altura do homem com o peso mais próximo de 95?
 - **1.93**
- Por exemplo, usar o valor médio da amostra
 - Qual a média do peso dos homens?
 - **76,33**

>> Também de poderia usar a mediana, moda

Gén	Altura	Peso
M	1,76	70
M	1,7	72
M	1,93	96
M	1,82	90
M	1,68	65
M	1.93	95
F	1,53	45
F	1,63	60
M	1,7	65
M	1,66	76

Tratamento dos dados

Tarefas

Transformação


Tratamento dos dados

TRANSFORMAÇÃO

- Tipos de dados de um dataset podem ser variados
 - Strings
 - Enumerações
 - Valores reais
 - Valores inteiros
 - Valores booleanos
 -
- Os algoritmos de *Machine Learning* precisam de dados numéricos!!


Tratamento dos dados

TRANSFORMAÇÃO



Tratamento dos dados

TRANSFORMAÇÃO: regras básicas



Tratamento dos dados


TRANSFORMAÇÃO: dados numéricos

- **Normalização de valores**
 - Assegura que as escalas dos diferentes atributos numéricos são as mesmas
 - Valores passam a estar no intervalo $[0, 1]$ sem perderem a relação entre eles
- Algumas técnicas de normalização
 - Máximo
 - Min-max

Tratamento dos dados

TRANSFORMAÇÃO: dados numéricos

- **Standardização (padronização) de valores**
 - os valores são centrados em torno da média com um desvio padrão unitário.
 - a média do atributo torna-se zero e a distribuição resultante tem um desvio padrão unitário



Tratamento dos dados

TRANSFORMAÇÃO: dados numéricos

- **Normalização**

Técnica do valor máximo

$$X'_i = \frac{X_i}{\max(X)}$$

Gén	Altura	Peso
M	1,76	70
M	1,7	72
M	1,93	96
M	1,82	90
M	1,68	65
M	1,93	95
F	1,53	45
F	1,63	60
M	1,7	65
M	1,66	76

Gén	Altura	Peso
M	0,91	0,73
M	0,88	0,75
M	1,00	1,00
M	0,94	0,94
M	0,87	0,68
M	1,00	0,99
F	0,79	0,47
F	0,84	0,63
M	0,88	0,68
M	0,86	0,79

Tratamento dos dados

TRANSFORMAÇÃO: dados numéricos

- **Normalização**

Técnica Min-Max

$$X'_i = \frac{X_i - \min(X)}{\max(X) - \min(X)}$$

Gén	Altura	Peso
M	1,76	70
M	1,7	72
M	1,93	96
M	1,82	90
M	1,68	65
M	1,93	95
F	1,53	45
F	1,63	60
M	1,7	65
M	1,66	76

Gén	Altura	Peso
M	0,58	0,49
M	0,43	0,53
M	1,00	1,00
M	0,73	0,88
M	0,38	0,39
M	1,00	0,98
F	0,00	0,00
F	0,25	0,29
M	0,43	0,39
M	0,33	0,61

Tratamento dos dados

TRANSFORMAÇÃO: dados numéricos

- **Standardização (padronização) de valores**

$$X_i' = \frac{X_i - \mu}{\sigma}$$

μ – média

σ – desvio padrão

Tratamento dos dados

TRANSFORMAÇÃO: dados numéricos

- **Standardização**

$$X_i' = \frac{X_i - \mu}{\sigma}$$

$$\mu_{\text{altura}} = 1,73$$

$$\mu_{\text{peso}} = 73,4$$

$$\sigma_{\text{altura}} = 0,13$$

$$\sigma_{\text{peso}} = 16,33$$

Gén	Altura	Peso
M	1,76	70
M	1,7	72
M	1,93	96
M	1,82	90
M	1,68	65
M	1,93	95
F	1,53	45
F	1,63	60
M	1,7	65
M	1,66	76

Gén	Altura	Peso
M	0,20	-0,21
M	-0,27	-0,09
M	1,53	1,38
M	0,67	1,02
M	-0,42	-0,51
M	1,53	1,32
F	-1,59	-1,74
F	-0,81	-0,82
M	-0,27	-0,51
M	-0,58	0,16

Tratamento dos dados

TRANSFORMAÇÃO: dados numéricos

- **Normalizar ou Standardizar?**

- Depende do algoritmo de ML que se pretende usar
- Redes neuronais, regressão: Normalização
- Agrupamento, Máquinas de vetor de suporte, ...: Standardização

Normalização	Standardização
Altera a gama de valores para [0, 1]	Centra os dados em torno da média e dimensiona para um desvio padrão de 1
Útil quando a distribuição dos dados é desconhecida ou não gaussiana	Útil quando a distribuição dos dados é gaussiana ou desconhecida
Sensível a outliers	menos sensível a outliers
Mantém a forma dos dados iniciais	Altera a forma dos dados originais
Pode não preservar a relação entre os dados	Preserva a relação entre os dados
$X' = (X - \min) / (\max - \min)$	$X' = (X - \text{média}) / \text{desv. padrão}$

Tratamento dos dados

TRANSFORMAÇÃO: dados categóricos

- **Podem ser**

- **Categorias ou valores nominais:**

- Duas ou mais categorias sem ordem estabelecida entre elas
 - Booleanos/Binários
 - Cores: Vermelho, verde, azul, amarelo,...
 - Tipo de casa: moradia, apartamento, quinta rural, ...

- **Valores ordinais**

- Duas ou mais categorias com ordem estabelecida entre elas
 - Baixo, Médio, Alto
 - Pequeno, Médio, Grande, Extra-Grande
 - Básico, Secundário, Universidade,

Tratamento dos dados

TRANSFORMAÇÃO: dados categóricos

- **Transformar para valores numéricos**

- Ordinais:

- S $\rightarrow$ 1
- M $\rightarrow$ 2
- L $\rightarrow$ 3
- XL $\rightarrow$ 4

- Low $\rightarrow$ 1
- Medium $\rightarrow$ 2
- High $\rightarrow$ 3

Tratamento dos dados

TRANSFORMAÇÃO: dados categóricos

- **Transformar para valores numéricos**
 - Booleanos / Binários:
 - True → 1
 - False → 0
 - Female → 1
 - Male → 0
 - Positive → 1
 - Negativo → 0

Tratamento dos dados

TRANSFORMAÇÃO: dados categóricos

- Enumerações (exemplo, atributo cor):
 - **Transformar para valores numéricos**

- Codificar para valor inteiro

azul → 1

vermelho → 2

verde → 3

amarelo → 4

vegetais → 1

fruta → 2

carne → 3

peixe → 4

- *One hot encoding (usar array binário)*

azul	1	0	0	0
vermelho	0	1	0	0
verde	0	0	1	0
amarelo	0	0	0	1

vegetais	1	0	0	0
fruta	0	1	0	0
carne	0	0	1	0
peixe	0	0	0	1

Tratamento dos dados

Tarefas

Seleção

Tratamento dos dados

Seleção: escolha de atributos

- Analisar todos os atributos do dataset
 - Importância de cada atributo
 - Reduzir número de atributos
- Porquê?
 - Diminuir o ruído
 - Identificar atributos relevantes
 - Aumentar o desempenho dos algoritmos
 - Simplificar o modelo
 - Melhorar a visualização e interpretação dos dados

Tratamento dos dados

Seleção: escolha de atributos

- Como selecionar os melhores atributos?
 - O próprio algoritmo pode ter capacidade para escolher os melhores atributos: árvores de decisão, por exemplo
 - Usar um filtro: quais os atributos que permitem uma correlação mais forte com a variável target?
 - Independente do algoritmo
 - Estudo prévio:
 - fazer seleções entre diferentes grupos de atributos
 - Executar o algoritmo
 - Ver qual a seleção com melhor desempenho

Tratamento dos dados

Tarefas

Redução

Tratamento dos dados

Redução: diminuir o número de atributos

- Reduzir o número de atributos
 - A etapa anterior (seleção) permite ajudar nesta etapa
 - Um número elevado de atributos normalmente não traduz bons desempenhos do algoritmo
 - Atributos discriminantes, com variâncias elevadas, poucos outliers, serão sempre os melhores candidatos.

Tratamento dos dados

Visualização dos dados

Tratamento de dados

EXERCÍCIOS

Tratamento de dados

Exercício 1

Considere o seguinte dataset:

Taxa de juros	Preços
1,7	55000
1,7	56000
	62000
1,9	64000
2,3	70000
3,4	85000
3,6	87000
4,6	
4,7	95000
4,9	95000

- Usando o excel, matlab ou outra ferramenta, calcule a média, mediana, moda, desvio padrão
- Preencha os valores em falta usando uma das abordagens estudadas
- Normalize os valores dos atributos usando a **técnica min-max**
- Padronize os valores usando a **média e desvio padrão**

Tratamento de dados

Exercício 1 a)

Considere o seguinte dataset:

- a) Usando o excel, matlab ou outra ferramenta, calcule a média, mediana, moda, desvio padrão

	Taxa de juros	Preços
MODA	1,70	95000,00
MÉDIA	3,20	74333,33
MEDIANA	3,40	70000,00
DESV PAD	1,34	16263,46

Taxa de juros	Preços
1,7	55000
1,7	56000
	62000
1,9	64000
2,3	70000
3,4	85000
3,6	87000
4,6	
4,7	95000
4,9	95000

Tratamento de dados

Exercício 1 b)

b) Preencha os valores em falta usando uma das abordagens estudadas

Atribuir valores em falta

>> taxa de juro: usar a moda >> 1.7

>> preço: caso mais semelhante

Taxa de juros	Preços
1,7	55000
1,7	56000
1.7	62000
1,9	64000
2,3	70000
3,4	85000
3,6	87000
4,6	95000
4,7	95000
4,9	95000

caso mais semelhante



Tratamento de dados

Exercício 1 c)

Normalize os valores dos atributos usando a **técnica min-max**

$$X'_i = \frac{X_i - \min(X)}{\max(X) - \min(X)}$$

Taxa de juros	Preços
1,7	55000
1,7	56000
1.7	62000
1,9	64000
2,3	70000
3,4	85000
3,6	87000
4,6	95000
4,7	95000
4,9	95000



Taxa de juros	Preços
0,00	0,00
0,00	0,03
0,00	0,18
0,06	0,23
0,19	0,38
0,53	0,75
0,59	0,80
0,91	1,00
0,94	1,00
1,00	1,00

Max	4,9	95000
Min	1,7	55000

Tratamento de dados

Exercício 1 d)

Padronização dos valores dos atributos

$$X_i' = \frac{X_i - \mu}{\sigma}$$

Taxa de juros	Preços
1,7	55000
1,7	56000
1.7	62000
1,9	64000
2,3	70000
3,4	85000
3,6	87000
4,6	95000
4,7	95000
4,9	95000



Taxa de juros	Preços
-1,00	-1,28
-1,00	-1,22
-1,00	-0,86
-0,85	-0,74
-0,56	-0,38
0,26	0,52
0,41	0,64
1,15	1,12
1,23	1,12
1,37	1,12

Média	3,05	76400
Desvio Padrão	1,35	16667,99

Tratamento de dados

Exercício 2

Analise o seguinte dataset

Id	Idade	Nº Filhos	Distrito	Rendimento	Atribuição apoio?
1	20	1	Coimbra	Nenhum	Sim
2	22	1	Aveiro	Baixo	Sim
3	18	0	Porto	Médio	Não
4	30	2	Aveiro	Alto	?
5	32	3	Lisboa	Nenhum	?
6	27	2	Lisboa	Médio	Não
7	35	3	Coimbra	Alto	Não
8	29	3	Lisboa	Baixo	Sim
9	40	4	Lisboa	Baixo	Sim
10	32	3	Aveiro	Nenhum	Sim

Tratamento de dados

Exercício 2

- Como fazer a transformação dos dados não numéricos?
- Use um sistema de CBR para atribuir os valores em falta
- Normalize os dados numéricos
- Crie um gráfico de dispersão para ver a relação entre os atributos idade e numero de filhos.
- Visualize os dados usando histogramas

Tratamento de dados

Exercício 2

- Como fazer a transformação dos dados não numéricos?

Rendimento

Nenhum - 0

Baixo - 1

Médio - 2

Alto - 3

Atribuição Apoio

Sim - 1

Não - 0

Distrito

(coordenadas...)

Vamos considerar atributo não discriminante e eliminar este atributo

Id	Idade	Nº Filhos	Rendimento	Atribuição apoio?
1	20	1	0	1
2	22	1	1	1
3	18	0	2	0
4	30	2	3	?
5	32	3	0	?
6	27	2	2	0
7	35	3	3	0
8	29	3	1	1
9	40	4	1	1
10	32	3	0	1

Tratamento de dados

Exercício 2

- Use um sistema de CBR para atribuir os valores em falta

Case Library:

Id	Idade	Nº Filhos	Rendimento	Atribuição apoio?
1	20	1	0	Sim
2	22	1	1	Sim
3	18	0	2	Não
6	27	2	2	Não
7	35	3	3	Não
8	29	3	1	Sim
9	40	4	1	Sim
10	32	3	0	Sim

Querys: linhas com valores em falta

Id	Idade	Nº Filhos	Rendimento	Atribuição apoio?
4	30	2	3	?
5	32	3	0	?

Tratamento de dados

Exercício 2

- Use um sistema de CBR para atribuir os valores em falta

Calcular Distâncias Locais lineares normalizadas::

Case Library

Id	Idade	Nº Filhos	Rendimento
1	20	1	0
2	22	1	1
3	18	0	2
6	27	2	2
7	35	3	3
8	29	3	1
9	40	4	1
10	32	3	0

Querys:

Id	Idade	Nº Filhos	Rendimento	Atribuição apoio?
4	30	2	3	
5	32	3	0	

Query com ID 4

DL Idade	DL Filhos	DL Rendimento
0,25	0,25	1,00
0,20	0,25	0,67
0,30	0,5	0,33
0,08	0	0,33
0,13	0,25	0,00
0,03	0,25	0,67
0,25	0,5	0,67
0,05	0,25	1,00

Query com ID 5

DL Idade	DL Filhos	DL Rendimento
0,30	0,5	0,00
0,25	0,5	0,33
0,35	0,75	0,67
0,13	0,25	0,67
0,08	0	1,00
0,08	0	0,33
0,20	0,25	0,33
0,00	0	0,00

Tratamento de dados

Exercício 2

- Use um sistema de CBR para atribuir os valores em falta

Calcular Similaridade Global

Pesos	1	2	3			
Id	Idade	Nº Filhos	Rendimento	Atribuição apoio?	SIM GLOBAL sim caso 4	SIM GLOBAL sim caso 5
1	20	1	0	Sim	37,50%	78,33%
2	22	1	1	Sim	55,00%	62,50%
3	18	0	2	Não	61,67%	35,83%
6	27	2	2	Não	82,08%	56,25%
7	35	3	3	Não	89,58%	48,75%
8	29	3	1	Sim	57,92%	82,08%
9	40	4	1	Sim	45,83%	71,67%
10	32	3	0	Sim	40,83%	100,00%

redundante

Querys:

Id	Idade	Nº Filhos	Rendimento	Atribuição apoio?
4	30	2	3	Não
5	32	3	0	Sim

Tratamento de dados

Exercício 2

- Normalize os dados numéricos

Id	Idade	Nº Filhos	Rendimento	Atribuição apoio?
1	20	1	0	1
2	22	1	1	1
3	18	0	2	0
4	30	2	3	0
5	32	3	0	1
6	27	2	2	0
7	35	3	3	0
8	29	3	1	1
9	40	4	1	1
Média	28,11	2,11	1,44	0,56
Mediana	29,00	2,00	1,00	1,00
Desv. Padrao	7,20	1,27	1,13	0,53
Maximo	40,00	4,00	3,00	1,00
Minimo	18,00	0,00	0,00	0,00


Id	Idade	Nº Filhos	Rendimento	Atribuição apoio?
1	0,09	0,25	0,00	1
2	0,18	0,25	0,33	1
3	0,00	0,00	0,67	0
4	0,55	0,50	1,00	0
5	0,64	0,75	0,00	1
6	0,41	0,50	0,67	0
7	0,77	0,75	1,00	0
8	0,50	0,75	0,33	1
9	1,00	1,00	0,33	1

$$X'_i = \frac{X_i - \min(X)}{\max(X) - \min(X)}$$

Tratamento de dados

Exercício 2

- Crie um gráfico de dispersão para ver a relação entre os atributos idade e numero de filhos.




Id	Idade	Nº Filhos
1	0,091	0,250
2	0,182	0,250
3	0,000	0,000
4	0,545	0,500
5	0,636	0,750
6	0,409	0,500
7	0,773	0,750
8	0,500	0,750
9	1,000	1,000
10	0,636	0,750

Tratamento de dados

Exercício 2

- Visualize os dados usando histogramas

Idade



Rendimento

