

CONHECIMENTO E RACIOCÍNIO

10 – Árvores de Decisão



Árvores de decisão

- O que são árvores de decisão
- Terminologia e conceitos
- Critérios de divisão numa árvore de decisão
- Algoritmo ID3

Árvores de decisão

- Modelo de aprendizagem supervisionada
- Utilizado para classificação ou para regressão.
 - Pode ser usado para prever categorias discretas (sim ou não, por exemplo)
 - Pode ser usado para prever valores numéricos (o valor do lucro em euros, por exemplo).
- Objetivo:
 - Criar um modelo que prevê o valor de uma variável target, aprendendo regras de decisão a partir dos dados disponíveis

Árvores de decisão

- Decisão: vou correr hoje?
 - Atributos a considerar
 - Está a chover?
 - Tenho tempo?
 - Dormi bem?
- Através de um dataset com vários exemplos, a árvore é criada e transforma-se um sistema de regras que permite tomar a decisão
- Cada pergunta = nó
- Cada resposta = ramo
- Decisão final = folha

Árvores de decisão

- Decisão: **“Emprestariam 10.000€ a uma pessoa?”**
- Atributos:
 - Rendimento: alto / baixo
 - Histórico de crédito: bom / mau
 - Emprego: estável / instável

Se histórico = mau → recusar

Se histórico = bom:

Se rendimento alto → aprovar


Senão → depende do emprego

Árvores de decisão

- mas qual é a melhor pergunta a fazer primeiro?
 - Primeiro perguntar “rendimento”?
 - Ou “histórico de crédito”?
 - Ou “emprego”?

Uma árvore de decisão é um modelo que aprende automaticamente as melhores perguntas a fazer.

Árvores de decisão



Se histórico = mau → recusar

Uma regra = um caminho da raiz até à folha

Árvores de decisão

terminologia e conceitos


- **Nó raiz:**
 - Contem todos os exemplos que se pretendem classificar (dataset)
- **Critério de Divisão (splitting):**
 - Métrica que escolher como dividir os exemplos em cada nível da árvore
- **Nós decisão:**
 - Os nós da primeira divisão
- **Nós folha (terminais):**
 - Os nós da última divisão (decisão/resposta)
- **Ramo ou sub-árvore**
- **Profundidade da árvore:**
 - tamanho do caminho desde a raiz até às folhas

Uma árvore de decisão é um conjunto de perguntas organizadas de forma hierárquica que levam a uma decisão.

Árvores de decisão

um exemplo simples: classificação binária

Altura	Desempenho académico	Turma	Pratica desporto?
160	Positivo	B	N
163	Positivo	A	S
174	Positivo	A	S
165	Positivo	B	N
170	Positivo	B	S
173	Negativo	B	N
180	Negativo	B	N
166	Negativo	B	N
163	Positivo	A	S
158	Positivo	A	N
175	Positivo	B	S
169	Positivo	A	S
171	Positivo	A	S
164	Negativo	B	N
172	Negativo	A	S
170	Positivo	A	S
155	Positivo	A	N
167	Positivo	B	N
164	Positivo	B	N
167	Negativo	A	S



Nº de alunos: 20

Entradas:

Atributos

Altura (<165 ; ≥ 165)

Desempenho Académico (Positivo; Negativo)

Turma (A; B)

Saída:

Duas Classes


S: Pratica desporto

N: Não pratica desporto

Árvores de decisão

terminologia e conceitos

- Nó raiz
- Divisão (splitting)
- Nós decisão
- Nós folha (terminais)
- Ramo ou sub-arvore
- Nós Pais/filhos
- Profundidade da árvore 2




Árvores de decisão

um exemplo simples


- Dividir pela altura
- Dividir pelo desempenho
- Dividir pela turma

Nº de alunos: 20
Praticam desporto: 10
Percentagem: 50%




<165

>=165



Nº de alunos: 8
Praticam desporto: 2
Percentagem: 25%



Nº de alunos: 12
Praticam desporto: 8
Percentagem: 66,67%


Altura	Desempenho académico	Turma	Pratica desporto?
160	Positivo	B	N
163	Positivo	A	S
174	Positivo	A	S
165	Positivo	B	N
170	Positivo	B	S
173	Negativo	B	N
180	Negativo	B	N
166	Negativo	B	N
163	Positivo	A	S
158	Positivo	A	N
175	Positivo	B	S
169	Positivo	A	S
171	Positivo	A	S
164	Negativo	B	N
172	Negativo	A	S
170	Positivo	A	S
155	Positivo	A	N
167	Positivo	B	N
164	Positivo	B	N
167	Negativo	A	S

Árvores de decisão

um exemplo simples

- Dividir pela altura
- **Dividir pelo desempenho**
- Dividir pela turma


Nº de alunos: 20
Praticam desporto: 10
Percentagem: 50%




Positivo

Negativo

Nº de alunos: 14
Praticam desporto: 8
Percentagem: 57,14%



Nº de alunos: 6
Praticam desporto: 2
Percentagem: 33,33%




Altura	Desempenho académico	Turma	Pratica desporto?
160	Positivo	B	N
163	Positivo	A	S
174	Positivo	A	S
165	Positivo	B	N
170	Positivo	B	S
173	Negativo	B	N
180	Negativo	B	N
166	Negativo	B	N
163	Positivo	A	S
158	Positivo	A	N
175	Positivo	B	S
169	Positivo	A	S
171	Positivo	A	S
164	Negativo	B	N
172	Negativo	A	S
170	Positivo	A	S
155	Positivo	A	N
167	Positivo	B	N
164	Positivo	B	N
167	Negativo	A	S

Árvores de decisão

um exemplo simples

- Dividir pela altura
- Dividir pelo desempenho
- **Dividir pela turma**


Nº de alunos: 20
Praticam desporto: 10
Percentagem: 50%




A

B

Nº de alunos: 10
Praticam desporto: 8
Percentagem: 80%



Nº de alunos: 10
Praticam desporto: 2
Percentagem: 20%




Altura	Desempenho académico	Turma	Pratica desporto?
160	Positivo	B	N
163	Positivo	A	S
174	Positivo	A	S
165	Positivo	B	N
170	Positivo	B	S
173	Negativo	B	N
180	Negativo	B	N
166	Negativo	B	N
163	Positivo	A	S
158	Positivo	A	N
175	Positivo	B	S
169	Positivo	A	S
171	Positivo	A	S
164	Negativo	B	N
172	Negativo	A	S
170	Positivo	A	S
155	Positivo	A	N
167	Positivo	B	N
164	Positivo	B	N
167	Negativo	A	S


Árvores de decisão

um exemplo simples


- Que atributo escolher para iniciar o algoritmo?



Dividir pela altura



Dividir pelo desempenho




Dividir pela turma

Árvores de decisão

um exemplo simples


- Dividir pela altura
- Dividir pelo desempenho
- Dividir pela turma
- **Praticaram desporto**
o ano passado?

Nº de alunos: 20
Praticam desporto: 10
Percentagem: 50%




Sim

Não



Nº de alunos: 10
Praticam desporto: 10
Percentagem: 100%




Nº de alunos: 10
Praticam desporto: 0
Percentagem: 0%

Altura	Desempenho académico	Turma	Pratica desporto?
160	Positivo	B	N
163	Positivo	A	S
174	Positivo	A	S
165	Positivo	B	N
170	Positivo	B	S
173	Negativo	B	N
180	Negativo	B	N
166	Negativo	B	N
163	Positivo	A	S
158	Positivo	A	N
175	Positivo	B	S
169	Positivo	A	S
171	Positivo	A	S
164	Negativo	B	N
172	Negativo	A	S
170	Positivo	A	S
155	Positivo	A	N
167	Positivo	B	N
164	Positivo	B	N
167	Negativo	A	S

Árvores de decisão

um exemplo simples

- Para este dataset esta será uma AD possível
- Como escolher os atributos em cada iteração?



Árvores de decisão



critérios de divisão (splitting)

- Valores Discretos
 - Impureza de Gini
 - Entropia / Ganho de informação
- Valores contínuos
 - Variância

Árvores de decisão

critérios de divisão (splitting): impureza de Gini

- Gini:
 - Esta métrica varia entre 0 e 1
 - Mede a probabilidade de aleatoriamente serem escolhidos exemplos da mesma classe



- Para decidir o atributo a escolher para a divisão usa-se:

$$\text{Impureza de Gini} = 1 - \text{Gini}$$

Árvores de decisão

critérios de divisão (splitting): impureza de Gini

Propriedades

- Escolher o atributo com menor impureza
 - Esse atributo garante maior homogeneidade nos dados
- Apenas para problemas de classificação categóricos (discretos)

Árvores de decisão

critérios de divisão (splitting): impureza de Gini

- Passos para usar a impureza de Gini para decidir uma divisão na árvore:

- Para todos os atributos do dataset calcular Impureza de Gini:

$$IG_{Atr} = 1 - Gini_{Atr}$$

- O valor de Gini de um atributo: soma do quadrado das probabilidades de cada classe/categoria nesse atributo:

$$Gini_{Atr} = p_1^2 + p_2^2 + \dots p_n^2$$

- Para decidir a divisão:
 - calcular a **impureza de Gini pesada** de cada atributo K

$$IG_k = \sum_n (Gini_n * peso_n), n = \text{número de classes}$$


← **ESCOLHER ATRIBUTO K COM MENOR VALOR**

peso = número de exemplos de um sub-nodo / número total de exemplos do pai²⁰

Árvores de decisão

um exemplo simples

- IG - Altura
- IG - Desempenho
- IG - Turma



Escolher o atributo com menos IG

Altura	Desempenho académico	Turma	Pratica desporto?
160	Positivo	B	N
163	Positivo	A	S
174	Positivo	A	S
165	Positivo	B	N
170	Positivo	B	S
173	Negativo	B	N
180	Negativo	B	N
166	Negativo	B	N
163	Positivo	A	S
158	Positivo	A	N
175	Positivo	B	S
169	Positivo	A	S
171	Positivo	A	S
164	Negativo	B	N
172	Negativo	A	S
170	Positivo	A	S
155	Positivo	A	N
167	Positivo	B	N
164	Positivo	B	N
167	Negativo	A	S

Árvores de decisão

critérios de divisão (splitting): impureza de Gini

Impureza de Gini para “Altura”

- Calcular impureza de Gini para nó “<165”

$$IG_{<165} = 1 - [0.25^2 + 0.75^2] = 0.375$$

$$\text{Peso} = 8/20$$


- Calcular impureza de Gini para nó “>=165”

$$IG_{>=165} = 1 - [0.67^2 + 0.33^2] = 0.44$$

$$\text{Peso} = 12/20$$

IG pesada para “Altura”

$$8/20 * 0.375 + 12/20 * 0.44 = 0.415$$



Árvores de decisão

critérios de divisão (splitting): impureza de Gini

Impureza de Gini para “Desempenho”

- Calcular impureza de Gini para nó “Positivo”

$$IG_{\text{pos}} = 1 - [0.57^2 + 0.43^2] = 0.49$$

$$\text{Peso} = 14/20$$


- Calcular impureza de Gini para nó “Negativo”

$$IG_{\text{neg}} = 1 - [0.33^2 + 0.67^2] = 0.44$$

$$\text{Peso} = 6/20$$

IG pesada para “Desempenho”

$$14/20 * 0.49 + 6/20 * 0.44 = 0.475$$



Árvores de decisão

critérios de divisão (splitting): impureza de Gini

Impureza de Gini para “Turma”

- Calcular impureza de Gini para nó “A”

$$IG_A = 1 - [0.8^2 + 0.2^2] = 0.32$$

$$\text{Peso} = 10/20$$


- Calcular impureza de Gini para nó “B”

$$IG_B = 1 - [0.2^2 + 0.8^2] = 0.32$$

$$\text{Peso} = 10/20$$

IG pesada para “Turma”

$$10/20 * 0.32 + 10/20 * 0.32 = 0.32$$



Árvores de decisão

critérios de divisão (splitting): impureza de Gini


- Impureza de Gini pesada para os três atributos

Atributo	Impureza de Gini pesada
Altura	0.415
Desempenho	0.475
Turma	0.320

- Escolher o atributo com menor valor: **Turma**

Árvores de decisão

critérios de divisão (splitting): impureza de Gini




Repetir os mesmos cálculos para os atributos **Altura** e **Desempenho**, considerando os pais de cada sub-árvore

Árvores de decisão

critérios de divisão (splitting): impureza de Gini

Turma A



IG da altura

<165:

2 praticam; 2 não praticam

Peso: 4/10

$$IG = 1 - (0.5^2 + 0.5^2) = 0.5$$

≥ 165 :

6 praticam; 0 não praticam

Peso: 6/10

$$IG = 1 - (1^2) = 0$$

$$IG \text{ total} = 0.5 * 4/10 = 0.2$$



DIVIDIR PELA ALTURA

IG do desempenho

Positivo:

6 praticam; 2 não praticam

Peso: 8/10

$$IG = 1 - (0.36^2 + 0.04^2) = 0.6$$

Negativo:


2 praticam; 0 não praticam

Peso: 2/10

$$IG = 1 - (0.04^2) = 0.96$$

$$IG \text{ total} = 0.6 * 8/10 + 0.96 * 2/10 = 0.67$$

Turma B



IG da altura

<165:

0 praticam; 3 não praticam

Peso: 3/10

$$IG = 1 - (1^2) = 0$$

≥ 165 :

2 praticam; 5 não praticam

Peso: 7/10

$$IG = 1 - (0.28^2 + 0.71^2) = 0.42$$

$$IG \text{ total} = 0.42 * 7/10 = 0.29$$



DIVIDIR PELA ALTURA

IG do desempenho

Positivo:

2 praticam; 4 não praticam

Peso: 6/10

$$\bullet IG = 1 - (0.2^2 + 0.4^2) = 0.8$$

Negativo:

0 praticam; 4 não praticam


Peso: 4/10

$$IG = 1 - (0.4^2) = 0.84$$

$$IG \text{ total} = 0.8 * 6/10 + 0.84 * 4/10 = 0.81$$


Árvores de decisão

critérios de divisão (splitting): impureza de Gini



Árvores de decisão




critérios de divisão (splitting): impureza de Gini



Árvores de decisão

critérios de divisão (splitting): ganho de informação

- Ganho de informação
 - Esta métrica varia entre 0 e 1
 - Escolher o atributo com maior ganho
 - Esse atributo garante maior homogeneidade nos dados



Maior ganho de informação

Árvores de decisão

critérios de divisão (splitting): ganho de informação

- Propriedades
 - Entropia = $1 - \text{Ganho}$
 - Escolher o atributo com menor entropia, i.e., maior ganho
 - Apenas para problemas de classificação categóricos (discretos)

Árvores de decisão

critérios de divisão (splitting): ganho de informação

- Passos para usar o método do ganho de informação:
 - Calcular a entropia do dataset: $E(D)$
 - Calcular o **entropia total pesada** para cada atributo
 - Calcular o ganho de informação para cada atributo
 - $G_{\text{Informação_Atributo}} = E(D) - E(\text{Atributo})$
- Escolher o atributo com a maior ganho


Árvores de decisão

critérios de divisão (splitting): ganho de informação

Ganho de informação do dataset = 1 - Entropia

A Entropia de um dataset com n classes:

$$\text{Entropia}(D) = -p_1 * \log_2(p_1) - p_2 * \log_2(p_2) - \dots - p_n * \log_2(p_n)$$




% praticar desporto = 0.5

% não praticar desporto = 0.5

$$\text{Entropia} = -0.5 * \log_2(0.5) - 0.5 * \log_2(0.5) = 1$$

$$\text{Ganho de informação} = 1 - 1 = 0$$



% praticar desporto = 0

% não praticar desporto = 1

$$\text{Entropia} = 0$$

$$\text{Ganho de informação} = 1$$

Árvores de decisão

critérios de divisão (splitting): ganho de informação

Calcular a entropia para cada atributo:
quantos subconjuntos tem um atributo?
qual o peso de cada subconjunto?

A Entropia de subconjunto S de um atributo K :

$$\text{Entropia}_k(S) = -p_1 * \log_2(p_1) - p_2 * \log_2(p_2) - \dots - p_n * \log_2(p_n)$$

A **Entropia total pesada** de um atributo K :

soma pesada de todas as entropias dos diferentes subconjuntos

$$\text{Entropia}_{\text{total}}(K) = \text{peso}_1 * \text{Entropia}_k(S_1) + \text{peso}_2 * \text{Entropia}_k(S_2) + \dots + \text{peso}_n * \text{Entropia}_k(S_n)$$

$$\text{O Ganho de um atributo } K = E(D) - E(K)$$

Árvores de decisão

critérios de divisão (splitting): ganho de informação

Nº de alunos: 20
Praticam: 10
Não Praticam: 10
Prob. praticar: 0.5
Prob. não praticar: 0.5

Entropia para “Altura”

- Calcular a entropia do dataset

$$\text{Entropia}(D) = -0.5 * \log_2(0.5) - 0.5 * \log_2(0.5) = 1$$

- Calcular a entropia do nó “<165”

$$\text{Peso} = 8/20$$

$$\text{Entropia}(<165) = -0.25 * \log_2(0.25) - 0.75 * \log_2(0.75) = 0.81$$

- Calcular a entropia do nó “>=165”


$$\text{Peso} = 12/20$$

$$\text{Entropia}(>=165) = -0.67 * \log_2(0.67) - 0.33 * \log_2(0.33) = 0.91$$

Entropia Total pesada para “Altura”

$$8/20 * 0.81 + 12/20 * 0.91 = 0.87$$

$$\text{Ganho} = 1 - 0.87 = 0.13$$



Árvores de decisão

critérios de divisão (splitting): ganho de informação

Nº de alunos: 20
Praticam desporto: 10
Percentagem: 50%

Entropia para “Desempenho”

- Calcular a entropia do nó pai

$$\text{Entropia}(D) = -0.5 * \log_2(0.5) - 0.5 * \log_2(0.5) = 1$$

- Calcular a entropia do nó “Positivo”

$$\text{Peso} = 14/20$$

$$\text{Entropia}(\text{Pos}) = -0.57 * \log_2(0.57) - 0.43 * \log_2(0.43) = 0.98$$

- Calcular a entropia do nó “Negativo”


$$\text{Peso} = 6/20$$

$$\text{Entropia}(\text{Neg}) = -0.33 * \log_2(0.33) - 0.67 * \log_2(0.67) = 0.91$$

Entropia Total pesada para “Desempenho”

$$14/20 * 0.98 + 6/20 * 0.91 = 0.959$$

$$\text{Ganho} = 1 - 0.959 = 0.041$$



Árvores de decisão

critérios de divisão (splitting): ganho de informação

Entropia para “Turma”

- Calcular a entropia do nó pai

$$\text{Entropia}(D) = -0.5 * \log_2(0.5) - 0.5 * \log_2(0.5) = 1$$

- Calcular a entropia do nó “A”

$$\text{Peso} = 10/20$$

$$\text{Entropia}(A) = -0.8 * \log_2(0.8) - 0.2 * \log_2(0.2) = 0.722$$

- Calcular a entropia do nó “B”


$$\text{Peso} = 10/20$$

$$\text{Entropia}(B) = -0.2 * \log_2(0.2) - 0.8 * \log_2(0.8) = 0.722$$

Entropia Total pesada para “Turma”

$$10/20 * 0.722 + 10/20 * 0.722 = 0.722$$

$$\text{Ganho} = 1 - 0.722 = 0.278$$



Árvores de decisão

critérios de divisão (splitting): ganho de informação

- Ganho de informação para os três atributos

Atributo	Entropia	Ganho de informação
Altura	0.870	0.130
Desempenho	0.959	0.041
Turma	0.722	0.278

- Escolher o atributo com maior ganho: **Turma**

Árvores de decisão

critérios de divisão (splitting): reduzir a variância

- Para datasets com **valores contínuos**
 - Usar a fórmula da variância


$$\text{Variância} = \sum[k * (X - \mu)^2] / n$$

X: valores da amostra

μ : média

n: número de exemplos

k: nº de exemplos de cada valor



μ : 5.83

n: 6

$$\text{Variância} = [(1 * (2 - 5.83)^2) + (1 * (4 - 5.83)^2) + (1 * (6 - 5.83)^2) + (2 * (7 - 5.83)^2) + (1 * (9 - 5.83)^2)] / 6 = 5.14$$

Árvores de decisão

critérios de divisão (splitting): variância

- Propriedades
 - Escolher o atributo/variável com menor variância
 - Usa-se para problemas com valores contínuos


Árvores de decisão

critérios de divisão (splitting): variância

- Passos para usar o método da variância:
 - Calcular a variância de cada nó filho
$$\text{Variância} = \sum[k * (X - \mu)^2]/n$$
 - Calcular a **variância total pesada** de cada atributo
 - Escolher o atributo com a menor variância pesada


Árvores de decisão

critérios de divisão (splitting): variância



Pratica desporto: 1

Não pratica desporto: 0



$$\text{Variância} = \sum [k * (X - \mu)^2] / n$$

Árvores de decisão

critérios de divisão (splitting): variância

Variância para “Altura”

- Calcular a variância do nó “<165”

$$\text{Peso} = 8/20$$

$$\text{Média} = (2 * 1 + 6 * 0) / 8 = 0.25$$

$$n = 8$$

$$\text{Var}_{<165} = [6 * (0 - 0.25)^2 + 2 * (1 - 0.25)^2] / 8 = 0.1875$$

- Calcular a entropia do nó “>=165”

$$\text{Peso} = 12/20$$


$$\text{Média} = (8 * 1 + 4 * 0) / 12 = 0.67$$

$$n = 12$$

$$\text{Var}_{>=165} = [8 * (1 - 0.67)^2 + 4 * (0 - 0.67)^2] / 12 = 0.22$$

Variância Total pesada para “Altura”

$$8/20 * 0.1875 + 12/20 * 0.222 = 0.207$$



Árvores de decisão

critérios de divisão (splitting): variância

Variância para “Desempenho”

- Calcular a variância do nó “Positivo”

$$\text{Peso} = 14/20$$

$$\text{Média} = (8*1 + 6*0)/14 = 0.57$$

$$\text{Var} = 0.245$$

- Calcular a variância do nó “Negativo”


$$\text{Peso} = 6/20$$

$$\text{Média} = (2*1 + 4*0)/6 = 0.33$$

$$\text{Var} = 0.222$$

Variância Total pesada para “Desempenho”

$$14/20 * 0.245 + 6/20 * 0.222 = 0.238$$



Árvores de decisão

critérios de divisão (splitting): variância

Variância para “Turma”

- Calcular a variância do nó “A”

$$\text{Peso} = 10/20$$

$$\text{Média} = (8 \cdot 1 + 2 \cdot 0)/10 = 0.8$$

$$\text{Var} = 0.16$$

- Calcular a entropia do nó “B”


$$\text{Peso} = 10/20$$

$$\text{Média} = (2 \cdot 1 + 8 \cdot 0)/10 = 0.2$$

$$\text{Var} = 0.16$$

Variância Total pesada para “Turma”

$$10/20 \cdot 0.16 + 10/20 \cdot 0.16 = 0.16$$



Árvores de decisão

critérios de divisão (splitting): variância

- Variância para os três atributos

Atributo	Variância
Altura	0.220
Desempenho	0.186
Turma	0.180

- Escolher o atributo com menor variância: **Turma**

Árvores de decisão

Exemplo

- Dataset total:
 - 6 Yes
 - 4 No
- Atributo A:
 - Grupo 1: (4 Yes, 0 No)
 - Grupo 2: (2 Yes, 4 No)
- Atributo B:
 - Grupo 1: (3 Yes, 2 No)
 - Grupo 2: (3 Yes, 2 No)
- Qual o melhor atributo?
 - Impureza de Gini
 - Ganho de informação

A	B	Target
Grupo1	Grupo1	Yes
Grupo1	Grupo1	Yes
Grupo1	Grupo1	Yes
Grupo1	Grupo2	Yes
Grupo2	Grupo2	Yes
Grupo2	Grupo2	Yes
Grupo2	Grupo1	No
Grupo2	Grupo1	No
Grupo2	Grupo2	No
Grupo2	Grupo2	No

Árvores de decisão

Exemplo – Impureza de Gini

- Dataset total: 6 Yes (0.6) // 4 No (0.4)
- Atributo A
 - G1 – 4 elementos – peso = 4/10
 - 4 Yes (1) // 0 No (0)
 - G2 – 6 elementos – peso = 6/10
 - 2 Yes (0.33) // 4 No (0.67)
- $\text{ImpGini}(G1) = 1 - (1^2 + 0^2) = 0$
- $\text{ImpGini}(G2) = 1 - (0.33^2 + 0.67^2) = 0.44$
- $\text{ImpGini}(A) = 4/10 * 0 + 6/10 * 0.44 = 0.26$

Árvores de decisão

Exemplo – Impureza de Gini

- Dataset total: 6 Yes (0.6) // 4 No (0.4)
- Atributo B
 - G1 – 5 elementos – peso = 5/10
 - 3 Yes (0.6) // 2 No (0.4)
 - G2 – 5 elementos – peso = 5/10
 - 2 3 Yes (0.6) // 2 No (0.4)
- $\text{ImpGini}(G1) = 1 - (0.6^2 + 0.4^2) = 0.48$
- $\text{ImpGini}(G2) = 1 - (0.6^2 + 0.4^2) = 0.48$
- $\text{ImpGini}(B) = 4/10 * 0.48 + 6/10 * 0.48 = 0.48$

Árvores de decisão

Exemplo – Impureza de Gini

- $\text{ImpGini}(A) = 4/10 * 0 + 6/10 * 0.44 = 0.26$
- $\text{ImpGini}(B) = 4/10 * 0.48 + 6/10 * 0.48 = 0.48$
- Escolhe-se o atributo com menor Impureza:
 - Atributo A

Árvores de decisão

Exemplo – Ganho de Informação

- Dataset total: 6 Yes (0.6) // 4 No (0.4)
- Entropia do Dataset: $E(D) = -0.6 \cdot \log_2(0.6) - 0.4 \cdot \log_2(0.4) = 0.97$
- **Atributo A**
 - G1 – 4 elementos – peso = 4/10
 - 4 Yes (1) // 0 No (0)
 - G2 – 6 elementos – peso = 6/10
 - 2 Yes (0.33) // 4 No (0.67)
- $E(G1) = 0$
- $E(G2) = -0.33 \cdot \log_2(0.33) - 0.67 \cdot \log_2(0.67) = 0.91$
- $E(A) = 4/10 \cdot 0 + 6/10 \cdot 0.91 = 0.55$
- $G(A) = E(D) - E(A) = 0.97 - 0.55 = 0.42$

Árvores de decisão

Exemplo – Ganho de Informação

- Dataset total: 6 Yes (0.6) // 4 No (0.4)
- Entropia do Dataset: $E(D) = -0.6 \cdot \log_2(0.6) - 0.4 \cdot \log_2(0.4) = 0.97$
- **Atributo B**
 - G1 – 5 elementos – peso = 5/10
 - 3 Yes (0.6) // 2 No (0.4)
 - G2 – 5 elementos – peso = 5/10
 - 3 Yes (0.6) // 2 No (0.4)

$$E(G1) = -0.6 \cdot \log_2(0.6) - 0.4 \cdot \log_2(0.4) = 0.97$$

$$E(G2) = -0.6 \cdot \log_2(0.6) - 0.4 \cdot \log_2(0.4) = 0.97$$

$$E(B) = 5/10 \cdot 0.07 + 5/10 \cdot 0.97 = 0.97$$

- $G(B) = E(D) - E(B) = 0.97 - 0.97 = 0$

Árvores de decisão

Exemplo – Ganho de Informação

- $G(A) = E(D) - E(A) = 0.97 - 0.55 = 0.42$
- $G(B) = E(D) - E(B) = 0.97 - 0.97 = 0$
- Escolhe-se o atributo com maior ganho:
 - Atributo A

Árvores de decisão

ID3

- A árvore de decisão com maior sucesso é o ID3
 - ID3 - *Iterative Dichotomizer 3*
 - Este algoritmo foi proposto por Ross Quinlan (1986)
 - Usa o **ganho de informação** como medida para decidir a divisão da árvore

Árvores de decisão

ID3 - algoritmo

1. Começar com todos os exemplos
2. Escolher o atributo que **melhor divide os exemplos**, ou seja agrupar exemplos da mesma classe ou exemplos semelhantes;
3. Para o atributo escolhido, criar um nó filho para cada valor possível do atributo
4. Transportar os exemplos para cada filho tendo em conta o valor do filho;
5. Repetir o procedimento para cada filho não "puro". Um filho é puro quando cada atributo X tem o mesmo valor em todos os exemplos.

Usa como medida de decisão o Ganho de Informação

Árvores de decisão

ID3 - algoritmo

- Calcular a entropia do Dataset: **$E(D)$**
- Para cada atributo A
 - Calcular **$G(D, A) = E(D) - E(A)$**
 - Para calcular $E(A)$ calcular a entropia total de todos os subconjuntos S

$$E(A) = \sum_S peso_s * E(S)$$

- Dividir o conjunto de dados usando o maior ganho **G**
- A partir desse nó, fazer divisões recursivas usando o mesmo processo

Árvores de decisão

ID3 - algoritmo

- Constrói a árvore mais curta
- Utilização intuitiva
- Só testa os atributos necessários até todos os dados estarem classificados
- Não garante a solução ótima
- Pode convergir para ótimos locais
- Usado para datasets categóricos

Árvores de decisão

ID3 – exemplo 1

- Dataset:

	Vento	Humidade	Casaco
1	Forte	Alta	Sim
2	Forte	Média	Sim
3	Fraco	Baixa	Não
4	Fraco	Média	Não
5	Fraco	Alta	Sim

Dataset

- Target: Casaco
 - Tem 5 exemplos
 - 3 SIM
 - 2 NÃO
- Tem 2 atributos
 - Vento
 - Tem 2 subconjuntos
 - Forte/Fraco
 - Humidade
 - Tem 3 subconjuntos
 - Baixa/Média/Alta

Árvores de decisão

ID3 – exemplo 1


	Vento	Humidade	Casaco
1	Forte	Alta	Sim
2	Forte	Média	Sim
3	Fraco	Baixa	Não
4	Fraco	Média	Não
5	Fraco	Alta	Sim

Passo 1 - Entropia do Dataset (D)

- $P_{sim} = 3/5 = 0.6$
- $P_{não} = 2/5 = 0.4$
- $E(D) = -0.6 * \log_2(0.6) - 0.4 * \log_2(0.4) = 0.971$

Passo 2 – Para o atributo Vento (V)

calcular ganho de informação para cada subconjunto



$$\text{Peso}_{\text{fraco}} = 3/5 = 0.6$$

$$\text{Peso}_{\text{forte}} = 2/5 = 0.4$$

$$E(\text{Fraco}) = -0.33 * \log_2(0.33) - 0.67 * \log_2(0.67) = 0.915$$


$$E(\text{Forte}) = -1 * \log_2(1) - 0 * \log_2(0) = 0$$

$$\text{Entropia} = -p_1 * \log_2(p_1) - p_2 * \log_2(p_2) - \dots - p_n * \log_2(p_n)$$

$$\text{Ganho} = 1 - \text{Entropia}$$

Passo 2 – Para o atributo Humidade (H)

calcular ganho de informação para cada subconjunto



$$\text{Peso}_B = 1/5 = 0.2$$

$$\text{Peso}_M = 2/5 = 0.4$$

$$\text{Peso}_A = 2/5 = 0.4$$

$$E(B) = -0 * \log_2(0) - 1 * \log_2(1) = 0$$

$$E(M) = -0.5 * \log_2(0.5) - 0.5 * \log_2(0.5) = 1$$

$$E(A) = -1 * \log_2(1) - 0 * \log_2(0) = 0$$

Árvores de decisão

ID3 – exemplo 1

	Vento	Humidade	Casaco
1	Forte	Alta	Sim
2	Forte	Média	Sim
3	Fraco	Baixa	Não
4	Fraco	Média	Não
5	Fraco	Alta	Sim

$$G(A) = E(D) - E(A)$$

$$E(A) = \sum_S peso_s * E(S)$$

VENTO

$$Peso_{\text{fraco}} = 3/5 = 0.6$$

$$Peso_{\text{forte}} = 2/5 = 0.4$$

$$E(\text{Fraco}) = -0.33 * \log_2(0.33) - 0.67 * \log_2(0.67) = 0.915$$

$$E(\text{Forte}) = -1 * \log_2(1) - 0 * \log_2(0) = 0$$

$$G(D, \text{Vento}) = 0.971 - (0.6 * 0.915 + 0.4 * 0) = 0.422$$

$$G(D, \text{Humidade}) = 0.971 - (0.2 * 0 + 0.4 * 1 + 0.4 * 0) = 0.571$$

HUMIDADE

$$Peso_B = 1/5 = 0.2$$

$$Peso_M = 2/5 = 0.4$$

$$Peso_A = 2/5 = 0.4$$

$$E(B) = -0 * \log_2(0) - 1 * \log_2(1) = 0$$


$$E(M) = -0.5 * \log_2(0.5) - 0.5 * \log_2(0.5) = 1$$

$$E(A) = -1 * \log_2(1) - 0 * \log_2(0) = 0$$

Humidade tem maior ganho

Árvores de decisão

ID3 – exemplo 1



	Vento	Humidade	Casaco
1	Forte	Alta	Sim
2	Forte	Média	Sim
3	Fraco	Baixa	Não
4	Fraco	Média	Não
5	Fraco	Alta	Sim

Árvores de decisão

ID3 – exemplo 2

- Quando há mais atributos, o processo é similar, excluindo-se nas iterações seguintes, os atributos que já foram usados nas interações anteriores
- Dataset:

	Céu	Temp	Hum	Vento	Casaco
1	Sol	Alta	Elevada	Fraco	Não
2	Sol	Alta	Elevada	Forte	Não
3	Nuvens	Alta	Elevada	Fraco	Sim
4	Chuva	Média	Elevada	Fraco	Sim
5	Chuva	Baixa	Normal	Fraco	Sim
6	Chuva	Baixa	Normal	Forte	Não
7	Nuvens	Baixa	Normal	Fraco	Sim
8	Sol	Média	Elevada	Fraco	Não
9	Sol	Baixa	Normal	Fraco	Sim
10	Chuva	Média	Normal	Forte	Sim
11	Sol	Média	Normal	Forte	Sim
12	Nuvens	Média	Elevada	Forte	Sim
13	Nuvens	Alta	Normal	Fraco	Sim
14	Chuva	Média	Elevada	Forte	Não

Dataset

- Target: Casaco
 - Tem 14 exemplos
 - 5 SIM (36%)
 - 9 NÃO (64%)
- Tem 4 atributos
 - Céu (Sol, Nuvens, Chuva)
 - Temp (Baixa, Média, Alta)
 - Hum (Normal, Elevada)
 - Vento (Fraco, Forte)

Árvores de decisão

ID3 – exemplo 2

$$G(A) = E(D) - E(A)$$

$$E(A) = \sum_s \text{peso}_s * E(S)$$

$$E(D) = -p_1 * \log_2(p_1) - p_2 * \log_2(p_2) = -0.36 * \log_2(0.36) - 0.64 * \log_2(0.64) = 0.94$$

$$G(D, \text{Céu}) = 0.247$$


$$G(D, \text{Temp}) = 0.029$$

$$G(D, \text{Humidade}) = 0.151$$

$$G(D, \text{Vento}) = 0.048$$

Atributo **Céu** tem maior ganho

Na próxima iteração, "Céu" já não é considerado



$$G(\text{Céu_Sol}, \text{Temp}) = 0.97 - (0 + 2/5 * 1 + 0) = 0.57$$

$$G(\text{Céu_Sol}, \text{Hum}) = 0.97 - (0 + 0) = 0.97$$

$$G(\text{Céu_Sol}, \text{Vento}) = 0.97 - (2/5 * 1 + 3/5 * 0.918) = 0.019$$

$$G(\text{Céu_Chuva}, \text{Temp}) = 0.97 - (2/5 * 1 + 3/5 * 0.915) = 0.021$$


$$G(\text{Céu_Chuva}, \text{Hum}) = 0.97 - (3/5 * 0.915 + 2/5 * 1) = 0.021$$

$$G(\text{Céu_Chuva}, \text{Vento}) = 0.97 - (2/5 * 0 + 3/5 * 0.915) = 0.421$$

Árvores de decisão

ID3 – exemplo 2

A árvore de decisão treinada pelo ID3:



	Céu	Temp	Hum	Vento	Casaco
1	Sol	Alta	Elevada	Fraco	Não
2	Sol	Alta	Elevada	Forte	Não
3	Nuvens	Alta	Elevada	Fraco	Sim
4	Chuva	Média	Elevada	Fraco	Sim
5	Chuva	Baixa	Normal	Fraco	Sim
6	Chuva	Baixa	Normal	Forte	Não
7	Nuvens	Baixa	Normal	Fraco	Sim
8	Sol	Média	Elevada	Fraco	Não
9	Sol	Baixa	Normal	Fraco	Sim
10	Chuva	Média	Normal	Forte	Sim
11	Sol	Média	Normal	Forte	Sim
12	Nuvens	Média	Elevada	Forte	Sim
13	Nuvens	Alta	Normal	Fraco	Sim
14	Chuva	Média	Elevada	Forte	Não

Dia seguinte: **Céu com Sol, Vento Forte, Humidade Elevada**
Levar Casaco?

Árvores de decisão

Outros algoritmos

- ID4
- C4.5
- CaART
- Random Forest

Árvores de decisão

Vantagens e desvantagens

VANTAGENS

- Árvores de decisão continuam a ser bastante utilizadas
 - Facilidade de compreensão
 - Requerem mínima preparação de dados
 - Extensíveis muito facilmente: novas opções podem ser adicionadas às árvores existentes
 - Podem ser usadas em combinação com outras metodologias de tomada de decisão

• DESVANTAGENS

- Para problemas com muitos atributos podem tornar-se bastante complexas
- Overfitting