

CONHECIMENTO E RACIOCÍNIO

Sebenta de Estudo

Matéria completa + 6 exames resolvidos passo a passo

CBR · Sistemas Periciais · Redes Bayesianas · Lógica Difusa
Tratamento de Dados · Redes Neurais · Regressão · Árvores de Decisão

Licenciatura em Engenharia Informática · 2.º ano / 2.º semestre

Índice

PARTE I — MATÉRIA.....	
Como está organizado o exame.....	3
1. Raciocínio Baseado em Casos (CBR).....	4
2. Raciocínio Lógico — Sistemas Periciais.....	5
3. Raciocínio Incerto — Redes Bayesianas.....	6
4. Raciocínio Incerto — Lógica Difusa (Fuzzy).....	7
5. Tratamento e Análise de Dados (Datasets).....	8
6. Redes Neurais I — Perceptron.....	9
7. Redes Neurais II — Multicamada e Backpropagation.....	10
8. Modelos de Regressão.....	11
9. Árvores de Decisão.....	12
10. Formulário — resumo rápido.....	13
PARTE II — EXAMES RESOLVIDOS.....	
Exame 1 — Normal (17/06/2024).....	15
Exame 2 — Recurso (01/07/2024).....	17
Exame 3 — Normal (20/06/2025).....	19
Exame 4 — Recurso (11/07/2025).....	20
Exame 5 — Especial (24/07/2025).....	22
Exame 6 — Normal (15/06/2026).....	24

Como está organizado o exame

O exame de Conhecimento e Raciocínio dura 120 minutos e divide-se em duas partes. O formato varia entre épocas: umas têm 30 perguntas de escolha múltipla, outras 20 ou apenas 10, mas a lógica é sempre a mesma.

Parte I — Escolha múltipla (≈45%)

- Perguntas de escolha múltipla (10, 20 ou 30 conforme a época), só uma resposta correta.
- **Penalização:** respostas erradas descontam 25% da cotação. Em dúvida total, o valor esperado de responder ao calhar é negativo — só «chute» se eliminar 1-2 hipóteses.
- Forte incidência em definições, vantagens/desvantagens e «o que faz cada fase/ passo».

Parte II — Perguntas de cálculo / aplicação (≈55%)

Perguntas de desenvolvimento (5% a 10% cada). Sem cálculos na folha, a cotação é zero. Tipos recorrentes:

- **CBR:** tabela de similaridade, distâncias locais (linear/euclidiana) e similaridade global pesada.
- **Sistemas periciais:** forward e backward chaining (que regras disparam / provar objetivos) e fatores de certeza do MYCIN.
- **Redes Bayesianas:** probabilidade conjunta, inferência causal e de diagnóstico (Bayes); identificar o tipo.
- **Lógica Difusa:** funções de pertença, fuzzificação, regras disparadas e defuzzificação (centroide, middle-of-maxima ou first-of-maxima).
- **Regressão:** mínimos quadrados, métricas (MAE, MSE, RMSE, R^2) e iteração do gradiente.
- **Perceptron:** saída na 1.^a execução e uma época de treino com a regra delta (Step ou Sinal).
- **Árvores:** entropia, ganho de informação e impureza de Gini; topologia de rede feedforward.

Estratégia: a Parte II é mecânica e treinável. Dominar estes procedimentos dá quase metade do exame. Treine cada um até o fazer sem olhar para a fórmula.

1. Raciocínio Baseado em Casos (CBR)

1.1 Ideia central

O **Raciocínio Baseado em Casos** (Case-Based Reasoning) resolve um problema novo **reutilizando a solução de casos passados semelhantes**. A memória é uma *base de casos*; cada caso = descrição do problema + solução. Inspirado no raciocínio humano (o médico ou o mecânico recordam situações parecidas).

- Introduzido por **Roger Schank (1982)**; 1.º sistema: CYRUS (Kolodner, 1983).
- Protótipos: CHEF, PROTON/CASEY, JUDGE, HYPO, PATDEX.

1.2 Quando usar (vantagens / desvantagens)

Vantagens	Desvantagens / Indicações
Raciocínio pericial: usa experiência passada.	Dificuldade na adaptação de casos.
Aprendizagem simples: basta adicionar casos.	Precisa de um número significativo de casos.
Evita a extração de regras.	Domínios dinâmicos, complexos ou mal compreendidos.

1.3 Ciclo dos 4 R (Aamodt & Plaza)

1. **Retrieve**: identificar os casos mais semelhantes (similaridade).
2. **Reuse**: propor a solução do caso recuperado, direta ou adaptada.
3. **Revise**: validar/corrigir a solução.
4. **Retain**: guardar o novo caso resolvido — é a aprendizagem.

Dica de exame: Retrieve = encontrar o mais semelhante; Reuse = aplicar/adaptar; Revise = validar/corrigir; Retain = guardar o novo caso. A aprendizagem dá-se em Revise+Retain.

1.4 Similaridade (fase de Retrieve)

Número entre 0 (nada semelhante) e 1 (igual). Calcula-se em distâncias locais (atributo a atributo) e depois global pesada (caso a caso).

$$\text{Similaridade Global} = 1 - D \quad (D = \text{distância normalizada})$$

- **Numéricos**: normalizar ($V/V_{\max}$ ou $(V-V_{\min})/(V_{\max}-V_{\min})$); linear $|c-q|$ ou euclidiana $\sqrt{(c-q)^2}$.
- **Ordinais**: converter para escala e tratar como numéricos.
- **Simbólicos**: tabela de similaridade (TS); $d = 1 - TS(v_1, v_2)$.

$$D_L = \frac{\sum (d_i \cdot w_i)}{\sum w_i} \quad D_E = \frac{\sum (d_i^2 \cdot w_i)}{\sum w_i}$$

Dica de exame: Receita: (1) normalizar; (2) converter ordinais/símbolos; (3) distância local; (4) distância global pesada; (5) $\text{Sim} = 1 - D$; (6) maior similaridade = caso recuperado.

2. Raciocínio Lógico — Sistemas Periciais

2.1 O que é

Programa que reproduz o raciocínio de um **especialista** com regras **SE...ENTÃO**. Apoio à decisão (não substitui o perito). Marcos: DENDRAL (1.º), MYCIN, PROSPECTOR, XCON, CADUCEUS.

2.2 Componentes

- **Base de conhecimento:** as regras e factos do domínio.
- **Memória de trabalho:** os factos do problema atual.
- **Motor de inferência:** liga regras a factos, ativa regras, infere e explica.

2.3 Encadeamento

Forward chaining (para a frente)	Backward chaining (para trás)
Guiado pelos factos (data-driven).	Guiado por objetivos (goal-driven).
Parte dos factos e infere conclusões (novos factos).	Parte de um objetivo e procura factos/regras que o provem.
Cada regra dispara 1x; pára quando nenhuma é ativável.	Procura regras cujo consequente é o objetivo.

Backward (provar objetivo): encadeia regras de trás para a frente até chegar a factos conhecidos. Se faltar um facto que nenhuma regra infere, o objetivo NÃO é provável.

2.4 Fatores de certeza (MYCIN)

CF entre -1 e +1 (não é probabilidade). AND→min, OR→max, NOT→-CF.

$$CF_{\text{conclusão}} = CF_{\text{condições}} \times CF_{\text{regra}}$$

Combinar 2 regras (mesma hipótese)	Fórmula
Ambos ≥ 0	$CF = CF_1 + CF_2 \cdot (1 - CF_1)$
Ambos ≤ 0	$CF = CF_1 + CF_2 \cdot (1 + CF_1)$
Sinais opostos	$(CF_1 + CF_2) / (1 - \min(CF_1 , CF_2))$

Dica de exame: Para >2 regras combina-se duas a duas. Ex.: $CF_{\text{cond}}=0.9$, $CF_{\text{regra}}=0.8 \rightarrow 0.72$; combinar 0.72 e 0.49 $\rightarrow 0.72+0.49 \cdot (1-0.72)=0.857$.

3. Raciocínio Incerto — Redes Bayesianas

3.1 Probabilidades

- Condicional: $P(A|B) = P(A,B)/P(B)$.
- Lei da probabilidade total: $P(A) = \sum P(A|B_n) \cdot P(B_n)$.

3.2 Teorema de Bayes

Atualiza uma crença (priori $\rightarrow$ posteriori) com nova evidência.

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

$$P(B) = \sum P(B|A_i) \cdot P(A_i)$$

3.3 Redes Bayesianas (Pearl, 1985)

- Grafo **acíclico dirigido**; nós = variáveis aleatórias; arestas = dependência condicional (causa $\rightarrow$ efeito).
- Cada nó tem uma CPT.

Conjunta:

$$P(x_1, \dots, x_n) = \prod_i P(x_i | \text{Pais}(x_i))$$

Causal (causa $\rightarrow$ efeito): lei da probabilidade total. **Diagnóstico (efeito $\rightarrow$ causa):** teorema de Bayes.

Dica de exame: Se a evidência está na CAUSA e se pergunta o EFEITO $\rightarrow$ causal (prob. total). Se está no EFEITO e se pergunta a CAUSA $\rightarrow$ diagnóstico (Bayes).

4. Raciocínio Incerto — Lógica Difusa (Fuzzy)

4.1 Conceitos

Lógica difusa (Zadeh, 1965): graus de verdade em $[0,1]$, em vez de 0/1. Conjunto fuzzy admite pertença **parcial**; função de pertença $\mu: U \rightarrow [0,1]$ (não é probabilidade). Variável linguística: valores são palavras.

4.2 Operações

Operação	Fórmula
Interseção (AND)	$\min(\mu_A, \mu_B)$
União (OR)	$\max(\mu_A, \mu_B)$
Complemento (NOT)	$1 - \mu_A$

4.3 FIS (Mamdani) — 4 passos

1. **Fuzzificar**: calcular μ de cada entrada em cada termo.
2. **Avaliar regras**: grau = $\min$ (AND) ou $\max$ (OR); truncar o consequente.
3. **Agregar**: sobrepor ($\max$) as saídas truncadas.
4. **Defuzzificar**: converter num valor crisp.

$$\mu_{\text{triangular}}(x) = \max(\min((x-a)/(b-a) , (c-x)/(c-b)) , 0)$$

Trapezoidal (a,b,c,d): $\mu=1$ entre b e c.

4.4 Métodos de defuzzificação

- **Centroide (COA)**: $z^* = \Sigma(z_i \cdot \mu(z_i)) / \Sigma \mu(z_i)$ — o mais pedido.
- **Middle of Maxima (MoM)**: ponto médio do intervalo onde μ é máximo na área agregada.
- **First of Maxima (FoM)**: primeiro valor de x onde μ atinge o máximo.
- Outros: max membership, média pesada, last-of-maxima, center-of-sum.

Dica de exame: Identificar o máximo da área agregada é a chave para MoM e FoM: MoM = meio do patamar máximo; FoM = início desse patamar. O centroide usa todos os termos pesados pelo seu μ .

5. Tratamento e Análise de Dados (Datasets)

5.1 Tipos de aprendizagem

- **Supervisionada:** com target — classificação (categorias) e regressão (contínuo).
- **Não supervisionada:** sem target — clustering.
- **Por reforço:** por recompensa.

Dataset: linhas=exemplos, colunas=atributos; os algoritmos precisam de dados numéricos.

5.2 Limpeza e transformação

- **Limpeza:** outliers (extremos), NaN (eliminar/preencher/prever), redundâncias.
- **Transformação:** normalizar, standardizar; ordinais→escala, nominais→one-hot.

Norm. máx: $X/\max$ min-max: $(X-\min)/(\max-\min)$
 Standard (z): $(X-\mu)/\sigma$ [média 0, desvio 1]

Normalização	Standardização
Gama [0,1]; mantém a forma.	Centra na média, desvio 1; altera a forma.
Sensível a outliers; redes neuronais, regressão.	Menos sensível a outliers; clustering, SVM.

Dica de exame: Overfitting: bom no treino, mau em dados novos. Evitar com mais dados, divisão treino/validação/teste e cross-validation.

6. Redes Neurais I — Perceptron

6.1 Neurónio artificial

$$S = b \cdot w_0 + \sum x_i \cdot w_i \quad y = g(S)$$

Bias w_0 : ajusta o limiar de disparo (o b em $y=ax+b$).

6.2 Modelos

- **McCulloch-Pitts (1943):** binário, limiar fixo, NÃO aprende; implementa portas AND/OR/NOR.
- **Perceptron (Rosenblatt 1957) e ADALINE (1960):** aprendem (supervisionado). Ativação Step: $y=1$ se $S \geq 0$ senão 0.

6.3 Regra Delta (treino)

$$\begin{aligned} \text{erro} &= \text{target} - y \\ w_i &= w_i + \eta \cdot (\text{target} - y) \cdot x_i \quad w_0 \text{ usa } b \end{aligned}$$

- **Época:** uma passagem por todos os exemplos. Iteração: um exemplo.
- **Limite (Minsky&Papert):** só separa problemas linearmente separáveis. XOR não → rede multicamada.

Dica de exame: Receita: tabela por exemplo $S \rightarrow y$ (Step/Sinal) → erro=target-y → atualizar w_0, w_1, w_2 . Os exemplos seguintes usam os pesos já atualizados. Sinal dá -1/+1; Step dá 0/1.

7. Redes Neurais II — Multicamada e Backpropagation

- Camada escondida resolve o XOR (separa por plano/hiperplano).
- **Feedforward**: info da entrada para a saída, sem ciclos. Nós de entrada = nº de features; nós de saída = nº de classes.

7.1 Sigmoide e treino

Sigmoide: $y = 1/(1+e^{(-x)})$ contínua e diferenciável

Treina-se por **gradiente descendente** minimizando o custo $E = \frac{1}{2} \sum (t-y)^2$.

7.2 Backpropagation

1. **Forward pass**: calcular a saída.
2. Calcular o erro na saída.
3. **Backward pass**: retropropagar o erro (gradiente por peso).
4. Atualizar os pesos; repetir até convergir.

Dica de exame: Topologia (desenho): entrada (1 nó por feature) → camadas escondidas → saída (1 nó por classe), todos os nós ligados entre camadas. Indique as dimensões (ex.: 3-2-2-3).

8. Modelos de Regressão

- Supervisionada para **prever valores contínuos**. Reta $y=a \cdot x+b$ (a =declive, b =ordenada).
- Resíduo $= y_i - \hat{y}_i$. Pearson $r \in [-1,1]$; R^2 = qualidade do ajuste (R^2 =Pearson²).

8.1 Mínimos quadrados (não iterativo)

$$\begin{aligned} a \cdot \sum x^2 + b \cdot \sum x &= \sum xy \\ a \cdot \sum x + b \cdot n &= \sum y \end{aligned}$$

8.2 Métricas

Métrica	Fórmula
MAE	$\sum y - \hat{y} / n$
MSE	$\sum (y - \hat{y})^2 / n$
RMSE	$\sqrt{\text{MSE}}$
R^2	$1 - \frac{\sum (y - \hat{y})^2}{\sum (y - \bar{y})^2}$

8.3 Gradiente descendente (iterativo)

$$\begin{aligned} a &= a - LR \cdot 2 \cdot \sum (a \cdot x_i + b - y_i) \cdot x_i \\ b &= b - LR \cdot 2 \cdot \sum (a \cdot x_i + b - y_i) \end{aligned}$$

Dica de exame: «Reta que melhor aproxima» → mínimos quadrados (exato). «N iterações com a, b e LR » → gradiente. Não confunda.

9. Árvores de Decisão

- Supervisionada (classificação/regressão). Nó raiz, nós de decisão, folhas, ramos.
- Critério: qual o melhor atributo para dividir primeiro.

9.1 Entropia e Ganho (ID3)

$$\begin{aligned} \text{Entropia}(D) &= -\sum p_i \cdot \log_2(p_i) \\ E(A) &= \sum \text{peso}_j \cdot \text{Entropia}(S_j) \\ \text{Ganho}(D, A) &= E(D) - E(A) \rightarrow \text{MAIOR} \end{aligned}$$

- Entropia 0 = puro; 1 = 50/50. Escolher MAIOR ganho.
- ID3 só trabalha com atributos categóricos.

9.2 Gini e variância

$$\begin{aligned} \text{Gini}(\text{nó}) &= 1 - \sum p_k^2 \rightarrow \text{MENOR} \\ \text{Variância} &= \sum k_i \cdot (X_i - \mu)^2 / n \quad (\text{target contínuo}) \end{aligned}$$

Dica de exame: Entropia/Ganho e Gini respondem «qual atributo no nó?», mas a regra é oposta: MAIOR ganho, MENOR Gini. Mostre sempre os pesos de cada ramo.

10. Formulário — resumo rápido

CBR

$Sim = 1 - D$
 $D_L = \sum (d_i w_i) / \sum w_i$ $D_E = \sum (d_i^2 w_i) / \sum w_i$
 simbólica: $d = 1 - TS(v1, v2)$

MYCIN

AND $\rightarrow$ min OR $\rightarrow$ max NOT $\rightarrow$ -CF
 $CF_{concl} = CF_{cond} \times CF_{regra}$
 ambos+: $CF_1 + CF_2 (1 - CF_1)$
 opostos: $(CF_1 + CF_2) / (1 - \min(|CF_1|, |CF_2|))$

Bayes

$P(A|B) = P(B|A)P(A)/P(B)$
 conjunta: $\prod P(x_i | \text{país})$
 causal $\rightarrow$ prob total | diagnóstico $\rightarrow$ Bayes

Fuzzy

AND = min OR = max NOT = $1 - \mu$
 $\text{tri}(a, b, c): \max(\min((x-a)/(b-a), (c-x)/(c-b)), 0)$
 centroide: $z^* = \sum (z_i \mu_i) / \sum \mu_i$
 MoM = meio do máx | FoM = início do máx

Perceptron / MLP

$S = b \cdot w_0 + \sum x_i w_i$; Step: $y = 1$ se $S \geq 0$
 $w_i = w_i + \eta(\text{target} - y)x_i$
 sigmoide: $1/(1 + e^{(-x)})$; $E = \frac{1}{2} \sum (t - y)^2$

Regressão

MMQ: $a \sum x^2 + b \sum x = \sum xy$; $a \sum x + b n = \sum y$
 $MAE = \sum |y - \hat{y}| / n$ $MSE = \sum (y - \hat{y})^2 / n$ $RMSE = \sqrt{MSE}$
 $R^2 = 1 - \sum (y - \hat{y})^2 / \sum (y - \bar{y})^2$

Árvores

Entropia = $-\sum p_i \log_2 p_i$; Ganho = $E(D) - E(A)$ [MAIOR]
 Gini = $1 - \sum p_k^2$ [MENOR]

$\log_2$ úteis

$.5 = -1$ $.25 = -2$ $.75 = -0.415$ $.2 = -2.32$
 $.4 = -1.32$ $.8 = -0.32$ $\frac{2}{3} = -0.585$ $\frac{1}{3} = -1.585$

PARTE II

Seis exames resolvidos passo a passo

2024 · 2025 · 2026

Exame 1 — Normal (17/06/2024)

Grupo 1 — CBR [20%]

Domínio [1,100], distância local /100, pesos A=2 B=2 C=1. Novo: A=60 B=50 C=90.

Caso	D global	Sim = 1 - D
1 (70,60,80)	$(2 \cdot 1 + 2 \cdot 1 + 1 \cdot 1) / 5 = 0,10$	0,90
2 (20,30,50)	$(2 \cdot 4 + 2 \cdot 2 + 1 \cdot 4) / 5 = 0,32$	0,68
3 (50,50,100)	$(2 \cdot 1 + 2 \cdot 0 + 1 \cdot 1) / 5 = 0,06$	0,94

Resposta: a) 0,90 / 0,68 / 0,94. b) Retrieve: C3 → C1 → C2. c) Não reter (C3 ~94% redundante).


Grupo 2 — Bayes [15%]

$$P(\text{Sol}=T, \text{Vento}=T, \neg\text{Praia}) = 0,5 \times 0,2 \times 0,2 = 0,02$$

Resposta: 0,02 (2%).

Grupo 3 — Fuzzy [15%]

Operação	Resultado
$\tilde{A} \cap \tilde{N}$ (mín)	$\{(1;0,1), (3;0,4)\}$
$\tilde{A} \cup \tilde{N}$ (máx)	$\{(1;0,4), (2;0,7), (3;1,0), (4;1,0), (5;0,6)\}$
$\neg\tilde{N} (1-\mu)$	$\{(1;0,6), (2;1,0), (3;0,6), (4;0), (5;0,4)\}$



Área agregada (fraco@0,3 · médio@0,5 · alto@0,7). Domínio [0,10].

$$\text{Centroide: } z^* = (2 \cdot 0,3 + 5 \cdot 0,5 + 8 \cdot 0,7) / 1,5 = 8,7 / 1,5 = 5,8$$

Resposta: Operações acima; $z^* = 5,8$.

Grupo 4 — Regressão [15%]

$$\Sigma x=32 \quad \Sigma y=26 \quad \Sigma x^2=224 \quad \Sigma xy=126 \quad (n=6).$$

$$a = (6 \cdot 126 - 32 \cdot 26) / (6 \cdot 224 - 32^2) = -76 / 320 = -0,2375$$

$$b = (26 + 7,6) / 6 = 5,6 \rightarrow y = -0,2375x + 5,6$$

$$\text{MAE} = 8,0 / 6 \approx 1,33$$

Resposta: $y = -0,2375x + 5,6$; $MAE \approx 1,33$.

Grupo 5 — Perceptron (Step) [20%]

Pesos iniciais $w_0=-1$ $w_1=1$ $w_2=1$; $b=1$; $\eta=1$.

Ex.	x_1	x_2	S	y	alvo	erro	w_0	w_1	w_2
ini	-	-	-	-	-	-	-1	1	1
1	0	1	0	1	1	0	-1	1	1
2	1	2	2	1	0	-1	-2	0	-1
3	2	1	-3	0	0	0	-2	0	-1

Resposta: a) $y=1$. b) $w_0=-2$, $w_1=0$, $w_2=-1$.

Grupo 6 — Árvore [15%]

$E(D) = -0,5 \cdot \log_2 0,5 \cdot 2 = 1,0$
 $Sol=Sim \rightarrow 3V(E=0)$ $Sol=Não \rightarrow 3F(E=0) \rightarrow Ganho=1,0$

Resposta: $E(D)=1,0$; $Ganho(Sol)=1,0$; raiz = Sol (Sim $\rightarrow$ Verdade, Não $\rightarrow$ Falso).

Exame 2 — Recurso (01/07/2024)

Grupo 1 — CBR (automóveis) [20%]

Pesos portas=1 tipo=1 preço=2. portas[0,5] e preço[1000,2000] euclidiana; tipo por tabela. Novo: 5 portas, Gasolina, 1500€.

Tabela proposta (tipo): Gasolina ↔ Gasolina=1; Gasolina ↔ Híbrido=0,5; Gasolina ↔ Elétrico=0.

Caso	Sim = $1 - \Sigma(d \cdot w)/4$
1 (Híbrido, 1500€)	$1 - 0,7/4 = 0,825$
2 (Gasolina, 1100€)	$1 - 0,8/4 = 0,80$
3 (Elétrico, 1700€)	$1 - 1,4/4 = 0,65$

Resposta: Retrieve: C1 → C2 → C3. Sugerido: Caso 1 (marca A). Nota: C2 (B) muito perto — depende da tabela do tipo. Reuse = propor a marca; Retain = guardar o caso novo.

Grupo 2 — Bayes [10%]


$$P(\text{Praia=Sim} \mid \text{Sol=T}) = 0,8 \cdot 0,2 + 0,99 \cdot 0,8 = 0,952$$

Resposta: 0,952 (inferência causal).

Grupo 3 — Fuzzy [15%]

$\tilde{A} = \{(1;0,5), (2;1), (3;1), (4;0,5)\}$ [$A=(0,2,3,5)$]; $\tilde{N} = \{(1;0,3), (2;0,6), (4;0,6), (5;0)\}$ [$N \text{ pico} \approx 3,3$].

Operação	Resultado
$\tilde{A} \cap \tilde{N}$	$\{(1;0,3), (2;0,6), (4;0,5)\}$
$\tilde{A} \cup \tilde{N}$	$\{(1;0,5), (2;1), (3;1), (4;0,6)\}$
$\neg \tilde{N}$	$\{(1;0,7), (2;0,4), (4;0,4), (5;1)\}$



b) Área dada; defuzzificação por Middle of Maxima (máximo 0,8 no patamar [8,12]).

Resposta: b) Middle of Maxima = $(8+12)/2 = 10$.

Grupo 4 — Regressão [20%]

a) Uma iteração do gradiente ($a=1$, $b=10$, $LR=0,001$): $\Sigma r=66$, $\Sigma(r \cdot x)=418$.

$$a = 1 - 0,001 \cdot 2 \cdot 418 = 0,164 \quad ; \quad b = 10 - 0,001 \cdot 2 \cdot 66 = 9,868$$

b) R^2 com $y = -0,24x + 5,6$: $SS_{res}=12,33$, $SS_{tot}=15,33$.

$$R^2 = 1 - 12,33/15,33 = 0,20$$

Resposta: a) $a=0,164$ $b=9,868$. b) $R^2 \approx 0,20 \rightarrow$ ajuste fraco (só ~20% da variação).

Grupo 5 — Perceptron (Step) [20%]

$$a) \ x_1=1 \ x_2=1: S=-2+1+1=0 \geq 0 \rightarrow y=1$$

$$b) \text{ Reta de decisão } (w_0=-1, w_1=-1, w_2=2): x_2 = -x_1 \cdot (w_1/w_2) - b \cdot (w_0/w_2).$$

$$x_2 = 0,5 \cdot x_1 + 0,5$$

Resposta: a) $y=1$. b) reta $x_2 = 0,5 \cdot x_1 + 0,5$ (separa (1,1) e (0,1) de (2,1)).

Grupo 6 — Árvore [15%]

$E(D)=1,0$; Estatura=Alta $\rightarrow 2V(E=0)$ Baixa $\rightarrow 2F(E=0)$
 Ganho(Estatura)=1,0

Resposta: $E(D)=1,0$; Ganho(Estatura)=1,0 ; raiz = Estatura (Alta $\rightarrow$ Verdade, Baixa $\rightarrow$ Falso).

Exame 3 — Normal (20/06/2025)

Grupo I — Escolha múltipla (1-30)

#	R	#	R	#	R	#	R	#	R
1	B	7	C	13	A	19	B	25	C
2	C	8	B	14	B	20	C	26	A
3	B	9	C	15	C	21	B	27	B
4	C	10	C	16	B	22	B	28	C
5	B	11	B	17	C	23	B	29	C
6	C	12	B	18	C	24	C	30	B

31 — Bayes [15%]

$P(\text{Praia}|\text{Sol}=\text{T})=0,8 \cdot 0,2+0,99 \cdot 0,8=0,952$
 $P(\text{Praia}|\text{Sol}=\text{F})=0,05 \cdot 0,2+0,1 \cdot 0,8=0,09$
 $P(\text{Praia})=0,952 \cdot 0,5+0,09 \cdot 0,5=0,521$
 $P(\text{Sol}|\text{Praia})=0,476/0,521=0,914$

Resposta: a) 0,914. b) inferência de diagnóstico (efeito→causa, Bayes).

32 — Fuzzy [15%]

Saída trapezoidal: Nula(0,0,0,0) Fraca(0,2,3,5) Média(3,4,5,6) Alta(4,6,8,10).

Entrada	Fuzzificação
Vento = 2	fraco=1,0 · médio=0 · forte=0
Humidade = 3	baixa=0,25 · média=0,5 · alta=0

Regras: R1 $\max(0;1)=1$ dispara · R2 0,5 dispara · R3 $\min(0,25;1)=0,25$ dispara · R4 (forte=0) não.

Centroide (Nula=0 Fraca=2,5 Alta=7; μ 1/0,5/0,2):
 $z^*=(0+1,25+1,4)/1,7=2,65/1,7=1,56$

Resposta: Fuzzificação acima; disparam R1, R2 e R3; $z^* = 1,56$.

33 — Topologia [?]

Feedforward, 2 camadas escondidas de 2 neurónios: entrada (3 nós: x,y,z) → escondida 2 → escondida 2 → saída (3 nós: A,B,C), com todas as ligações entre camadas.

34 — Árvore [?]

$E(D)=- (4/6) \log_2 (4/6) - (2/6) \log_2 (2/6)=0,918$
 $\text{Ganho}(\text{Salário})=0,918-0,459=0,459$
 $\text{Gini: Salário}=0,222 < \text{Encargos}=0,333$

Resposta: $E(D)=0,918$; $\text{Ganho}(\text{Salário})=0,459$; nó de decisão = Salário (menor Gini).

Exame 4 — Recurso (11/07/2025)

Grupo I — Escolha múltipla (1-20)

#	R	#	R	#	R	#	R
1	C	6	B	11	C	16	C
2	B	7	C	12	C	17	D
3	B	8	D	13	C	18	C
4	A	9	C	14	C	19	B
5	C	10	C	15	B	20	C

21 — CBR [10%]

Pesos Idade=2 Triagem=1 Doença=2. Novo: Idade60 Triagem2 Doença=Grave. Tabela proposta (doença): Ligeiro1 Moderado2 Grave3 MuitoGrave4, $d = |a-b|/3$.

Caso	Sim global
1 (70, 3, Grave)	$\approx 0,91$
2 (20, 5, Muito Grave)	$\approx 0,56$
3 (20, 1, Ligeiro)	$\approx 0,52$

Resposta: Caso 1 é o mais semelhante ($\approx 0,91$) → Internamento = Sim.

22 — Bayes [10%]

$$P(\text{Falha}=\text{Sim} \mid \text{Temp}=\text{Alta}) = 0,6 \cdot 0,85 + 0,95 \cdot 0,15 = 0,6525$$


Resposta: 0,6525 (inferência causal).

23 — Fuzzy [?]

Temperatura triangular: baixa[0,10,20] moderada[10,20,30] alta[20,30,40]. Temp=12.

$$\text{baixa} = (20-12)/10 = 0,8 \quad ; \quad \text{moderada} = (12-10)/10 = 0,2 \quad ; \quad \text{alta} = 0$$

Disparam R1 (baixa→alto, 0,8) e R2 (moderada→médio, 0,2); R3 não.



Saída agregada ($\text{alto} @ 0,8 \cdot \text{médio} @ 0,2$). Máximo 0,8; patamar [8,6 ; 10].

Resposta: Fuzzificação acima; Middle of Maxima = $(8,6+10)/2 = 9,3$.

24 — Regressão (split 50/50) [20%]

Treino (Id ímpar): (2,7) (5,5) (8,3) — colineares. Teste (Id par): (9,5) (7,2) (1,4).

$$a = (3 \cdot 63 - 15 \cdot 15) / (3 \cdot 93 - 225) = -36/54 = -0,667$$

$$b = (15 + 10) / 3 = 8,333 \rightarrow y = -0,667x + 8,333$$

b) SSE treino = 0 (ajuste perfeito). c) MAE teste:

$$MAE = (8/3 + 5/3 + 11/3) / 3 = 8/3 \approx 2,67 \quad (MSE \approx 7,78)$$

Resposta: $y = -0,667x + 8,333$; $SSE=0$; $MAE \approx 2,67$.

25 — Perceptron (Sinal ± 1) [10%]

Pesos iniciais $w_0 = -1$ $w_1 = 1$ $w_2 = 0$; $b = 1$; $\eta = 1$; Sinal: $y = +1$ se $S \geq 0$ senão -1 .

Ex.	x_1	x_2	S	y	alvo	erro	w_0	w_1	w_2
ini	-	-	-	-	-	-	-1	1	0
1	1	1	0	+1	0	-1	-2	0	-1
2	1	2	-4	-1	0	+1	-1	1	1
3	2	1	2	+1	-1	-2	-3	-3	-1

Resposta: a) $y = +1$. b) $w_0 = -3$, $w_1 = -3$, $w_2 = -1$.

26 — Árvore [?]

$$E(D) = -(1/4) \log_2(1/4) - (3/4) \log_2(3/4) = 0,811$$

Peso=Leve 1V1F(E=1) Pesado 2N(E=0) $\rightarrow E=0,5$

$$\text{Ganho(Peso)} = 0,811 - 0,5 = 0,311$$

Resposta: $E(D) = 0,811$; $\text{Ganho(Peso)} = 0,311$.

Exame 5 — Especial (24/07/2025)

Grupo I — Escolha múltipla (1-20)

#	R	#	R	#	R	#	R
1	B	6	B	11	C	16	A
2	B	7	C	12	A	17	C
3	C	8	B	13	B	18	B
4	A	9	A	14	C	19	C
5	C	10	C	15	A	20	B

21 — Raciocínio Lógico (forward) [10%]

Pessoa	Regras que disparam
João (febre, dores)	R2 (constipação), R3 (resfriado)
Maria (febre)	R3 (resfriado)
Ana (febre, dores, tosse)	R1 (gripe), R2, R3 e depois R4 (marcar consulta)

Resposta: Ativam-se R1, R2, R3 e R4. R4 só dispara depois de R1 produzir «gripe».


22 — Bayes [10%]

$$P(\text{Temp=Alta, Pressão=Baixa, } \neg \text{Falha}) = 0,2 \times 0,15 \times 0,05 = 0,0015$$

Resposta: 0,0015.

23 — Fuzzy [10%]

Operação	Resultado
$\tilde{A} \cap \tilde{N}$	$\{(1;0,1), (3;0,4)\}$
$\tilde{A} \cup \tilde{N}$	$\{(1;0,4), (2;0,7), (3;1), (4;1), (5;0,6)\}$
$\neg \tilde{N} (\text{dom } [1,10])$	$\{(1;0,6), (2;1), (3;0,6), (4;0), (5;0,4), (6;1), (7;1), (8;1), (9;1), (10;1)\}$



Área agregada ($\text{fraco}@0,5 + \text{médio}@0,25 + \text{alto}@0,75$). Domínio $[0,20]$.

$$\text{Centroide: } z^* = (5 \cdot 0,5 + 10 \cdot 0,25 + 15 \cdot 0,75) / 1,5 = 16,25 / 1,5 \approx 10,83$$

Resposta: Operações acima; $z^* \approx 10,83$. (Domínio $[1,10] \rightarrow \neg \tilde{N}$ inclui 6-10 a 1,0.)

24 — Regressão [20%]

Pearson $r = 443,58/449,16 \approx 0,99$ (positiva forte)
 $MSE (y=2,8x-1,5) = 6,71/5 \approx 1,34$
 $x=10 \rightarrow \hat{y}=2,8 \cdot 10 - 1,5 = 26,5 \text{ k€}$

Resposta: $r \approx 0,99$; $MSE \approx 1,34$; previsão = 26,5 k€.

25 — Perceptron (Step) [10%]

Pesos iniciais $w_0=-1$ $w_1=1$ $w_2=-1$; $b=1$; $\eta=1$.

Ex.	x_1	x_2	S	y	alvo	erro	w_0	w_1	w_2
ini	-	-	-	-	-	-	-1	1	-1
1	1	1	-1	0	0	0	-1	1	-1
2	0	2	-3	0	0	0	-1	1	-1
3	2	0	1	1	-1	-2	-3	-3	-1

Resposta: a) $y=0$. b) $w_0=-3$, $w_1=-3$, $w_2=-1$.

26 — Árvore [20%]

$E(D) \approx 0,971$
 Som: Ganho=0,171 ; Movimento: Ganho=0,971

Resposta: $E(D) \approx 0,971$; Ganho(Som) $\approx 0,171$; raiz = Movimento (ganho maior, Sim $\rightarrow V$, Não $\rightarrow F$).

Dica de exame: Armadilha: a alínea pede o ganho do «Som» (0,171), mas o ID3 escolhe o «Movimento» (0,971) para a raiz.

Exame 6 — Normal (15/06/2026)

Resolução oficial. Tópicos novos: backward chaining, fatores de certeza MYCIN e defuzzificação First-of-Maxima.

Grupo I — Escolha múltipla (1-10)

#	R	#	R
1	B	6	B
2	C	7	B
3	B	8	A
4	C	9	C
5	B	10	B

11 — Sistema pericial [10%]

a) Forward: R1→falha backend; R2→erro versão nova; R3→incidente aplicacional. R4 não dispara (falta «perda de dados reportada»).

b) Backward: «incidente aplicacional» é provável (R3←R2←R1). «incidente crítico» NÃO é provável — R4 precisa de «perda de dados reportada», que não é facto nem há regra que o infira.

12 — MYCIN [10%]

$CF_1 = 0,9 \cdot 0,8 = 0,72$; $CF_2 = 0,7 \cdot 0,7 = 0,49$; $CF_3 = 0,8 \cdot 0,6 = 0,48$
 $CF_{12} = 0,72 + 0,49 \cdot (1 - 0,72) = 0,8572$
 $CF = 0,8572 + 0,48 \cdot (1 - 0,8572) = 0,926 \approx 0,93$

Resposta: CF final $\approx 0,93$.


13 — Bayes (diagnóstico) [10%]

$P(AL, A=V) = 0,95 \cdot 0,2 \cdot 0,3 + 0,8 \cdot 0,2 \cdot 0,7 = 0,169$
 $P(AL) = 0,057 + 0,096 + 0,112 + 0,028 = 0,293$
 $P(A=V | AL) = 0,169 / 0,293 = 0,577$

Resposta: $P(A=V | AL=Sim) \approx 0,577$ (57,7%).

14 — Fuzzy (First-of-Maxima) [20%]

Entradas (=65): Médio=(70-65)/20=0,25 ; Alto=(65-60)/40=0,125. Regras (AND=min) todas dão 0,125 ou 0,25.



Saída agregada (Média@0,25 · Alta@0,125). First-of-Maxima = primeiro x onde $\mu=0,25$.

FoM: $\mu_{\text{máx}}=0,25$ (Média 30,50,70) $\rightarrow (x-30)/20=0,25 \rightarrow x = 35$

Resposta: First-of-Maxima = 35%.

15 — Perceptron (Step) [10%]

Pesos iniciais $w_0=-1$ $w_1=1$ $w_2=0$; $b=1$; $\eta=1$. 1.ª execução (1,1): $S=0 \rightarrow y=1$.

Ex.	x_1	x_2	S	y	alvo	erro	w_0	w_1	w_2
ini	-	-	-	-	-	-	-1	1	0
1	1	1	0	1	1	0	-1	1	0
2	1	2	0	1	0	-1	-2	0	-2
3	2	1	-4	0	0	0	-2	0	-2

Resposta: 1.ª saída = 1 ; após 1 época: $w_0=-2$, $w_1=0$, $w_2=-2$.

16 — Árvore [?]

$E(D)=1,0$

Certificação: Sim $\rightarrow$ 3V($E=0$) Não $\rightarrow$ 3F($E=0$) $\rightarrow$ Ganho=1,0

Gini(Experiência)=(2/6) · 0,5 · 3=0,5

Resposta: $E(D)=1,0$; Ganho(Certificação)=1,0 ; nó de decisão = Certificação (divisão pura).