

CONHECIMENTO E RACIOCÍNIO

Guia de Estudo Completo

Matéria completa das teóricas + exames resolvidos passo a passo

CBR · Sistemas Periciais · Redes Bayesianas · Lógica Difusa
Tratamento de Dados · Redes Neurais · Regressão · Árvores de Decisão

Licenciatura em Engenharia Informática · 2.º ano / 2.º semestre

Índice

PARTE I — MATÉRIA.....	
Como está organizado o exame.....	3
1. Raciocínio Baseado em Casos (CBR).....	4
2. Raciocínio Lógico — Sistemas Periciais.....	6
3. Raciocínio Incerto — Redes Bayesianas.....	8
4. Raciocínio Incerto — Lógica Difusa (Fuzzy).....	10
5. Tratamento e Análise de Dados (Datasets).....	12
6. Redes Neurais I — Perceptron.....	14
7. Redes Neurais II — Multicamada e Backpropagation.....	15
8. Modelos de Regressão.....	16
9. Árvores de Decisão.....	17
10. Formulário — resumo rápido.....	18
PARTE II — EXAMES RESOLVIDOS.....	
Exame Resolvido 1 — Época Normal (17/06/2024).....	21
Exame Resolvido 2 — Época Especial (24/07/2025).....	24

Como está organizado o exame

O exame de Conhecimento e Raciocínio tem a duração de **120 minutos** e divide-se essencialmente em duas partes:

Parte I — Escolha múltipla (≈45%)

- **30 perguntas** de escolha múltipla, cada uma valendo cerca de 1.0–1.5%.
- Só existe uma resposta correta por pergunta.
- **Penalização:** respostas erradas descontam 25% da cotação da pergunta. Em caso de dúvida total entre 4 opções, o valor esperado de responder ao calhar é negativo — só «chute» quando conseguir eliminar pelo menos uma ou duas hipóteses.
- Cobre todos os temas, com forte incidência em definições, vantagens/desvantagens e «o que faz cada fase/ passo».

Parte II — Perguntas de cálculo / aplicação (≈55%)

São perguntas de desenvolvimento, com cotações altas (5% a 10% cada). Exigem mostrar os cálculos na folha de prova — sem cálculos, a cotação é zero. Os tipos recorrentes nos exames anteriores são:

- **CBR:** propor tabela de similaridade, calcular distâncias locais (linear/euclidiana) e similaridade global pesada.
- **Sistemas periciais:** forward chaining (que regras disparam) e fatores de certeza do MYCIN.
- **Redes Bayesianas:** probabilidade conjunta, inferência causal e inferência de diagnóstico (Bayes); identificar o tipo de inferência.
- **Lógica Difusa:** desenhar funções de pertença, fuzzificar entradas, indicar regras disparadas e defuzzificar pelo centroide.
- **Regressão:** mínimos quadrados (equação da reta), métricas (MAE, MSE, RMSE, R^2) e uma iteração do gradiente descendente.
- **Perceptron:** saída na 1.ª execução e uma época de treino com a regra delta (função Step ou Sinal).
- **Árvores de decisão:** entropia do dataset, ganho de informação e impureza de Gini de cada atributo; topologia de uma rede feedforward.

Estratégia: a Parte II pesa mais e é onde se ganham notas altas porque é mecânica e treinável. Dominar os 7 «procedimentos» acima dá quase metade do exame. Faça cada um até conseguir executá-lo sem olhar para a fórmula.

1. Raciocínio Baseado em Casos (CBR)

1.1 Ideia central

O **Raciocínio Baseado em Casos** (Case-Based Reasoning) resolve um problema novo **reutilizando a solução de casos passados semelhantes**. Em vez de inferir tudo a partir de regras, a memória do sistema é uma *base de casos* (case library), e cada caso = descrição do problema + respetiva solução.

Princípio básico: usar a experiência passada (memória » base de casos) para resolver um novo problema (novo caso). Inspirado no raciocínio humano: o médico, o mecânico ou o arquiteto recordam situações anteriores parecidas.

Origem e exemplos históricos

- Introduzido por **Roger Schank (1982)**; primeiro sistema CBR: CYRUS (Janet Kolodner, Yale, 1983).
- Protótipos: CHEF (receitas), PROTOS/CASEY (diagnóstico médico), JUDGE (sentenças), HYPO (patentes), PATDEX (falhas em equipamento).

1.2 Quando usar CBR (vantagens / desvantagens)

Vantagens	Desvantagens / Indicações
Raciocínio pericial: baseia-se em experiência passada.	Dificuldade na adaptação de casos.
Aprendizagem simples: basta adicionar casos relevantes.	Precisa de um número significativo de casos.
Evita a fase de extração de conhecimento (regras).	Indicado para domínios dinâmicos, complexos ou mal compreendidos, que dependem de experiência passada.

Contraste com sistemas de regras: os sistemas baseados em regras servem domínios bem delimitados e estáveis (factos + regras IF...THEN) e geram respostas «do zero»; o CBR serve domínios extensos/vagos/dinâmicos, representa conhecimento como casos, dá respostas baseadas em precedentes e aprende automaticamente com o uso.

1.3 O ciclo dos 4 R (Aamodt & Plaza)

1. **Retrieve (Recuperar):** identificar na base os casos mais semelhantes ao problema atual (cálculo de similaridade).
2. **Reuse (Reutilizar):** propor a solução do caso recuperado, diretamente ou adaptada ao novo contexto.
3. **Revise (Rever):** avaliar/validar a solução (perito externo ou simulação) e corrigir se necessário.
4. **Retain (Reter):** guardar o novo caso (já resolvido) na base, aumentando o conhecimento — é a aprendizagem.

Dica de exame: As 30 perguntas de escolha múltipla adoram pedir «o que acontece na fase X». Decore: Retrieve = encontrar o mais semelhante; Reuse = aplicar/adaptar; Revise = validar/corrigir; Retain = guardar o novo caso para aprender.

1.4 Medidas de similaridade (fase de Retrieve)

A semelhança é um número real entre **0.0** (nada semelhante) e **1.0** (igual). Calcula-se em duas etapas: distâncias *locais* (atributo a atributo) e depois a distância *global pesada* (caso a caso). A similaridade obtém-se de:

$$\text{Similaridade Global} = 1 - D \quad (D = \text{distância normalizada})$$

Distância local — depende do tipo de atributo

- **Numéricos:** normalizar primeiro ($V/V_{\max}$ ou $(V-V_{\min})/(V_{\max}-V_{\min})$). Distância linear $|c - q|$ ou euclidiana $\sqrt{(c-q)^2}$.
- **Ordinais:** converter para escala (S,M,L,XL $\rightarrow$ 1,2,3,4; Baixo,Médio,Alto $\rightarrow$ 0, 0.5, 1) e tratar como numéricos.
- **Simbólicos / enumerados:** usar uma tabela de similaridade (TS) definida pelo perito; a distância local é $D = 1 - TS(\text{valor1}, \text{valor2})$.
- **Datas:** reduzir a um número (ex.: só o ano) e tratar como numérico.
- **Booleanos:** 0 / 1.

Distância global pesada (cada atributo tem um peso w_i)

$$\begin{aligned} \text{Linear:} \quad D_L(q,s) &= \sum [d_i(q_i, s_i) \cdot w_i] / \sum w_i \\ \text{Euclidiana:} \quad D_E(q,s) &= \sum [d_i(q_i, s_i)^2 \cdot w_i] / \sum w_i \end{aligned}$$

Os casos «retrieved» são os de **maior similaridade** (menor distância), geralmente acima de um limiar (threshold).

Exemplo resumido (avaliação de risco de crédito)

Para cada caso da base calculam-se as distâncias locais normalizadas (idade, dívida, rendimento, histórico), depois a distância global linear (com pesos), e a similaridade $= 1 - D$. Ordenando por similaridade decendente, os casos no topo são os recuperados; a sua decisão (ex.: «Aprovar») é reutilizada e depois revista e, se útil e não redundante, retida.

Receita para a pergunta de CBR no exame: (1) normalizar os atributos numéricos; (2) converter ordinais/strings (tabela de similaridade); (3) calcular distância local de cada atributo; (4) aplicar a fórmula global pesada; (5) Similaridade $= 1 - D$; (6) o(s) caso(s) com maior similaridade é(são) o(s) recuperado(s).

2. Raciocínio Lógico — Sistemas Periciais

2.1 O que é um sistema pericial

Programa que reproduz o raciocínio de um **especialista** numa área, usando regras **IF ... THEN**. Serve de apoio à decisão — *nunca substitui* o perito. O conhecimento do especialista é traduzido em regras: SE (antecedente) ENTÃO (consequente), onde antecedentes/consequentes são conjunções/disjunções de proposições.

Marcos históricos

Sistema	Ano / Área	Nota
DENDRAL	1965 — química orgânica	1.º sistema pericial (Feigenbaum & Lederberg)
MYCIN	1972 — infeções no sangue	~450 regras; usa fatores de certeza
PROSPECTOR	1974 — geologia	~1000 regras
XCON	1978 — config. de computadores (DEC)	>10000 regras; grande sucesso comercial
CADUCEUS	1972 — diagnóstico médico	>10000 patologias

2.2 Componentes

- **Base de conhecimento:** as regras (e/ou redes semânticas, frames).
- **Memória de trabalho:** os factos conhecidos sobre o problema atual.
- **Motor de inferência:** liga as regras aos factos, ativa regras e infere conclusões; consegue explicar como chegou à resposta.

2.3 Encadeamento (motor de inferência)

Forward chaining (para a frente)	Backward chaining (para trás)
Guiado pelos factos (data-driven).	Guiado por objetivos (goal-driven).
Parte dos factos e infere novas conclusões, que viram novos factos.	Parte de uma hipótese/objetivo e procura factos que a provem.
Cada regra dispara uma vez; termina quando nenhuma regra mais é ativável.	Procura regras cujo consequente é o objetivo; termina quando não há mais.

Conflitos no forward chaining: quando várias regras estão ativas, escolhe-se por prioridade, especificidade (regra com mais informação) ou pelos factos mais recentes.

Exemplo (forward): Factos: febre, dores. Regras: R1 SE febre $\wedge$ dores $\wedge$ tosse $\rightarrow$ gripe; R2 SE febre $\wedge$ dores $\rightarrow$ constipação; R3 SE febre $\rightarrow$ resfriado. Disparam R2 (constipação) e R3 (resfriado); R1 não dispara (falta «tosse»). Os novos factos podem ativar outras regras (ex.: R4 SE gripe $\rightarrow$ marcar consulta).

2.4 Fatores de certeza (MYCIN)

O MYCIN é **goal-driven (backward chaining)** e lida com incerteza via **fatores de certeza (CF)**, entre -1 e $+1$. O CF *não é probabilidade* — é uma heurística do perito. Regra: SE condições ENTÃO hipótese [CF_regra].

CF das condições (combinação de antecedentes)

Operador	CF das condições
AND	$\min(CF_1, CF_2, \dots)$
OR	$\max(CF_1, CF_2, \dots)$

Operador	CF das condições
NOT	-CF

- Condição que é facto observado $\rightarrow$ CF = 1; senão usa-se o CF fornecido; se inferida por outra regra, usa-se o CF dessa inferência.

$$CF_{\text{conclusão}} = CF_{\text{condições}} \times CF_{\text{regra}}$$

Combinar várias regras que concluem a mesma hipótese (duas a duas)

Situação	Fórmula
Ambos ≥ 0 (reforço)	$CF = CF_1 + CF_2 \cdot (1 - CF_1)$
Ambos ≤ 0 (reforço contra)	$CF = CF_1 + CF_2 \cdot (1 + CF_1)$
Sinais opostos	$CF = (CF_1 + CF_2) / (1 - \min(CF_1 , CF_2))$

Para >2 regras: combina-se duas a duas, e o resultado vai sendo combinado com a regra seguinte. Mesmo sinal $\rightarrow$ reforço; sinais opostos $\rightarrow$ compensação; nunca ultrapassa ± 1 .

Exemplo: R2 dispara com $CF_{\text{cond}} = \min(1, 0.7) = 0.7$ e $CF_{\text{regra}} = 0.8 \rightarrow CF_{\text{conclusão}} = 0.7 \times 0.8 = 0.56$. Se duas regras com sinais positivos 0.6 e 0.5 concluem a mesma hipótese $\rightarrow 0.6 + 0.5 \cdot (1 - 0.6) = 0.8$.

Cuidado: se a condição de uma regra é falsa (ou um NOT cuja condição é verdadeira), essa regra é ignorada (CF = 0). Para uma hipótese ligada por OR de várias regras, a combinação final por OR é o máximo dos CF — mas se houver reforço entre regras que apontam para a mesma conclusão, use as fórmulas de combinação.

3. Raciocínio Incerto — Redes Bayesianas

3.1 Revisão de probabilidades

- **Probabilidade simples:** $P(A) = r/N$ (casos favoráveis / total).
- **Conjunta de eventos independentes:** $P(A,B) = P(A) \cdot P(B)$. Só vale se forem independentes.
- **Condicional:** $P(A|B) = P(A,B) / P(B)$.
- **Marginalização:** somar uma variável para obter a probabilidade de outra.

Lei da probabilidade total

$$P(A) = \sum_n P(A|B_n) \cdot P(B_n) = P(A|b_1)P(b_1) + \dots + P(A|b_n)P(b_n)$$

Exemplo (controlo de qualidade): $P(\text{defeituoso}) = 0.01 \cdot 0.30 + 0.02 \cdot 0.45 + 0.015 \cdot 0.25 = 0.1575$.

3.2 Teorema de Bayes

Permite **atualizar uma crença** (priori → posteriori) quando surge nova evidência. É a base do raciocínio probabilístico moderno.

$$P(A|B) = [P(B|A) \cdot P(A)] / P(B)$$

com $P(B) = \sum P(B|A_i) \cdot P(A_i)$ (lei da prob. total)

$P(A)$ = priori; $P(B|A)$ = verosimilhança; $P(B)$ = prob. total da evidência; $P(A|B)$ = posteriori.

Exemplo (teste médico): $P(D)=0.01$, $P(+|D)=0.95$, $P(+|\neg D)=0.05$. $P(+)=0.95 \cdot 0.01 + 0.05 \cdot 0.99 = 0.059$. Logo $P(D|+) = (0.95 \cdot 0.01) / 0.059 \approx 0.161$.

3.3 Redes Bayesianas (Judea Pearl, 1985)

- Grafo **acíclico direcionado**: nós = variáveis aleatórias; arcos = dependências/relações causa→efeito.
- Cada nó tem uma tabela de probabilidade (CPT): sem pais → $P(X)$; 1 pai → $P(X|Y)$; vários pais → $P(X|Y_1, \dots, Y_n)$.
- Desenhar a rede = (1) um nó por variável + setas das causas para os efeitos; (2) estimar as CPT (históricos ou peritos).

Cálculos numa rede Bayesiana

a) **Probabilidade conjunta** (regra da cadeia):

$$P(x_1, \dots, x_n) = \prod_i P(x_i | \text{Pais}(x_i))$$

b) **Inferência causal** (da causa para o efeito): usar a lei da probabilidade total. Se há evidência num pai, $P(\text{pai})=1$; se um pai é desconhecido, somam-se todas as suas possibilidades.

$$P(X) = \sum P(X | \text{Pais}) \cdot P(\text{Pais})$$

c) **Inferência de diagnóstico** (do efeito para a causa): usar Bayes.

$$P(C|x) = [P(x|C) \cdot P(C)] / P(x)$$

Exemplo (relva molhada): «Sabendo que a relva está molhada, qual a probabilidade de ter chovido?» é diagnóstico → Bayes. Numerador = $\sum P(\text{molhada}|\text{chuva}, \dots) \cdot P(\dots)$; denominador = $P(\text{molhada})$ por lei da prob. total sobre todas as combinações. Resultado típico ≈ 0.71 .

Identificar o tipo de inferência (pergunta clássica de 5%): se a evidência está na CAUSA e se pergunta o EFEITO → inferência causal (prob. total). Se a evidência está no EFEITO e se pergunta a CAUSA →

inferência de diagnóstico (Bayes). Construir CPT a partir de frequências: $P = \text{frequência da combinação} / \text{total}$.

4. Raciocínio Incerto — Lógica Difusa (Fuzzy)

4.1 Conceitos

A lógica difusa (Lotfi Zadeh, 1965) lida com conhecimento **vago/impreciso** usando *graus de verdade* entre 0 e 1, em vez do crisp 0/1 da lógica booleana. É uma extensão da lógica clássica.

- **Conjunto fuzzy:** admite pertença parcial. Caracterizado pela função de pertença $\mu_A: U \rightarrow [0,1]$.
- **Função de pertença $\mu(x)$:** dá o grau com que x pertence ao conjunto (não é probabilidade). Pode ser triangular, trapezoidal, gaussiana...
- **Variável linguística:** valores são palavras (termos linguísticos), ex.: idade = {jovem, adulto, idoso}. Cada termo é um conjunto fuzzy.

4.2 Operações sobre conjuntos fuzzy

Operação	Fórmula
Interseção (AND)	$\mu_{A \cap B}(x) = \min(\mu_A(x), \mu_B(x))$
União (OR)	$\mu_{A \cup B}(x) = \max(\mu_A(x), \mu_B(x))$
Complemento (NOT)	$\mu_{\bar{A}}(x) = 1 - \mu_A(x)$

Exemplo: se $\mu(\text{Carlos é alto})=1.0$ e $\mu(\text{Alice é alta})=0.55 \rightarrow$ «Carlos NÃO é alto» = $1-1 = 0$; «Daniela E Alice altas» = $\min(0, 0.55) = 0$; «Carlos NÃO alto OU Alice alta» = $\max(0, 0.55) = 0.55$.

4.3 Sistema de Inferência Fuzzy (FIS) — método de Mamdani

Um FIS converte entradas crisp em saída crisp, em quatro etapas:

1. **Fuzzificação:** calcular o grau de pertença μ de cada entrada a cada termo linguístico.
2. **Avaliação das regras (inferência):** o grau de ativação de cada regra é o mínimo dos antecedentes (se ligados por AND) ou o máximo (se OR). No Mamdani, o consequente é «cortado» (truncado) por esse grau.
3. **Agregação:** combinar (sobrepor) as áreas truncadas de todas as regras disparadas para a variável de saída.
4. **Defuzzificação:** converter a área agregada num valor crisp (ex.: centroide).

Função de pertença triangular (a, b, c)

μ sobe de a até b (pico = 1 em b) e desce de b até c. Para um valor x calcula-se a fração no lado correspondente. Trapezoidal (a, b, c, d): $\mu = 1$ entre b e c.

$$\mu_{\text{triangular}}(x) = \max(\min((x-a)/(b-a) , (c-x)/(c-b)) , 0)$$

Exemplo: Morno = (15, 25, 35), $x = 28 \rightarrow (35-28)/(35-25) = 0.7$.

Defuzzificação — métodos

- **Centroide / Center of Area (COA):** o mais pedido. $z^* = \sum (x_i \cdot \mu(x_i)) / \sum \mu(x_i)$.
- **Outros:** Max membership (critério máximo), média pesada, mean-max (middle of maxima), center of sum, first/last of maxima.

$$\text{Centroide: } z^* = \sum (z_i \cdot \mu(z_i)) / \sum \mu(z_i)$$

Exemplo: após agregação, pontos (0,0),(20,0.2),(40,0.6),(60,0.6),(80,0.3),(100,0): $z^* = (20 \cdot 0.2 + 40 \cdot 0.6 + 60 \cdot 0.6 + 80 \cdot 0.3) / (0.2 + 0.6 + 0.6 + 0.3) \approx 51.76$.

Receita do FIS no exame: (1) fuzzificar cada entrada (calcular μ em cada termo, com a fórmula triangular/trapezoidal); (2) para cada regra, grau = min (AND) ou max (OR) dos antecedentes; regras com grau 0 não disparam; (3) truncar/agregar as saídas; (4) defuzzificar pelo centroide. Mostre sempre os μ e a soma no denominador.

5. Tratamento e Análise de Dados (Datasets)

5.1 Aprendizagem de máquina — tipos

- **Supervisionada:** aprende com exemplos rotulados (target). Inclui classificação (categorias) e regressão/previsão (valores contínuos). Ex.: regressão, redes neuronais.
- **Não supervisionada:** sem target; agrupamento/clustering, segmentação.
- **Por reforço:** aprende por recompensa; robótica, jogos.

Objetivo geral: aprender com dados conhecidos para resolver problemas novos. Pipeline: recolher dados → tratar (feature engineering) → treinar → avaliar.

5.2 Dataset e atributos

- **Dataset = tabela:** colunas = atributos (features); linhas = exemplos. Em classificação há uma coluna target.
- **Bons atributos:** informativos, disponíveis, discriminantes, independentes e simples.
- **Os algoritmos de ML precisam de dados numéricos.**

5.3 Análise exploratória, limpeza, transformação, seleção, redução

Análise exploratória (AED)

Analisar atributos (valores em falta, tipos, redundância, atributos não discriminantes, outliers, escalas, estatística) e o target (nº de classes, balanceamento). Estatística: média, moda, mediana, desvio-padrão. Gráficos: dispersão (correlação, outliers) e histogramas (balanceamento, gamas).

Limpeza

- **Redundâncias:** eliminar linhas duplicadas e colunas com baixa variância, valor único ou deriváveis de outras (ex.: data de nascimento → idade).
- **Outliers:** valores extremos. Detetar por desvio-padrão ou IQR; afetam média/desvio e modelos como a regressão linear. Remover ou corrigir (se for ruído/erro).
- **Valores em falta (NaN):** eliminar linhas; preencher com aleatório; preencher com estatística (média/moda/mediana); ou prever (CBR, regressão, redes neuronais).

Transformação (dados → números)

Numéricos	Categóricos
Normalização (máx ou min-max): leva a [0,1].	Ordinais → inteiros por escala (Baixo,Médio,Alto → 1,2,3).
Standardização (z-score): média 0, desvio 1.	Nominais → inteiro codificado ou one-hot encoding (array binário).

Normalização (máx): $X' = X_i / \max(X)$
 Normalização (min-max): $X' = (X_i - \min) / (\max - \min)$
 Standardização (z): $X' = (X_i - \mu) / \sigma$

Normalização	Standardização
Gama [0,1]; mantém a forma dos dados.	Centra na média, desvio 1; altera a forma.
Útil se a distribuição é desconhecida/não gaussiana; sensível a outliers.	Útil se gaussiana/desconhecida; menos sensível a outliers; preserva relações.
Redes neuronais, regressão.	Clustering, SVM.

Seleção e redução de atributos

Reduzir o nº de atributos diminui ruído, melhora desempenho e simplifica o modelo. Selecionar pelos atributos com maior correlação com o target, ou deixar o próprio algoritmo escolher (ex.: árvores de decisão). Os melhores candidatos: discriminantes, variância elevada, poucos outliers.

Avaliação do modelo: usar métricas (erro, accuracy) na fase de treino e de teste/validação; vigiar o overfitting; usar cross-validation. Estes conceitos aparecem em escolha múltipla e ligam-se a regressão e redes neuronais.

6. Redes Neurais I — Perceptron

6.1 Neurónio artificial

Inspirado no neurónio biológico. Calcula uma **função de entrada** (soma pesada das entradas + bias) e aplica uma **função de ativação**:

$$IN = b \cdot w_0 + \sum_i x_i \cdot w_i \quad y = g(IN)$$

- Topologia, função de ativação e algoritmo de aprendizagem definem a rede.
- **Bias**: peso adicional w_0 (entrada fixa $b=1$) que ajusta o limiar de disparo; torna o modelo mais flexível (na reta $y=ax+b$, o bias é o b).

6.2 McCulloch-Pitts (1943)

- Primeiro modelo de neurónio. Binário (saída 0/1), com limiar fixo θ .
- Não aprende — os pesos não se atualizam; escolhem-se à mão.
- Implementa portas lógicas (AND, OR, NOR) escolhendo pesos e θ . Ex.: AND com $w_1=w_2=1$ e $\theta \geq 2$; OR com $w_1=w_2=1$ e $\theta \geq 1$.

6.3 Perceptron (Rosenblatt, 1957) e ADALINE (Widrow-Hoff, 1960)

Introduzem **aprendizagem supervisionada**: ajustam os pesos a partir do erro. Função de ativação Step (degrau):

$$y = 1 \text{ se } S \geq 0 ; \quad y = 0 \text{ se } S < 0 \quad (S = b \cdot w_0 + \sum x_i w_i)$$

Regra Delta (Widrow-Hoff) — atualização dos pesos

$$\begin{aligned} \text{erro} &= \text{target} - y \\ \Delta w_i &= \eta \cdot (\text{target} - y) \cdot x_i & w_i &= w_i + \Delta w_i \\ w_0 \text{ (bias): } \Delta w_0 &= \eta \cdot (\text{target} - y) \cdot b \end{aligned}$$

η = coeficiente de aprendizagem. Perceptron: $\Delta w_i = \eta \cdot \text{target} \cdot x_i$; ADALINE: $\Delta w_i = \eta \cdot (\text{target} - y) \cdot x_i$. (Regra de Hebb: reforçar a ligação se ambos os neurónios disparam.)

Algoritmo e conceitos

1. Inicializar os pesos com valores aleatórios.
2. Para cada exemplo: calcular a saída y ; calcular o erro; ajustar os pesos pela regra delta.
3. Repetir até erro = 0 (ou outro critério).
 - **Época**: uma passagem por todo o dataset.
 - **Iteração**: processamento de cada exemplo até completar a época.

Linha de decisão e limitação

A fronteira é uma reta: $b \cdot w_0 + x_1 w_1 + x_2 w_2 = 0$, donde $x_2 = -x_1 \cdot (w_1/w_2) - b \cdot (w_0/w_2)$.

Limitação (Minsky & Papert, 1969): o perceptron/ADALINE só aprende funções **linearmente separáveis**. O XOR não é linearmente separável → motiva a rede multicamada.

Receita de treino do perceptron no exame: monte uma tabela por exemplo: $S = b \cdot w_0 + x_1 w_1 + x_2 w_2 \rightarrow y$ (Step/Sinal) → erro = target - y → atualizar w_0, w_1, w_2 . Repita para os 3-4 exemplos (= 1 época) e dê os pesos finais. Atenção à função pedida: Step dá 0/1; Sinal (Sign) dá -1/+1.

7. Redes Neurais II — Multicamada e Backpropagation

7.1 Do perceptron à rede feedforward

- O XOR resolve-se com uma **camada escondida** (mais do que um neurónio).
- Perceptron → separa por uma reta (linearmente separável). MLP → separa por plano/hiperplano (não linearmente separável).
- **Rede feedforward**: informação flui da entrada para a saída, sem ciclos. Camada de entrada (n° nós = n° features), camadas escondidas (topologia a ajustar), camada de saída (n° nós = n° classes/saídas).

7.2 Função de ativação sigmoide

$$y = 1 / (1 + e^{(-x)}) \quad \text{out} = 1 \text{ se } y \geq 0.5 ; 0 \text{ se } y < 0.5$$

- Não linear, contínua e diferenciável → pode ser usada com gradiente descendente (ao contrário do Step).
- Outras: RELU, tangente, softmax. Pode usar-se uma diferente por camada.

7.3 Treino: gradiente descendente

Minimiza uma função de custo (erro). Soma do erro quadrático para o exemplo: $E_a = \frac{1}{2} \sum (t_a - y_a)^2$. Os pesos descem na direção oposta ao gradiente:

$$\begin{aligned} \Delta w_i &= -\eta \cdot \partial E / \partial w_i \\ \Delta w_i &= \eta \cdot \sum_d (t_d - y_d) \cdot x_{i,d} \quad w_i = w_i + \Delta w_i \end{aligned}$$

7.4 Backpropagation (Rumelhart, Hinton & Williams, 1986)

Algoritmo que ajusta TODOS os pesos de uma rede feedforward (muitos pesos, várias camadas).

1. **Forward pass**: aplicar as entradas e calcular a saída da rede.
2. **Calcular o erro** na saída (custo) comparando com o target.
3. **Backward pass**: retropropagar o erro, calculando o gradiente do erro em relação a cada peso (reforça ligações que ativam a saída certa — ideia de Hebb).
4. **Atualizar os pesos** com o gradiente; repetir para todos os exemplos até convergir (erro ≈ 0 , n° de iterações, etc.).

7.5 Generalização vs Overfitting

- **Generalização**: a rede responde bem a exemplos novos, não vistos no treino.
- **Overfitting**: adapta-se demais ao treino e falha em dados novos (ex.: 100% no treino, 10% no teste). Anula o propósito da aprendizagem.
- **Evitar overfitting**: mais exemplos; dividir bem (treino/validação/teste); cross-validation; regularização; testar topologias diferentes.

Topologia (pergunta de desenho): para «duas camadas escondidas com 2 neurónios cada», desenhe: entrada com 1 nó por feature → 2 nós (h.e.1) → 2 nós (h.e.2) → saída com 1 nó por classe, todos os nós ligados entre camadas. Indique as dimensões de cada camada (ex.: 3 entradas, 2-2 escondidas, 3 saídas).

8. Modelos de Regressão

8.1 Ideia

- Aprendizagem supervisionada para **previsão** de valores contínuos (a classificação prevê categorias).
- **Simple**: relação entre duas variáveis — reta $y = a \cdot x + b$ (a = declive; b = ordenada na origem / bias).
- **Múltipla**: várias variáveis independentes → um plano. Não linear: relações polinomiais/exponenciais.
- **Resíduos (erros)**: diferença entre o valor observado e o previsto, $\text{erro}_i = y_i - \hat{y}_i$.

Coefficiente de Pearson: mede a correlação, entre -1 e 1 (1 positiva, -1 negativa, 0 sem correlação).

Atenção: correlação não é causalidade. $R^2 = (\text{Pearson})^2$.

8.2 Método dos mínimos quadrados (MMQ)

Método **não iterativo** que encontra a e b minimizando a soma dos quadrados dos resíduos ($\text{SSE} = \sum (y_i - (a \cdot x_i + b))^2$). Resolve-se o sistema das equações normais:

$$\begin{aligned} a \cdot \sum x_i^2 + b \cdot \sum x_i &= \sum (x_i \cdot y_i) \\ a \cdot \sum x_i + b \cdot n &= \sum y_i \end{aligned}$$

Exemplo: com $x=\{1,3,4\}$, $y=\{7,10,15\}$: $\sum x^2=26$, $\sum x=8$, $\sum xy=97$, $\sum y=32$, $n=3 \rightarrow 26a+8b=97$ e $8a+3b=32 \rightarrow a=2.5$, $b=4 \rightarrow y = 2.5x + 4$.

8.3 Métricas de avaliação

Métrica	Fórmula	Significado
SSE	$\sum (y_i - \hat{y}_i)^2$	Soma dos quadrados dos erros.
MAE	$\sum y_i - \hat{y}_i / n$	Erro absoluto médio.
MSE	$\sum (y_i - \hat{y}_i)^2 / n$	Erro quadrático médio.
RMSE	$\sqrt{(\sum (y_i - \hat{y}_i)^2 / n)}$	Raiz do MSE (mesma unidade de y).
R^2	$1 - \sum (y_i - \hat{y}_i)^2 / \sum (y_i - \bar{y})^2$	% de variação explicada; 0...1; perto de 1 = bom ajuste.

8.4 Gradiente descendente para regressão

Método **iterativo** que ajusta a e b passo a passo na direção oposta ao gradiente do erro. Com LR = coeficiente de aprendizagem:

$$\begin{aligned} a &= a - \text{LR} \cdot 2 \cdot \sum (a \cdot x_i + b - y_i) \cdot x_i \\ b &= b - \text{LR} \cdot 2 \cdot \sum (a \cdot x_i + b - y_i) \end{aligned}$$

Por iteração: para cada x_i calcule $(a \cdot x_i + b - y_i)$ e $(a \cdot x_i + b - y_i) \cdot x_i$; some; multiplique por 2; atualize a e b . Ex.: $a=8$, $b=12$, $\text{LR}=0.01 \rightarrow$ somas -42 e -12 $\rightarrow a = 8 - 0.01 \cdot (-42) = 8.42$; $b = 12 - 0.01 \cdot (-12) = 12.12$.

MMQ vs gradiente: se a pergunta pede «a reta que melhor aproxima», resolva o sistema do MMQ (exato). Se pede «execute N iterações do gradiente descendente com a , b iniciais e LR», use as fórmulas de atualização. Não confunda os dois.

9. Árvores de Decisão

9.1 Conceitos

- Modelo supervisionado para **classificação ou regressão**. Aprende regras de decisão a partir dos dados.
- Cada pergunta = nó; cada resposta = ramo; decisão final = folha. Um caminho da raiz à folha = uma regra.
- **Terminologia**: nó raiz (todos os exemplos), critério de divisão (splitting), nós de decisão, nós folha (terminais), ramo/sub-árvore, profundidade.

A questão central: qual o melhor atributo para dividir primeiro? Escolhe-se com um critério de impureza/ganho.

9.2 Critérios de divisão

Entropia e Ganho de Informação (ID3) — para atributos categóricos

$$\begin{aligned} \text{Entropia}(D) &= -\sum p_i \cdot \log_2(p_i) \\ E(\text{atributo}) &= \sum \text{peso}_j \cdot \text{Entropia}(S_j) \quad (\text{peso} = n^\circ \text{ exemplos no ramo} / \text{total}) \\ \text{Ganho}(D, A) &= \text{Entropia}(D) - E(A) \end{aligned}$$

- Entropia 0 = nó puro (uma só classe); entropia 1 = máxima incerteza (50/50).
- Escolher o atributo com **MAIOR ganho** (= menor entropia ponderada).
- ID3 só trabalha nativamente com atributos categóricos; quando um nó fica puro, torna-se folha; nas iterações seguintes, os atributos já usados não voltam a ser considerados.

Impureza de Gini

$$\begin{aligned} \text{Gini}(\text{nó}) &= 1 - \sum p_k^2 \\ \text{Gini}(\text{atributo}) &= \sum \text{peso}_j \cdot \text{Gini}(\text{nó}_j) \end{aligned}$$

Escolher o atributo com o **MENOR valor de Gini ponderado**. Ex.: nó com 8 «pratica»/2 «não» → $\text{Gini} = 1 - (0.8^2 + 0.2^2) = 0.32$.

Redução da variância — para targets contínuos

$$\text{Variância} = \sum [k_i \cdot (X_i - \mu)^2] / n \quad (\text{escolher menor variância})$$

9.3 Exemplo ID3 (resumo) e algoritmos relacionados

Calcula-se Entropia(D), depois o ganho de cada atributo; o de maior ganho fica na raiz. Repete-se em cada ramo, excluindo atributos já usados, até nós puros. Ex. típico: Céu tem o maior ganho → raiz; segue-se Humidade/Vento nos ramos. Outros algoritmos: ID4, C4.5, CART, Random Forest.

Vantagens e desvantagens

Vantagens	Desvantagens
Fáceis de compreender; mínima preparação de dados.	Podem ficar complexas com muitos atributos.
Extensíveis; combináveis com outras metodologias.	Propensas a overfitting.

Entropia/Ganho vs Gini: ambos respondem «qual atributo no nó de decisão?», mas a regra de escolha é oposta — MAIOR ganho de informação, MENOR impureza de Gini. Mostre sempre os pesos de cada ramo e os cálculos de cada subconjunto.

10. Formulário — resumo rápido

CBR

Sim. Global = $1 - D$
 $D_L = \sum (d_i \cdot w_i) / \sum w_i$ $D_E = \sum (d_i^2 \cdot w_i) / \sum w_i$
 Local simbólica: $d = 1 - TS(v1, v2)$

MYCIN (fatores de certeza)

AND $\rightarrow$ min · OR $\rightarrow$ max · NOT $\rightarrow$ -CF
 $CF_{concl} = CF_{cond} \times CF_{regra}$
 ambos+: $CF_1 + CF_2(1 - CF_1)$ | ambos-: $CF_1 + CF_2(1 + CF_1)$
 opostos: $(CF_1 + CF_2) / (1 - \min(|CF_1|, |CF_2|))$

Bayes / Redes Bayesianas

$P(A|B) = P(B|A) \cdot P(A) / P(B)$
 $P(B) = \sum P(B|A_i) \cdot P(A_i)$
 Conjunta: $P(x_1..x_n) = \prod P(x_i | Pais(x_i))$
 Causal $\rightarrow$ prob. total | Diagnóstico $\rightarrow$ Bayes

Fuzzy

AND = min · OR = max · NOT = $1 - \mu$
 Triangular(a,b,c): $\max(\min((x-a)/(b-a), (c-x)/(c-b)), 0)$
 Centroide: $z^* = \sum (z_i \cdot \mu(z_i)) / \sum \mu(z_i)$

Dados

Norm. máx: $X/\max$ | min-max: $(X - \min) / (\max - \min)$
 Standard (z): $(X - \mu) / \sigma$

Perceptron

$S = b \cdot w_0 + \sum x_i w_i$; Step: $y=1$ se $S \geq 0$ senão 0
 $\Delta w_i = \eta \cdot (\text{target} - y) \cdot x_i$; $w_i = w_i + \Delta w_i$

Redes feedforward

Sigmoide: $y = 1 / (1 + e^{(-x)})$
 Custo: $E = \frac{1}{2} \sum (t - y)^2$; $\Delta w_i = \eta \sum (t - y) \cdot x_i$

Regressão

MMQ: $a \sum x^2 + b \sum x = \sum xy$; $a \sum x + b n = \sum y$
 $MAE = \sum |y - \hat{y}| / n$; $MSE = \sum (y - \hat{y})^2 / n$; $RMSE = \sqrt{MSE}$
 $R^2 = 1 - \sum (y - \hat{y})^2 / \sum (y - \bar{y})^2$
 Grad.: $a = a - LR \cdot 2 \sum (ax_i + b - y_i) x_i$; $b = b - LR \cdot 2 \sum (ax_i + b - y_i)$

Árvores de decisão

Entropia = $-\sum p_i \cdot \log_2(p_i)$; Ganho = $E(D) - E(A)$ [MAIOR]

$$\text{Gini} = 1 - \sum p_k^2 \text{ [MENOR] ; Variância} = \sum k(X-\mu)^2/n$$

Bom estudo! Treine cada procedimento da Parte II com os exames resolvidos das épocas anteriores — é a forma mais rápida de consolidar.

PARTE II

Exames Resolvidos passo a passo

Época Normal 17/06/2024 · Época Especial 24/07/2025

Exame Resolvido 1 — Época Normal (17/06/2024)

Grupo 1 — Raciocínio Baseado em Casos (CBR) [20%]

Base de casos (domínio [1,100]): Caso 1 (A=70, B=60, C=80 → Sim); Caso 2 (20, 30, 50 → Não); Caso 3 (50, 50, 100 → Sim). Novo caso: A=60, B=50, C=90. Pesos: A=2, B=2, C=1.

Passo 1 — distância local (normalizada por 100)

Como os atributos vão de 1 a 100, normaliza-se dividindo por 100, ficando cada distância entre 0 e 1: $d = |\text{valor_caso} - \text{valor_novo}| / 100$.

Caso	dA	dB	dC
1 (70,60,80)	$ 70-60 /100 = 0,10$	$ 60-50 /100 = 0,10$	$ 80-90 /100 = 0,10$
2 (20,30,50)	$ 20-60 /100 = 0,40$	$ 30-50 /100 = 0,20$	$ 50-90 /100 = 0,40$
3 (50,50,100)	$ 50-60 /100 = 0,10$	$ 50-50 /100 = 0$	$ 100-90 /100 = 0,10$

Passo 2 — distância global pesada e similaridade

Distância global linear: $D = \sum(d_i \cdot w_i) / \sum w_i$, com $\sum w_i = 2+2+1 = 5$. Similaridade = $1 - D$.

Caso	D global	Similaridade = 1 - D
1	$(2 \cdot 0,10 + 2 \cdot 0,10 + 1 \cdot 0,10) / 5 = 0,10$	0,90
2	$(2 \cdot 0,40 + 2 \cdot 0,20 + 1 \cdot 0,40) / 5 = 0,32$	0,68
3	$(2 \cdot 0,10 + 2 \cdot 0 + 1 \cdot 0,10) / 5 = 0,06$	0,94

Resposta: a) Sim. = 0,90 / 0,68 / 0,94. b) Ordem de recuperação: Caso 3 (0,94) → Caso 1 (0,90) → Caso 2 (0,68). c) Não reter: o novo caso é quase igual ao Caso 3 (94%), logo redundante.

Dica de exame: Sequência fixa: normalizar → distância local → distância global pesada → similaridade = $1 - D$ → o de maior similaridade é o recuperado.

Grupo 2 — Redes Bayesianas [15%]

Rede: Sol e Vento → Praia. $P(\text{Sol}=T)=0,5$; $P(\text{Vento}=T)=0,2$; $P(\text{Praia}=N\grave{a}o \mid \text{Sol}=T, \text{Vento}=T)=0,2$.

Probabilidade conjunta = produto de cada nó dado os pais:

$$P(\text{Sol}=T, \text{Vento}=T, \neg \text{Praia}) = 0,5 \times 0,2 \times 0,2 = 0,02$$

Resposta: 0,02 (2%).

Nota: é inferência simples por conjunta. Se a evidência estivesse no efeito (Praia) e perguntassem a causa, seria diagnóstico → teorema de Bayes.


Grupo 3 — Lógica Difusa [15%]

$\tilde{A} = \{(1;0,1), (2;0,7), (3;1,0)\}$; $\tilde{N} = \{(1;0,4), (3;0,4), (4;1,0), (5;0,6)\}$. Operações: $\cap$ = mínimo, $\cup$ = máximo, $\neg$ = 1 - grau (universo {1..5}).

Operação	Resultado
$\tilde{A} \cap \tilde{N}$ (mín)	$\{(1; 0,1), (3; 0,4)\}$
$\tilde{A} \cup \tilde{N}$ (máx)	$\{(1; 0,4), (2; 0,7), (3; 1,0), (4; 1,0), (5; 0,6)\}$
$\neg \tilde{N}$ ($1 - \mu$)	$\{(1; 0,6), (2; 1,0), (3; 0,6), (4; 0), (5; 0,4)\}$

b) Área agregada (fraco@0,3 • médio@0,5 • alto@0,7)

Corta-se cada termo no seu grau e agrega-se pelo máximo (contorno superior, a verde):



Áreas truncadas (tracejado) e agregação resultante (verde). Domínio [0,10].

c) Defuzzificação pelo Centróide

Centros dos termos: fraco→2, médio→5, alto→8. $z^* = \sum(\text{centro}_i \cdot \mu_i) / \sum \mu_i$.

$$z^* = (2 \cdot 0,3 + 5 \cdot 0,5 + 8 \cdot 0,7) / (0,3 + 0,5 + 0,7) = 8,7 / 1,5 = 5,8$$

Resposta: n e U acima; $z^* = 5,8$.

Grupo 4 — Regressão Linear [15%]

$X = \{2, 9, 5, 7, 8, 1\}$; $Y = \{7, 5, 5, 2, 3, 4\}$; $n = 6$.

Somatórios: $\sum x = 32$, $\sum y = 26$, $\sum x^2 = 224$, $\sum xy = 126$.

a) Mínimos quadrados

$$a = (n \cdot \sum xy - \sum x \cdot \sum y) / (n \cdot \sum x^2 - (\sum x)^2) = (756 - 832) / (1344 - 1024) = -76 / 320 = -0,2375$$

$$b = (\sum y - a \cdot \sum x) / n = (26 + 7,6) / 6 = 5,6$$

Resposta: $y = -0,2375 \cdot x + 5,6$.

b) Erro Absoluto Médio (MAE)

Calcula-se $\hat{y}$ em cada x e a média de $|y - \hat{y}|$:

x	2	9	5	7	8	1
$ y - \hat{y} $	1,875	1,5375	0,5875	1,9375	0,7	1,3625

$$MAE = (1,875 + 1,5375 + 0,5875 + 1,9375 + 0,7 + 1,3625) / 6 = 8,0 / 6 \approx 1,33$$

Resposta: $MAE \approx 1,33$.

Grupo 5 — Perceptron [20%]

Pesos iniciais: $w_0 = -1$, $w_1 = 1$, $w_2 = 1$; $b = 1$; $\eta = 1$; Step ($y = 1$ se $S \geq 0$, senão 0). $S = b \cdot w_0 + x_1 \cdot w_1 + x_2 \cdot w_2$.

a) $x_1 = 0$, $x_2 = 1$, $b = 1$

$$S = 1 \cdot (-1) + 0 \cdot 1 + 1 \cdot 1 = 0 \geq 0 \rightarrow y = 1$$

Resposta: $y = 1$.

b) Uma época (regra delta: $w_i \leftarrow w_i + \eta \cdot (\text{target} - y) \cdot x_i$)

Ex.	x_1	x_2	S	y	target	erro	w_0	w_1	w_2
início	-	-	-	-	-	-	-1	1	1
1	0	1	0	1	1	0	-1	1	1
2	1	2	2	1	0	-1	-2	0	-1
3	2	1	-3	0	0	0	-2	0	-1

No exemplo 2 deu $y=1$ mas o target era 0 (erro -1): baixam-se os pesos. No exemplo 3 já acerta. Os exemplos seguintes usam sempre os pesos atualizados.

Resposta: $w_0 = -2$; $w_1 = 0$; $w_2 = -1$.

Grupo 6 — Árvores de Decisão [15%]

Target 'Ir à Praia': Verdade nos dias 1,2,4; Falso nos dias 3,5,6 (3 e 3).

a) Entropia do dataset

$$E(D) = -0,5 \cdot \log_2(0,5) - 0,5 \cdot \log_2(0,5) = 0,5 + 0,5 = 1,0$$


b) Ganho de informação de 'Sol'

Sol=Sim (dias 1,2,4) → todos Verdade → $E=0$. Sol=Não (dias 3,5,6) → todos Falso → $E=0$.

$$E(\text{Sol}) = (3/6) \cdot 0 + (3/6) \cdot 0 = 0 \rightarrow \text{Ganho}(\text{Sol}) = 1 - 0 = 1,0$$

c) Árvore ID3

'Sol' tem ganho 1,0 (máximo) e separa tudo na perfeição → fica na raiz; 'Vento' não é preciso.



Resposta: $E(D)=1,0$; $\text{Ganho}(\text{Sol})=1,0$; raiz = Sol (Sim→Verdade, Não→Falso).

Exame Resolvido 2 — Época Especial (24/07/2025)

Grupo I — Escolha múltipla (1 a 20)

Cada erro desconta 25% da cotação — em dúvida total, mais vale deixar em branco.

#	R	Justificação	#	R	Justificação
1	B	Revise = avaliar e corrigir	11	C	Atribui grau de associação
2	B	Adaptar = fase Reuse	12	A	AND difuso = mínimo
3	C	Recupera pela semelhança	13	B	1 dependente, 1 independente
4	A	Aprende ao rever/reter	14	C	Prever a dependente
5	C	Arestas = dependência condicional	15	A	R^2 mede a força da relação
6	B	Diagnóstico médico	16	A	Resíduo = previsto - observado
7	C	Nós = variáveis aleatórias	17	C	Pesos = influência da entrada
8	B	Bayes infere de evidências	18	B	Captam padrões complexos
9	A	Incerteza/imprecisão	19	C	Classificação binária linear
10	C	Controlo de temperatura	20	B	Ativação da soma ponderada

Resposta: 1-B 2-B 3-C 4-A 5-C 6-B 7-C 8-B 9-A 10-C 11-C 12-A 13-B 14-C 15-A 16-A 17-C 18-B 19-C 20-B.

21 — Raciocínio Lógico (forward chaining) [10%]

O forward chaining parte dos factos e dispara qualquer regra cujas condições estejam todas satisfeitas, juntando as conclusões como novos factos, e repete. Analisa-se por pessoa.

Pessoa	Factos	Regras que disparam
João	febre, dores	R3 (resfriado), R2 (constipação)
Maria	febre	R3 (resfriado)
Ana	febre, dores, tosse	R1 (gripe), R2, R3 e — em 2.ª passagem — R4 (marcar consulta)

Resposta: Ativam-se R1, R2, R3 e R4. R4 só dispara depois de R1 produzir 'gripe' (encadeamento).

22 — Redes Bayesianas [10%]

$P(\text{Temp}=Alta)=0,2$; $P(\text{Pressão}=Baixa)=0,15$; $P(\text{Falha}=Não \mid \text{Temp}=Alta, \text{Pressão}=Baixa)=0,05$.

$$P(\text{Temp}=Alta, \text{Pressão}=Baixa, \neg \text{Falha}) = 0,2 \times 0,15 \times 0,05 = 0,0015$$

Resposta: 0,0015.


23 — Lógica Difusa [10%]

$\tilde{A} = \{(1;0,1), (2;0,7), (3;1,0)\}$; $\tilde{N} = \{(1;0,4), (3;0,4), (4;1,0), (5;0,6)\}$; domínio $[1,10]$.

Operação	Resultado
$\tilde{A} \cap \tilde{N}$ (mín)	$\{(1; 0,1), (3; 0,4)\}$
$\tilde{A} \cup \tilde{N}$ (máx)	$\{(1; 0,4), (2; 0,7), (3; 1,0), (4; 1,0), (5; 0,6)\}$
$\neg \tilde{N}$ ($1 - \mu$, domínio $[1,10]$)	$\{(1;0,6), (2;1,0), (3;0,6), (4;0), (5;0,4), (6;1,0), (7;1,0), (8;1,0), (9;1,0), (10;1,0)\}$

Atenção: como o domínio é $[1,10]$, o complemento inclui os elementos 6 a 10 (que valem 0 em $\tilde{N}$) a 1,0.

b) Área agregada (fraco@0,5 • médio@0,25 • alto@0,75)



Áreas truncadas (tracejado) e agregação resultante (verde). Domínio [0,20].

c) Defuzzificação pelo Centroide

Centros: fraco→5, médio→10, alto→15.

$$z^* = (5 \cdot 0,5 + 10 \cdot 0,25 + 15 \cdot 0,75) / (0,5 + 0,25 + 0,75) = 16,25 / 1,5 \approx 10,83$$

Resposta: n e U acima; $z^* \approx 10,83$.

24 — Regressão Linear [20%]

x (investimento) = {4,30; 9,56; 7,59; 6,39; 2,40}; y (vendas) = {10,20; 25,10; 22,02; 15,30; 5,70}; n=5.

Modelo dado: $y = 2,8x - 1,5$.

a) Coeficiente de Pearson (calcula-se dos dados, não do modelo)

$\Sigma x = 30,24$; $\Sigma y = 78,32$; $\Sigma xy = 562,39$; $\Sigma x^2 = 214,08$; $\Sigma y^2 = 1485,51$.

$$r = (n \cdot \Sigma xy - \Sigma x \cdot \Sigma y) / \sqrt{[(n \cdot \Sigma x^2 - (\Sigma x)^2)(n \cdot \Sigma y^2 - (\Sigma y)^2)]}$$

$$= 443,58 / \sqrt{(155,96 \cdot 1293,53)} = 443,58 / 449,16 \approx 0,99$$

Conclusão: $r \approx 0,99 \rightarrow$ correlação positiva muito forte (quase linear): mais investimento, mais vendas.

b) MSE (modelo $y = 2,8x - 1,5$)

x	4,30	9,56	7,59	6,39	2,40
$(y - \hat{y})^2$	0,116	0,028	5,144	1,192	0,230

$$MSE = (0,116 + 0,028 + 5,144 + 1,192 + 0,230) / 5 = 6,71 / 5 \approx 1,34$$

c) Previsão para investimento = 10 k€

$$\hat{y} = 2,8 \cdot 10 - 1,5 = 26,5 \text{ k€}$$

Resposta: $r \approx 0,99$ (forte, positiva); $MSE \approx 1,34$; previsão = 26,5 k€.

25 — Perceptron [10%]

Pesos iniciais: $w_0 = -1$, $w_1 = 1$, $w_2 = -1$; $b = 1$; $\eta = 1$; Step. $S = b \cdot w_0 + x_1 \cdot w_1 + x_2 \cdot w_2$.

a) $x_1 = 1$, $x_2 = 1$, $b = 1$

$$S = 1 \cdot (-1) + 1 \cdot 1 + 1 \cdot (-1) = -1 < 0 \rightarrow y = 0$$

Resposta: $y = 0$.

b) Uma época (regra delta)

Ex.	x_1	x_2	S	y	target	erro	w_0	w_1	w_2
início	-	-	-	-	-	-	-1	1	-1
1	1	1	-1	0	0	0	-1	1	-1
2	0	2	-3	0	0	0	-1	1	-1
3	2	0	1	1	-1	-2	-3	-3	-1

No exemplo 3, $y=1$ mas $\text{target}=-1 \rightarrow \text{erro} = -1 - 1 = -2$ (correção forte). w_2 não muda porque $x_2=0$; w_1 é o que mais desce porque $x_1=2$.

Resposta: $w_0 = -3$; $w_1 = -3$; $w_2 = -1$.

26 — Árvores de Decisão [20%]

Target 'Animal?': Verdade nos casos 1,4,5; Falso nos casos 2,3 (3 V, 2 F).

a) Entropia do dataset

$$E(D) = -(3/5) \cdot \log_2(3/5) - (2/5) \cdot \log_2(2/5) \approx 0,442 + 0,529 \approx 0,971$$

b) Ganho de informação de 'Som'


Som: Grave {1,3}=1V1F (E=1); Agudo {2,4}=1V1F (E=1); Ligeiro {5}=1V (E=0).

$$E(\text{Som}) = (2/5) \cdot 1 + (2/5) \cdot 1 + (1/5) \cdot 0 = 0,8 \rightarrow \text{Ganho}(\text{Som}) = 0,971 - 0,8 = 0,171$$

c) Árvore ID3

Compara-se também 'Movimento': Sim {1,4,5}=3V (E=0); Não {2,3}=2F (E=0) $\rightarrow E=0$ e $\text{Ganho}=0,971$.

Como Movimento (0,971) > Som (0,171), a raiz é **Movimento** — separa tudo na perfeição e 'Som' nem é usado.



Dica de exame: Armadilha: a alínea b) faz calcular o ganho do 'Som', mas o ID3 escolhe o 'Movimento' por ter ganho maior. Calcula sempre os dois para justificar a raiz.

Resposta: $E(D) \approx 0,971$; $\text{Ganho}(\text{Som}) \approx 0,171$; raiz = Movimento (Sim $\rightarrow$ V, Não $\rightarrow$ F).